UNIVERSIDAD PRIVADA ANTENOR ORREGO

FACULTAD DE INGENIERÍA

ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS E INTELIGENCIA ARTIFICIAL

TESIS PARA OPTAR EL TÍTULO PROFESIONAL DE

INGENIERO DE SISTEMAS E INTELIGENCIA ARTIFICIAL

Comparación de la Coherencia Narrativa en Campañas de Dungeons & Dragons generadas por Sistemas Multiagente versus Sistemas Monolíticos

---

Línea de investigación:

Sistemas Inteligentes

Autores:

Marin Yupanqui, Bryan Arturo

Mostacero Cieza, Luis David

Jurado Evaluador:

Presidente: [pendiente] · Secretario: [pendiente] · Vocal: [pendiente]

Asesor:

Cueva Chávez, Walter Manuel

Código Orcid: https://orcid.org/0000-0001-9660-6354

Proyecto aprobado con R.D. N.° [pendiente]

TRUJILLO, PERÚ

2026

UNIVERSIDAD PRIVADA ANTENOR ORREGO

FACULTAD DE INGENIERÍA

ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS E INTELIGENCIA ARTIFICIAL

TESIS PARA OPTAR EL TÍTULO PROFESIONAL DE

INGENIERO DE SISTEMAS E INTELIGENCIA ARTIFICIAL

Comparación de la Coherencia Narrativa en Campañas de Dungeons & Dragons generadas por Sistemas Multiagente versus Sistemas Monolíticos

---

Línea de investigación:

Sistemas Inteligentes

Autores:

Marin Yupanqui, Bryan Arturo

Mostacero Cieza, Luis David

Jurado Evaluador:

Presidente: [pendiente] · Secretario: [pendiente] · Vocal: [pendiente]

Asesor:

Cueva Chávez, Walter Manuel

Código Orcid: https://orcid.org/0000-0001-9660-6354

Proyecto aprobado con R.D. N.° [pendiente]

TRUJILLO, PERÚ

2026

Dedicatoria

[Dedicatoria de Bryan: pendiente]

Marin Yupanqui, Bryan Arturo

Agradecimiento

A la Universidad Privada Antenor Orrego, por facilitar el acceso a la infraestructura académica y los recursos bibliográficos necesarios para el desarrollo de esta investigación.

Al Mgtr. Walter Manuel Cueva Chávez, por su asesoría técnica y metodológica, cuya orientación fue determinante para la estructuración del diseño experimental y el análisis de la arquitectura MAS propuesta.

A los docentes del Programa de Estudio de Ingeniería de Sistemas e Inteligencia Artificial, por los conocimientos impartidos que sirvieron de base para diseñar, implementar y evaluar los distintos componentes del sistema.

[Dedicatoria de Luis: pendiente]

Mostacero Cieza, Luis David

A los directores de juego que participaron de manera voluntaria como evaluadores externos en la validación de los instrumentos, cuyo juicio permitió contrastar las mediciones automáticas con la experiencia humana.

A todas las personas que, de manera directa o indirecta, brindaron su tiempo, sus comentarios y el entorno académico necesarios para llevar a término este estudio.

Los autores.

Resumen

El objetivo de esta investigación fue comparar la coherencia narrativa de las campañas de Dungeons & Dragons (D&D) generadas por un sistema multiagente frente a las generadas por un sistema monolítico, ambos en el rol de director de juego. El problema que la motiva es que los modelos de lenguaje de gran escala tienden a perder el contexto, a contradecir hechos previos y a decidir por el jugador conforme la partida se extiende, y que no existe evidencia comparativa controlada entre ambas arquitecturas en el dominio de los juegos de rol de mesa.

La investigación fue aplicada, de enfoque cuantitativo y diseño experimental de medidas repetidas con pares emparejados. Se generaron 27 pares de campañas de 1,400 turnos (54 campañas y 75,600 turnos) con el mismo modelo de lenguaje (google/gemma-4-31B-it), la misma memoria estructurada del estado del mundo y el mismo extractor en ambas arquitecturas, de modo que la organización del director de juego fuera la única diferencia. Las acciones las produjo un agente jugador autónomo, y la coherencia se midió en tres dimensiones (reactiva, longitudinal y calidad narrativa emergente) con una batería de instrumentos deterministas, validados mediante pruebas de sensibilidad por perturbación y, cuando correspondía, auditorías humanas externas.

El sistema monolítico no se degradó a lo largo de los 1,400 turnos (prueba de Page, $p = 0.310$). En coherencia reactiva, ninguna arquitectura respondió mejor a la acción específica del jugador; en coherencia longitudinal, ningún instrumento alcanzó la clase confirmatoria; y en calidad narrativa emergente, el sistema multiagente usurpó de forma explícita la agencia del jugador en menos turnos (0.17 % frente a 3.47 %), diferencia que se mantuvo al corregir por la precisión del detector estimada por un evaluador humano externo. En consecuencia, la hipótesis general no se sostiene: con una memoria estructurada común, especializar agentes no mejora la coherencia medible, aunque reduce que el sistema decida por el jugador.

Palabras clave: sistemas multiagente; modelos de lenguaje de gran escala; coherencia narrativa; director de juego; Dungeons & Dragons; evaluación automática de narrativas.

Abstract

The objective of this research was to compare the narrative coherence of Dungeons & Dragons (D&D) campaigns generated by a multi-agent system with that of campaigns generated by a monolithic system, both acting as game master. The study is motivated by the tendency of large language models to lose context, contradict earlier facts and decide on the player's behalf as a campaign grows longer, and by the lack of controlled comparative evidence between both architectures in the domain of tabletop role-playing games.

The research was applied and quantitative, with a repeated-measures matched-pairs experimental design. Twenty-seven pairs of 1,400-turn campaigns were generated (54 campaigns and 75,600 turns) with the same language model (google/gemma-4-31B-it), the same structured world-state memory and the same extractor in both architectures, so that the organization of the game master was the only difference. Player actions were produced by an autonomous player agent, and coherence was measured in three dimensions (reactive, longitudinal and emergent narrative quality) with a battery of deterministic instruments validated through perturbation-based sensitivity tests and, where applicable, external human audits.

The monolithic system did not degrade over the 1,400 turns (Page test, $p = 0.310$). In reactive coherence, neither architecture responded better to the player's specific action; in longitudinal coherence, no instrument reached the confirmatory class; and in emergent narrative quality, the multi-agent system explicitly usurped the player's agency in fewer turns (0.17 % versus 3.47 %), a difference that held after correcting for the detector's precision as estimated by an external human rater. Therefore, the general hypothesis is not supported: with a shared structured memory, specializing agents does not improve measurable coherence, although it reduces the system's tendency to decide for the player.

Keywords: multi-agent systems; large language models; narrative coherence; game master; Dungeons & Dragons; automatic narrative evaluation.

Presentación

Señores miembros del jurado:

En cumplimiento de las disposiciones del Reglamento de Grados y Títulos de la Universidad Privada Antenor Orrego, sometemos a vuestra consideración la tesis titulada «Comparación de la Coherencia Narrativa en Campañas de Dungeons & Dragons generadas por Sistemas Multiagente versus Sistemas Monolíticos», desarrollada con el fin de obtener el título profesional de Ingeniero de Sistemas e Inteligencia Artificial.

La investigación compara, mediante un diseño experimental controlado de 27 pares de campañas, la coherencia narrativa que alcanzan un sistema multiagente y uno monolítico cuando desempeñan el rol de director de juego, con el propósito de aportar evidencia empírica sobre qué arquitectura conviene emplear para sostener campañas extensas sin perder la consistencia de la historia ni la agencia del jugador.

A ustedes, señores miembros del jurado, expresamos nuestro reconocimiento por el tiempo dedicado a la revisión del presente trabajo y por el dictamen que se sirvan emitir.

Marin Yupanqui, Bryan Arturo

DNI: [pendiente]

ORCID: [pendiente]

Mostacero Cieza, Luis David

DNI: [pendiente]

ORCID: [pendiente]

Índice de contenidos

Dedicatoria.....ii
Agradecimiento.....iii
Resumen.....iv
Abstract.....v
Presentación.....vi
Índice de contenidos.....vii
Índice de tablas.....x
Índice de figuras.....xi
I. INTRODUCCIÓN.....1
1.1. Problema de investigación.....1
1.1.1. Descripción de la realidad problemática.....1
1.1.2. Formulación del problema.....6
1.2. Objetivos.....8
1.2.1. Objetivo general.....8
1.2.2. Objetivos específicos.....8
1.3. Justificación del estudio.....8
1.3.1. Importancia y aportes del estudio.....10
1.4. Limitaciones del estudio.....12
1.5. Organización del documento.....15
II. MARCO DE REFERENCIA.....17
2.1. Antecedentes del estudio.....17
2.2. Marco teórico.....21
2.2.1. Marco histórico.....21
2.2.2. Coherencia narrativa.....22
2.2.3. Coherencia reactiva.....23
2.2.4. Coherencia longitudinal.....23
2.2.5. Calidad narrativa emergente.....24
2.2.6. Continuidad causal, memoria persistente y estado del mundo.....25
2.2.7. Limitaciones de los modelos de lenguaje para sostener la coherencia.....26
2.2.8. Pérdida de contexto.....26
2.2.9. Alucinación.....26
2.2.10. Complacencia y usurpación de la agencia.....27
2.2.11. Arquitecturas de inteligencia artificial para la dirección de juego.....27
2.2.12. Arquitectura monolítica.....28
2.2.13. Arquitectura multiagente.....28

2.2.14. Agente jugador autónomo....29
2.2.15. Fundamentos de la medición computacional de la coherencia....29
2.2.16. Coherencia local basada en entidades....30
2.2.17. Seguimiento del estado del mundo....30
2.2.18. Diversidad léxica y legibilidad....31
2.2.19. Validación de los instrumentos de medición....31
2.3. Marco conceptual....32
2.4. Sistema de hipótesis....34
2.4.1. Supuestos básicos....34
2.4.2. Hipótesis general....36
2.4.3. Hipótesis específicas....36
2.4.4. Variables e indicadores....39
2.4.5. Matriz de consistencia....41
III. METODOLOGÍA EMPLEADA....44
3.1. Tipo y nivel de investigación....44
3.1.1. Nivel de madurez tecnológica....44
3.1.2. Método de investigación....45
3.2. Población y muestra de estudio....45
3.3. Diseño de investigación....47
3.4. Técnicas e instrumentos de investigación....49
3.4.1. Técnica e instrumentos de generación del corpus....49
3.4.2. Técnica e instrumentos de medición....50
3.4.3. Validación de los instrumentos....51
3.5. Procedimiento de ejecución del estudio....53
3.5.1. Estudio piloto....53
3.5.2. Generación del corpus experimental....53
3.5.3. Medición y validación de los instrumentos....53
3.5.4. Desviaciones respecto del protocolo aprobado....54
3.6. Procesamiento y análisis de datos....55
3.6.1. Preparación de los datos....55
3.6.2. Contraste de las hipótesis de degradación....56
3.6.3. Contraste de las hipótesis comparativas....56
3.6.4. Análisis de robustez y de acuerdo....56
3.6.5. Reglas de decisión....57
IV. PRESENTACIÓN DE RESULTADOS....58
4.1. Propuesta de investigación: el sistema DM-IA y sus dos arquitecturas....59
4.2. Análisis e interpretación de resultados....62
4.2.1. Coherencia reactiva del sistema monolítico (OE-1)....62

4.2.2. Coherencia longitudinal del sistema monolítico (OE-2).....64
4.2.3. Calidad narrativa emergente del sistema monolítico (OE-3).....66
4.2.4. Comparación de la coherencia reactiva (OE-4).....68
4.2.5. Comparación de la coherencia longitudinal (OE-5).....70
4.2.6. Comparación de la calidad narrativa emergente (OE-6).....72
4.3. Docimasia de hipótesis.....74
4.3.1. Hipótesis H1a: degradación de la coherencia reactiva del sistema monolítico.....74
4.3.2. Hipótesis H1b: degradación de la coherencia longitudinal del sistema monolítico.....75
4.3.3. Hipótesis H1c: degradación de la calidad narrativa emergente del sistema monolítico.....76
4.3.4. Hipótesis H1d: mayor coherencia reactiva del sistema multiagente.....77
4.3.5. Hipótesis H1e: mayor coherencia longitudinal del sistema multiagente.....78
4.3.6. Hipótesis H1f: mayor calidad narrativa emergente del sistema multiagente.....78
4.3.7. Hipótesis general.....79
V. DISCUSIÓN DE LOS RESULTADOS.....81
5.1. Coherencia reactiva del sistema monolítico (OE-1).....81
5.2. Coherencia longitudinal del sistema monolítico (OE-2).....82
5.3. Calidad narrativa emergente del sistema monolítico (OE-3).....84
5.4. Comparación de la coherencia reactiva (OE-4).....86
5.5. Comparación de la coherencia longitudinal (OE-5).....88
5.6. Comparación de la calidad narrativa emergente (OE-6).....93
CONCLUSIONES.....96
RECOMENDACIONES.....100
REFERENCIAS BIBLIOGRÁFICAS.....103
ANEXOS.....113
Anexo 1. Ficha de los instrumentos de medición.....113
Anexo 2. Rúbrica D&D-IA y evaluación piloto del panel de expertos.....115
Anexo 3. Evidencias de la ejecución y trazabilidad de la investigación.....117
Anexo 4. Resolución de aprobación del proyecto de investigación.....118
Anexo 5. Constancia del asesor.....119

Índice de tablas

Tabla 1. Operacionalización de variables.....39

Tabla 2. Matriz de consistencia de la investigación.....41

Tabla 3. Estadísticos descriptivos — Coherencia reactiva, sistema monolítico (G2), n = 27 campañas.....63

Tabla 4. Estadísticos descriptivos — Coherencia longitudinal, sistema monolítico (G2), n = 27 campañas.....65

Tabla 5. Estadísticos descriptivos — Calidad narrativa emergente, sistema monolítico (G2), n = 27 campañas.....67

Tabla 6. Comparación pareada G1−G2, 27 parejas — Coherencia reactiva (H1d).....69

Tabla 7. Comparación pareada G1−G2, 27 parejas — Coherencia longitudinal (H1e).....71

Tabla 8. Comparación pareada G1−G2, 27 parejas — Calidad narrativa emergente (H1f).....73

Tabla 9. Contraste de degradación por bloques de 200 turnos — Coherencia reactiva, sistema monolítico (G2), n = 27 campañas.....75

Tabla 10. Contraste de degradación por bloques de 200 turnos — Coherencia longitudinal, sistema monolítico (G2).....76

Tabla 11. Contraste de degradación por bloques de 200 turnos — Calidad narrativa emergente, sistema monolítico (G2), n = 27 campañas.....77

Tabla 12. Acuerdo entre evaluadores en la validación humana del detector de personajes inactivos.....93

Índice de figuras

Figura 1. Diseño experimental de medidas repetidas con pares emparejados.....49

Figura 2. Ciclo del turno en las arquitecturas monolítica (G2) y multiagente (G1) de DM-IA..... 61

I. INTRODUCCIÓN

1.1. Problema de investigación

1.1.1. Descripción de la realidad problemática

Los juegos han ocupado, desde los primeros desarrollos de la inteligencia artificial, un lugar privilegiado como banco de pruebas para evaluar la capacidad de los sistemas computacionales de razonar, planificar e interactuar en entornos que, aun estando acotados por reglas explícitas, exhiben una complejidad comparable a la de numerosos problemas del mundo real, razón por la cual han sido considerados la aplicación decisiva para el desarrollo de una inteligencia artificial de nivel humano (Laird & van Lent, 2001); en consecuencia, cada avance relevante del campo ha encontrado en ellos un escenario de validación, desde la búsqueda en juegos de tablero hasta la generación procedimental de contenido y el modelado de jugadores (Yannakakis & Togelius, 2018). En la última década, no obstante, este papel se ha desplazado de manera progresiva hacia dominios abiertos en los que el lenguaje natural constituye la interfaz principal de la interacción, desplazamiento que se aceleró con la irrupción de los modelos de lenguaje de gran escala (LLMs), puesto que dichos modelos permiten formular como texto tanto el problema como su solución y, por ello, amplían de forma considerable el repertorio de funciones que un sistema de inteligencia artificial puede asumir dentro de un juego.

En ese sentido, la revisión de Gallotta et al. (2024), publicada en *IEEE Transactions on Games*, propone una tipología según la cual un LLM puede desempeñarse como jugador, personaje no jugador, asistente del jugador, comentarista, analista, mecánica de juego, diseñador automatizado, asistente de diseño o director de juego (*Game Master*), y dedica a esta última función un análisis particular, dado que el director de un juego de rol de mesa crea la trama, interpreta a los personajes y resuelve las acciones de unos jugadores cuya libertad solo está limitada por su imaginación, de modo que la historia puede tomar cualquier dirección. Sin embargo, los mismos autores advierten que los LLMs pierden el contexto y tienen dificultades para sostener la continuidad, puesto que su memoria efectiva está restringida por el tamaño de la ventana de contexto y, en consecuencia,

cuanto más se prolonga la interacción menor es la probabilidad de que el modelo recuerde los eventos tempranos, limitación que se agrava por su tendencia a producir afirmaciones plausibles pero falsas y a acomodar incluso las peticiones más extravagantes del jugador sin considerar su impacto sobre la trama (Gallotta et al., 2024). Por esta razón, las funciones que exigen un compromiso de largo plazo, como la del director de juego, se perfilan como un escenario idóneo para examinar los límites de la memoria y la coherencia de estos modelos, y si bien la generación aumentada por recuperación (RAG) se ha planteado como una vía para mitigar el problema, al permitir que el modelo consulte un archivo externo de eventos previos (Lewis et al., 2021), su efecto sobre la coherencia de narrativas interactivas extensas se presenta todavía como una solución hipotética antes que como un resultado verificado.

Dentro de este panorama, Dungeons & Dragons (D&D) se ha consolidado como un dominio de referencia para la investigación en inteligencia artificial conversacional, dado que Callison-Burch et al. (2022) lo formularon de manera explícita como un desafío de diálogo a partir de un corpus de partidas reales y que, posteriormente, el conjunto de datos FIREBALL incorporó a dichas transcripciones información estructurada del estado del juego y evaluó las respuestas generadas mediante un panel de 45 jugadores, cuyos comentarios cualitativos coincidieron en rechazar que el modelo tomara el control de su personaje (Zhu et al., 2023). En paralelo, la investigación publicada en *IEEE Transactions on Games* ha abordado tanto la generación de contenido narrativo para juegos de rol, como en el trabajo de Värtinen et al. (2024), quienes reunieron 978 misiones procedentes de seis videojuegos de rol para ajustar modelos de la familia GPT y validaron las descripciones generadas mediante un estudio con 349 jugadores, como la integración híbrida entre planificación simbólica y modelos de lenguaje, en la que Farrell y Ware (2025) emplean un LLM como guía de búsqueda de un planificador que conserva un dominio simbólico explícito, precisamente con el fin de asegurar la coherencia de historias en las que intervienen múltiples agentes.

Estos trabajos se inscriben en una trayectoria más amplia que se remonta a los sistemas de planificación narrativa de la inteligencia artificial clásica (George, 2015; Laclaustra et al., 2014), los cuales demostraron que la trama puede modelarse como una secuencia causal de acciones, aunque a costa de depender de conocimiento del dominio elaborado manualmente (Riedl & Bulitko, 2013); frente a ello, las arquitecturas multiagente se han propuesto como una alternativa capaz de distribuir las responsabilidades narrativas entre componentes especializados (Barambones et al., 2023), propuesta que se ha trasladado recientemente al paradigma de los LLMs mediante marcos como StoryWriter, en el que distintos agentes se encargan de planificar, redactar y revisar historias de gran extensión (Xia et al., 2025). De manera complementaria, Valdivia y Burelli (2025) señalan que la capacidad generativa de estos sistemas ha avanzado con mayor rapidez que los métodos disponibles para evaluar la calidad de las narrativas co-creadas con inteligencia artificial, por lo que la medición de la coherencia constituye, en sí misma, un problema de investigación abierto que condiciona cualquier comparación entre arquitecturas.

En el ámbito nacional y local, la revisión efectuada no identificó investigaciones que comparen arquitecturas de inteligencia artificial para la generación de narrativas interactivas, lo que sitúa al presente estudio como una primera aproximación a este problema en el contexto peruano. Sobre esta base, la investigación se desarrolla a partir de DM-IA, un sistema de dirección de juego para D&D 5e construido por los autores que opera bajo dos arquitecturas comparables, una multiagente y otra monolítica, las cuales comparten el mismo modelo de lenguaje, la misma base de datos del estado del mundo y el mismo mecanismo de tiradas deterministas, de modo que la diferencia entre ambas se concentra en la manera en que se distribuyen las decisiones narrativas y, en consecuencia, resulta posible contrastar de forma controlada las ventajas que la literatura atribuye a la especialización de agentes.

La generación de campañas de rol mediante modelos de lenguaje de gran escala enfrenta un problema que no se manifiesta en interacciones breves, pero que se vuelve determinante conforme la partida se prolonga, dado que

el director de juego debe conservar durante cientos de turnos la identidad de los personajes, las consecuencias de las decisiones del jugador y el estado de un mundo que cambia continuamente, mientras que la memoria efectiva de un LLM está acotada por su ventana de contexto y se degrada a medida que esta crece (Gallotta et al., 2024). Esta degradación, además, no es uniforme, puesto que Liu et al. (2024) demostraron que el desempeño de los modelos disminuye de forma significativa cuando la información relevante se ubica en la parte intermedia de contextos extensos, incluso en modelos diseñados explícitamente para contextos largos, de modo que un hecho narrativo establecido a mitad de una campaña corre un riesgo particular de ser ignorado o contradicho en los turnos posteriores, aun cuando todavía se encuentre dentro de la ventana del modelo.

En el dominio de Dungeons & Dragons, esta limitación se traduce en fallos observables que la literatura ha documentado desde distintos ángulos, dado que Callison-Burch et al. (2022) advirtieron que los modelos tienen dificultades para seguir el estado del juego a partir del diálogo, mientras que los evaluadores de FIREBALL señalaron de manera recurrente que el modelo tendía a tomar decisiones que correspondían al jugador (Zhu et al., 2023). En la misma línea, durante una evaluación piloto de la presente investigación, en la que un panel de cinco directores de juego examinó tres campañas generadas por una versión preliminar del sistema monolítico, los cinco evaluadores identificaron de manera independiente la reasignación de un mismo nombre a personajes no jugadores incompatibles entre sí, así como cambios de bando sin justificación narrativa, lo que confirma que la pérdida de coherencia longitudinal no constituye un riesgo teórico, sino un defecto que emerge de manera sistemática en campañas extensas.

Frente a este problema, las arquitecturas multiagente se han propuesto como una solución prometedora, puesto que distribuyen las responsabilidades narrativas entre agentes especializados (Barambones et al., 2023) y, en marcos como StoryWriter, logran historias largas más coherentes al separar la planificación, la redacción y la revisión (Xia et al., 2025); sin embargo, la evidencia general sobre estos sistemas es menos concluyente de lo que sugiere su adopción, dado que Cemri et al. (2025),

tras analizar siete marcos multiagente populares, reportaron que sus mejoras frente a los enfoques de un solo agente suelen ser mínimas y catalogaron catorce modos de fallo propios de la coordinación entre agentes, entre ellos la pérdida del historial de la conversación y la repetición de pasos. Por consiguiente, no puede asumirse de antemano que la especialización de agentes mejore la coherencia de una campaña de rol, en tanto que la propia medición de la coherencia plantea un problema adicional, ya que no existe consenso sobre los criterios humanos que deben emplearse para evaluar historias generadas y las métricas automáticas disponibles muestran una correspondencia limitada con dichos criterios (Chhun et al., 2022), situación que Valdivia y Burelli (2025) extienden explícitamente a las narrativas de juego co-creadas con inteligencia artificial.

En cuanto a su delimitación conceptual, el estudio aborda la coherencia narrativa en tres dimensiones, a saber, la coherencia reactiva, la coherencia longitudinal y la calidad narrativa emergente, operacionalizadas en seis indicadores que se miden mediante instrumentos deterministas contrastados con el estado persistido del mundo de juego, mientras que, en su delimitación técnica, la investigación se circunscribe al sistema de reglas de Dungeons & Dragons 5.ª edición en su documento de referencia (SRD), a campañas narradas íntegramente en español y a dos arquitecturas implementadas sobre un mismo modelo de lenguaje de pesos abiertos, google/gemma-4-31B-it, fijado en una única versión y consumido a través de un solo proveedor de inferencia. En esta configuración, la arquitectura monolítica (G2) resuelve cada turno mediante una única llamada al modelo, en tanto que la arquitectura multiagente (G1) distribuye el turno entre cinco roles especializados —enrutador, árbitro, actor de personajes no jugadores, agente del mundo y narrador—, uno de los cuales opera de forma determinista, y ambas comparten la misma base de datos del estado del mundo, el mismo extractor de cambios de estado y el mismo mecanismo de tiradas deterministas con semilla.

En cuanto a su delimitación muestral y temporal, el corpus del experimento comprende 27 pares de campañas, es decir, 54 campañas de 1,400 turnos

cada una, generadas en setiembre de 2026 con un agente jugador autónomo basado en un LLM en lugar de jugadores humanos, y cada par emplea una ambientación, un tono narrativo, una estructura de conflicto y un personaje jugador distintos a los de los demás pares, con el fin de evitar que los resultados dependan de un único escenario. Quedan fuera del alcance de la investigación, por tanto, la evaluación de la experiencia subjetiva de jugadores humanos, los componentes multimodales como imágenes o voz, la latencia y el costo de operación de cada arquitectura como variables de resultado, y el ajuste fino de los modelos, puesto que ambas arquitecturas operan con el mismo modelo base sin adaptadores entrenados.

1.1.2. Formulación del problema

¿Es superior la coherencia narrativa de campañas de Dungeons & Dragons generadas por sistemas multiagente en comparación con sistemas monolíticos de inteligencia artificial?

A partir de esta pregunta general, y en correspondencia con las tres dimensiones de la coherencia narrativa y con los dos niveles de análisis del estudio, se derivan los siguientes problemas específicos:

a) ¿Cuál es el nivel de coherencia reactiva que alcanza el sistema monolítico ante las acciones inmediatas del jugador?

b) ¿Cuál es el nivel de coherencia longitudinal y de preservación del estado del mundo que alcanza el sistema monolítico a lo largo de la campaña?

c) ¿Cuál es el nivel de calidad narrativa emergente, en términos de creatividad y de respuesta a la agencia del jugador, que alcanza el sistema monolítico?

d) ¿En qué medida difiere la coherencia reactiva de las respuestas generadas por el sistema multiagente y por el sistema monolítico?

e) ¿En qué medida difiere la coherencia longitudinal y la preservación del estado del mundo entre las campañas generadas por ambas arquitecturas?

f) ¿En qué medida difiere la calidad narrativa emergente entre las campañas generadas por el sistema multiagente y por el sistema monolítico?

El problema central del estudio consiste en que no se sabe si la distribución de las decisiones narrativas entre agentes especializados mejora la coherencia de campañas extensas de Dungeons & Dragons respecto de un sistema monolítico que opera con el mismo modelo de lenguaje y la misma información sobre el estado del mundo, dado que la literatura atribuye esa ventaja a la arquitectura multiagente (Xia et al., 2025) sin haberla contrastado de forma controlada en este dominio, mientras que la evidencia general sobre estos sistemas advierte que la coordinación entre agentes introduce, a su vez, modos de fallo propios (Cemri et al., 2025). Este problema se origina en tres causas que se refuerzan entre sí, puesto que la memoria efectiva del modelo es limitada y desigual a lo largo del contexto, el estado del mundo no suele registrarse de forma verificable fuera del texto generado y, en la arquitectura monolítica, una misma llamada debe narrar, arbitrar las reglas, interpretar a los personajes no jugadores y actualizar el mundo de manera simultánea, lo que concentra en un solo punto todas las oportunidades de error.

En consecuencia, sus efectos se manifiestan como contradicciones sobre la identidad y la disposición de los personajes no jugadores, como eventos que el sistema olvida o revierte sin justificación (De Lima et al., 2023) y como decisiones que el sistema toma en nombre del jugador (Zhu et al., 2023), efectos que socavan la credibilidad del mundo narrativo y que, sin embargo, no pueden cuantificarse con precisión mientras no se disponga de instrumentos de medición cuya capacidad de discriminación haya sido verificada (Valdivia & Burelli, 2025). Por ello, el problema central presenta una doble naturaleza, empírica y metodológica, ya que responder si una arquitectura produce campañas más coherentes que la otra exige, antes, construir una forma reproducible y verificable de medir dicha coherencia.

1.2. Objetivos

1.2.1. Objetivo general

Comparar la coherencia narrativa de las campañas de Dungeons & Dragons generadas por una arquitectura de sistema multiagente frente a una arquitectura monolítica.

1.2.2. Objetivos específicos

1.2.2.1. Evaluar la coherencia reactiva de las respuestas inmediatas generadas por el sistema monolítico.
1.2.2.2. Evaluar la coherencia longitudinal a lo largo de las campañas generadas por el sistema monolítico.
1.2.2.3. Evaluar la calidad narrativa emergente en las campañas generadas por el sistema monolítico.
1.2.2.4. Comparar la coherencia reactiva de las respuestas inmediatas generadas por ambos tipos de arquitectura.
1.2.2.5. Comparar la coherencia longitudinal a lo largo de las campañas generadas por ambos sistemas.
1.2.2.6. Comparar la calidad narrativa emergente producida por la arquitectura multiagente frente a la monolítica.

1.3. Justificación del estudio

Desde el punto de vista teórico, la investigación se justifica porque permite separar dos factores que la literatura tiende a presentar de manera conjunta, a saber, la memoria estructurada y la especialización de agentes, dado que las ventajas atribuidas a los sistemas multiagente (Xia et al., 2025) suelen evaluarse frente a sistemas que, además de tener una arquitectura distinta, carecen de un registro explícito del estado, mientras que Farrell y Ware (2025) muestran que la conservación de un dominio simbólico explícito contribuye por sí misma a la coherencia de historias con múltiples agentes. Por esta razón, al dotar a ambas arquitecturas de la misma base de datos del estado del mundo, el diseño aísla el efecto de la descomposición de las decisiones narrativas y aporta evidencia sobre si dicha descomposición añade coherencia una vez que la memoria deja de ser una variable diferencial, cuestión que las revisiones sobre modelos de lenguaje en juegos todavía plantean como abierta (Gallotta et al., 2024).

Desde el punto de vista práctico, los desarrolladores de sistemas narrativos enfrentan una decisión concreta entre enfoques multiagente y monolíticos

(Valdivia & Burelli, 2025), decisión que tiene consecuencias directas sobre el número de llamadas al modelo, la latencia y el costo de operación, por lo que la evidencia desagregada por dimensión que proporciona este estudio permite orientar la especialización hacia los componentes en los que efectivamente mejora la coherencia, contribuyendo así al diseño de directores de juego virtuales y compañeros narrativos de mayor calidad (Santiago et al., 2023). Además, el empleo de un modelo de pesos abiertos fijado en una sola versión responde a una preocupación práctica señalada por la literatura, puesto que los modelos cerrados pueden producir resultados distintos ante una misma petición a lo largo del tiempo, lo que dificulta tanto la reproducibilidad de los experimentos como la estabilidad de los productos que dependen de ellos (Gallotta et al., 2024).

Desde el punto de vista metodológico, la investigación responde a la falta de consenso sobre cómo evaluar historias generadas automáticamente, ya que el análisis de 72 métricas automáticas frente a criterios humanos puso en evidencia las debilidades de las métricas vigentes (Chhun et al., 2022), mientras que la evaluación mediante paneles humanos resulta costosa, difícil de escalar a corpus extensos y dependiente de la experticia de los evaluadores (González-Romero et al., 2021). Frente a ello, el estudio propone una batería de instrumentos deterministas anclados al estado persistido del mundo, cuya capacidad de discriminación se verifica mediante perturbaciones sintéticas con expectativas definidas de antemano y, en los casos pertinentes, mediante auditorías humanas externas con medición del acuerdo entre evaluadores, de modo que cada instrumento se clasifica como confirmatorio, exploratorio o descriptivo según la evidencia de su sensibilidad; este procedimiento, sumado al registro completo de cada turno en una base de datos y a un mecanismo de tiradas deterministas, permite que cualquier medición se repita sobre el mismo corpus y ofrece a la comunidad un protocolo replicable que favorece un progreso acumulativo en la evaluación de narrativas interactivas.

Desde el punto de vista social, la investigación contribuye a la producción de conocimiento sobre inteligencia artificial narrativa en español, dado que tanto los principales conjuntos de datos del dominio (Callison-Burch et al.,

2022; Zhu et al., 2023) como las herramientas de procesamiento de lenguaje empleadas para medir la coherencia se han desarrollado y validado mayoritariamente en inglés (Martinelli et al., 2024), por lo que el corpus y los instrumentos construidos en este estudio amplían las posibilidades de investigación para la comunidad hispanohablante y fortalecen la capacidad de investigación local en un área emergente. De manera complementaria, la evidencia obtenida acerca el desarrollo de directores de juego virtuales capaces de sostener campañas coherentes, los cuales podrían facilitar el acceso a los juegos de rol a personas que no cuentan con un director humano disponible (Santiago et al., 2023).

1.3.1. Importancia y aportes del estudio

La importancia de esta investigación se sitúa, en primer término, en el debate sobre la arquitectura más adecuada para generar narrativas complejas y de larga duración, debate que acompaña al campo desde los sistemas de generación de historias basados en planificación (Kybartas & Bidarra, 2017) y que la llegada de los LLMs ha reactivado, puesto que la revisión de Gallotta et al. (2024) identifica las interacciones de largo plazo, y en particular la función de director de juego, como un banco de pruebas idóneo para explorar los límites de la memoria de estos modelos. En ese contexto, el estudio traslada la discusión desde la postulación teórica, según la cual los sistemas multiagente gestionarían mejor la complejidad (Xia et al., 2025), hacia una comparación empírica y controlada que, al medir la coherencia de forma separada en cada una de sus dimensiones, permite identificar en cuáles la especialización de agentes aporta una ventaja y en cuáles no lo hace.

Asimismo, la relevancia del estudio trasciende el dominio de los juegos de rol, dado que los mismos problemas de continuidad afectan a cualquier agente conversacional que deba sostener un estado coherente durante interacciones prolongadas, como los asistentes, los tutores o los personajes interactivos, y dado que el entusiasmo por los sistemas multiagente contrasta con la escasa evidencia sobre sus beneficios reales (Cemri et al., 2025), por lo que una comparación que mantiene constantes el modelo, la información de estado y la aleatoriedad aporta un criterio verificable para

decidir cuándo la complejidad adicional de una arquitectura multiagente se justifica (Barambones et al., 2023). En consecuencia, los resultados ofrecen a desarrolladores e investigadores un conocimiento práctico para prevenir la degradación narrativa y las contradicciones lógicas en sistemas conversacionales complejos (De Lima et al., 2023; Valdivia & Burelli, 2025).

En este marco, la investigación aporta, en primer lugar, un protocolo experimental reproducible para comparar arquitecturas de dirección de juego bajo condiciones idénticas de modelo, memoria estructurada y escenario, aplicado a un corpus de 27 pares de campañas de 1,400 turnos; en segundo lugar, una batería de instrumentos deterministas para la coherencia reactiva, la coherencia longitudinal y la calidad narrativa emergente, acompañada de un procedimiento explícito para clasificar cada instrumento como confirmatorio, exploratorio o descriptivo según su sensibilidad demostrada, así como de instrumentos propios para la narración en segunda persona en español; y, en tercer lugar, evidencia empírica sobre las diferencias entre ambas arquitecturas, la cual indica que el sistema multiagente usurpa con menor frecuencia la agencia del jugador, ventaja que se mantiene al corregir por la precisión del detector estimada por un evaluador humano externo, mientras que ninguna de las dos arquitecturas responde mejor a la acción específica del jugador y, en la coherencia longitudinal, ningún instrumento alcanzó carácter confirmatorio. Por consiguiente, los hallazgos no respaldan una superioridad general y uniforme de la arquitectura multiagente, sino ventajas específicas por dimensión, lo que ofrece a desarrolladores e investigadores un criterio más preciso para decidir qué componentes de un sistema narrativo conviene especializar.

Desde el punto de vista práctico, este conocimiento resulta relevante para el diseño de directores de juego virtuales y compañeros narrativos (Santiago et al., 2023) capaces de sostener campañas extensas sin que la historia pierda consistencia, mientras que, desde el punto de vista metodológico, contribuye a la discusión sobre cómo evaluar narrativas generadas por inteligencia artificial sin depender exclusivamente del juicio de evaluadores humanos (Valdivia & Burelli, 2025).

1.4. Limitaciones del estudio

Las limitaciones del estudio se organizan según afecten a la validez interna del experimento, a la validez de constructo de los instrumentos, a la validez externa de los resultados o a su vigencia tecnológica, de modo que cada una se acompaña de las medidas adoptadas para mitigarla y de las restricciones que, pese a ellas, persisten.

En lo que respecta a la validez interna, un desafío fundamental es el sesgo potencial en la implementación de las arquitecturas, dado que un sistema multiagente conlleva mayor complejidad de ingeniería que uno monolítico; no obstante, esta disparidad constituye la naturaleza misma de la variable independiente, por lo que el diseño controla las variables de confusión al emplear en ambos brazos el mismo modelo, la misma base de datos del estado, el mismo extractor y el mismo mecanismo de tiradas deterministas, y al someter el código compartido a una auditoría línea por línea que aseguró la aplicación simétrica de cada corrección. Cabe precisar que, dado que la semilla de cada tirada se deriva del identificador de la campaña y cada brazo tiene el suyo, las secuencias de tiradas de los dos brazos de un par no son idénticas; se verificó, sin embargo, que no favorecen a ninguno, puesto que en 4,824 tiradas comparables de los 27 pares el resultado del dado coincide en el 4.7 % de los casos, lo esperable por azar, y el valor medio del dado no difiere entre arquitecturas (prueba de Wilcoxon, $p = 0.946$). Asimismo, durante la generación del corpus se registraron incidencias que se declaran de forma explícita, puesto que el agente jugador se generó con el modelo NousResearch/Hermes-3-Llama-3.1-70B en los pares 1 a 3 y en los primeros turnos de los pares 4 a 6, y con google/gemma-4-31B-it en el resto, de modo que el jugador y el director de juego comparten modelo en 24 de los 27 pares; las tiradas de característica pura se rechazaban hasta que se incorporaron estadísticas reales por personaje desde el par 3; una campaña del par 5 se interrumpió en el turno 747 y se reanudó tras corregir un error; una campaña del par 2 se truncó a 1,400 turnos para igualar la extensión del corpus; y el motor incorporó el avance determinista de los relojes narrativos a partir del par 18. Si bien estas diferencias afectan por igual a los dos brazos de cada par y, por tanto, no

sesgan la comparación intrapar, sí introducen variabilidad entre pares, razón por la cual los análisis de robustez se reportan también por lote.

En lo que respecta a la validez de constructo, si bien se asumió inicialmente que la coherencia narrativa carecía de una verdad fundamental verificable y que su evaluación dependería por completo de un panel de expertos, el desarrollo del estudio permitió identificar que varios indicadores admiten una verificación determinista al contrastarse con el estado persistido del mundo, como la identidad y el estado de los personajes no jugadores, el cumplimiento de misiones o la activación de eventos. Sin embargo, esta verificación depende de la exactitud del extractor que registra los cambios de estado, cuya precisión y exhaustividad se midieron sobre un banco de calibración y no sobre el corpus final; además, la calidad narrativa emergente conserva un componente de juicio que ningún instrumento determinista validado cubre por completo, dado que las medidas de diversidad léxica y de legibilidad solo alcanzan carácter exploratorio o descriptivo, la reactividad a la agencia del jugador descansa en un único instrumento cuya precisión, estimada por un evaluador humano externo, es de 33 % y que capta solo la forma explícita de la usurpación, y la coherencia longitudinal comparada no cuenta con un instrumento confirmatorio. Estas restricciones se declaran y se discuten en los capítulos IV y V, en tanto que la evaluación del panel piloto, basada en una rúbrica adaptada de la literatura (Pan et al., 2025) y en criterios de confiabilidad entre evaluadores (González-Romero et al., 2021), se conserva solo como antecedente, puesto que se aplicó a tres campañas de una versión anterior del sistema.

Conviene precisar, asimismo, el límite que afecta a los indicadores que dependen de reconocer cuándo una entidad ya introducida vuelve a aparecer en un turno posterior, como la tasa de correferencia de entidades en la coherencia longitudinal y su complemento basado en grafos de entidades en la coherencia reactiva, tarea que en el procesamiento de lenguaje natural se resuelve mediante sistemas de resolución de correferencia; sin embargo, el estado del arte en dicha tarea, ejemplificado por Maverick (Martinelli et al., 2024), se entrena y valida exclusivamente sobre corpus en inglés, sin que exista hasta la fecha un sistema equivalente

validado para el español, por lo que su uso quedaba descartado por incompatibilidad lingüística y no por preferencia de diseño. En consecuencia, el estudio no resuelve cadenas de correferencia pronominal completas, sino que reconoce la reaparición literal del nombre o del lema de cada entidad registrada en el estado persistido, complementada con lematización mediante spaCy (es_core_news_sm) en lugar de coincidencia por subcadena, operacionalización que resulta consistente con la tasa de correferencia de entidades propuesta por Roemmele et al. (2017), la cual tampoco resuelve pronombres, sino que mide la proporción de frases nominales del texto generado que remiten a una entidad presente en el contexto. Esta limitación se acentúa porque la narración del corpus se produce mayoritariamente en segunda persona, convención propia de Dungeons & Dragons y ausente de los corpus en tercera persona sobre los que se validan dichas herramientas, de manera que, en lugar de forzar un instrumento ajeno tanto al idioma como a la convención narrativa del dominio, el estudio desarrolló instrumentos propios para la narración en segunda persona, como el detector de usurpación de la agencia del jugador y los indicadores de arraigo contextual, los cuales se documentan como un aporte metodológico del proyecto y no como una carencia sin resolver.

En lo que respecta a la validez externa, la decisión de abstraer la interacción con jugadores humanos prioriza de manera deliberada la validez interna sobre la validez ecológica, dado que la variabilidad humana impediría presentar estímulos equivalentes a ambas arquitecturas, por lo que se optó por un agente jugador autónomo basado en un LLM y configurado con arquetipos de personaje que incluyen perfiles de comportamiento divergentes y caóticos, lo que asegura la continuidad de la prueba sin introducir la variabilidad no controlada de sujetos externos. Del mismo modo, las campañas se analizan como unidades completas de 1,400 turnos, equivalentes a siete sesiones de juego de 200 turnos, en lugar de fragmentos reducidos que subestimarían la degradación acumulativa (De Lima et al., 2023); no obstante, los resultados corresponden a un único modelo de lenguaje, a un solo idioma, a un sistema de reglas concreto y a una descomposición multiagente específica en cinco roles, de modo que su

generalización a otros modelos, idiomas o diseños multiagente requiere estudios adicionales.

Finalmente, en lo que respecta a la vigencia tecnológica, los modelos de lenguaje evolucionan con rapidez y el modelo empleado podría quedar superado en un plazo breve; sin embargo, la investigación se centra en la gestión del estado y en el razonamiento causal, problemas estructurales que persisten incluso en los modelos de vanguardia (Valdivia & Burelli, 2025), por lo que sus hallazgos se plantean como evidencia sobre las dimensiones de la coherencia en las que la especialización de agentes aporta o no una ventaja, más que como una conclusión ligada a la potencia de un modelo particular.

1.5. Organización del documento

El presente documento se organiza en cinco capítulos, conforme al esquema del Reglamento de Grados y Títulos de la Universidad Privada Antenor Orrego, seguidos de las conclusiones, las recomendaciones, las referencias bibliográficas y los anexos. El Capítulo I, de introducción, describe la realidad problemática, formula el problema, establece los objetivos general y específicos, justifica el estudio y declara sus limitaciones. El Capítulo II, marco de referencia, reúne los antecedentes del estudio, el marco teórico sobre la coherencia narrativa, las limitaciones de los modelos de lenguaje, las arquitecturas de dirección de juego y los fundamentos de su medición computacional, el marco conceptual y el sistema de hipótesis con la operacionalización de las variables y la matriz de consistencia. El Capítulo III detalla la metodología empleada, esto es, el tipo y nivel de investigación, la población y la muestra, el diseño, las técnicas e instrumentos, el procedimiento de ejecución, incluida la reformulación que reemplazó al panel de expertos por instrumentos computacionales, y las técnicas de procesamiento y análisis de datos. El Capítulo IV presenta la propuesta de investigación, es decir, el sistema DM-IA y sus dos arquitecturas, el análisis e interpretación de los resultados por objetivo específico y la docimasia de las hipótesis, mientras que el Capítulo V discute los resultados frente a los antecedentes y documenta, para cada objetivo, la brecha metodológica identificada y el procedimiento seguido para cerrarla.

Por último, los anexos reúnen la ficha de los instrumentos, las evidencias de ejecución y la documentación complementaria del estudio.

II. **MARCO DE REFERENCIA**

2.1. Antecedentes del estudio

Los antecedentes internacionales que sustentan esta investigación se agrupan en tres líneas complementarias, a saber, el uso de modelos de lenguaje como directores de juego en Dungeons & Dragons, las arquitecturas para la generación de narrativas coherentes con múltiples agentes y los métodos para medir la coherencia y la consistencia de las narrativas generadas; para cada antecedente se describen su objetivo, su método, sus principales resultados y su relación con el presente estudio.

Callison-Burch et al. (2022), en su trabajo *Dungeons and Dragons as a Dialog Challenge for Artificial Intelligence*, se propusieron formular D&D como un problema de diálogo para la inteligencia artificial, para lo cual construyeron un corpus a partir de partidas jugadas por mensajes en un foro en línea y definieron tareas de generación de la siguiente intervención y de seguimiento del estado del juego. Sus resultados mostraron que los modelos de lenguaje que disponen de información sobre el estado del juego generan intervenciones de mayor calidad que los que solo acceden al historial del diálogo, hallazgo que se relaciona directamente con este estudio, puesto que justifica que ambas arquitecturas comparadas dispongan del mismo estado persistido del mundo, de modo que la diferencia entre ellas no radique en el acceso a la información, sino en la forma de emplearla.

Zhu et al. (2023), en *FIREBALL: A Dataset of Dungeons and Dragons Actual-Play with Structured Game State Information*, tuvieron como objetivo superar la limitación de los estados de juego construidos de forma heurística, por lo que registraron cerca de 25,000 sesiones reales de D&D jugadas en Discord con el asistente Avrae, capturando el lenguaje, los comandos y el estado subyacente del juego. Demostraron que el uso de dicho estado mejora la generación tanto en métricas automáticas como en el juicio humano y, en el análisis cualitativo realizado por 45 evaluadores, identificaron como fallos recurrentes la usurpación de la agencia del jugador y el razonamiento erróneo sobre los puntos de golpe, fallos que en la presente investigación fundamentan el detector de usurpación de agencia y

los instrumentos que contrastan la narración con el estado real de las entidades.

Zhou et al. (2023), en *I Cast Detect Thoughts: Learning to Converse and Guide with Intents and Theory-of-Mind in Dungeons and Dragons*, plantearon descomponer la función del director de juego en tres componentes explícitos, esto es, la intención de guiar a los jugadores hacia una meta, el enunciado que expresa esa intención y un modelo de teoría de la mente que anticipa la reacción de los jugadores, y entrenaron dicho director mediante aprendizaje por refuerzo. Sus evaluaciones humanas y automáticas mostraron que las intervenciones generadas eran tres veces más propensas a cumplir la intención del director que las de un enfoque de generación convencional, resultado que respalda la idea central de la arquitectura multiagente evaluada en este estudio, según la cual separar las decisiones que componen el rol del director de juego puede mejorar la adecuación de sus respuestas a las acciones del jugador.

Ware et al. (2023), en un artículo publicado en *IEEE Transactions on Games*, formularon la gestión de la experiencia narrativa en entornos con múltiples personajes como un problema de poda de un grafo de historia, en el que los nodos representan estados y las aristas acciones, y en el que se eliminan acciones de los personajes no jugadores hasta dejar a lo sumo una por personaje y estado, sin podar nunca las acciones del jugador. Al aplicar esta técnica a un juego de aventura, los jugadores percibieron una mayor agencia y un comportamiento más creíble de los personajes no jugadores que en la condición de control, lo que aporta a esta investigación un precedente sobre la relación entre la gestión explícita de los personajes, la agencia del jugador y la credibilidad de la narrativa.

Farrell y Ware (2025), también en *IEEE Transactions on Games*, propusieron un enfoque híbrido en el que un algoritmo de planificación en el espacio de estados construye historias coherentes con múltiples agentes a partir de un dominio simbólico escrito a mano, mientras que un modelo de lenguaje actúa como guía para estimar qué eventos conviene explorar primero, y presentaron una evaluación inicial sobre un conjunto de problemas de planificación narrativa de referencia. Este antecedente resulta

pertinente porque sostiene que las fortalezas de los modelos de lenguaje y de las representaciones simbólicas del estado son complementarias, principio que el presente estudio adopta al anclar ambas arquitecturas a un registro estructurado del estado del mundo.

Xia et al. (2025), con StoryWriter, abordaron la generación de historias largas a partir de dos retos, la coherencia del discurso y la complejidad narrativa, para lo cual propusieron un marco multiagente compuesto por un agente de esquema, que genera un guion basado en eventos, un agente de planificación, que distribuye los eventos entre capítulos, y un agente de escritura, que comprime dinámicamente el historial de la historia en función del evento en curso. Según sus evaluaciones humanas y automáticas, el marco superó a los sistemas de referencia tanto en calidad como en extensión de las historias, por lo que constituye el principal antecedente de la hipótesis que esta investigación somete a prueba, aunque su evaluación se realizó sobre narrativas no interactivas y sin contrastar la arquitectura contra un sistema monolítico con la misma información de estado.

Cemri et al. (2025), en *Why Do Multi-Agent LLM Systems Fail?*, analizaron siete marcos multiagente populares sobre más de doscientas tareas con la participación de seis anotadores expertos y construyeron una taxonomía de catorce modos de fallo agrupados en problemas de especificación, desalineación entre agentes y verificación de tareas, taxonomía que alcanzó un coeficiente kappa de Cohen de 0.88. Sus resultados indican que las mejoras de estos sistemas frente a los enfoques de un solo agente suelen ser mínimas, por lo que este antecedente aporta el contrapeso necesario a la hipótesis de superioridad multiagente y justifica que el presente estudio la someta a una comparación controlada en lugar de asumirla.

Papalampidi et al. (2022), en *Towards Coherent and Consistent Use of Entities in Narrative Generation*, analizaron la coherencia y la consistencia de las entidades en historias generadas por modelos de lenguaje, para lo cual propusieron métricas automáticas basadas en la distribución de las menciones de los personajes a lo largo del texto y en la exclusividad de los atributos asociados a cada uno, y aumentaron un modelo preentrenado con una memoria dinámica de entidades. Demostraron que dicha memoria

incrementa la coherencia de las entidades según el juicio automático y humano, especialmente cuando la ventana de contexto es limitada, y que sus métricas se correlacionan con las valoraciones humanas, razón por la cual esta investigación las adopta con una ventaja adicional, dado que cada mención de personaje en el corpus ya se encuentra anclada a una entidad registrada en la base de datos.

Yu et al. (2025), con RPGBench, presentaron el primer banco de pruebas para evaluar modelos de lenguaje como motores de juegos de rol textuales, organizado en una tarea de creación de juegos y otra de simulación de partidas, y combinaron verificaciones objetivas de la mecánica, que comprueban sin intervención humana si los eventos se disparan según sus condiciones y si las variables se actualizan según sus efectos, con valoraciones subjetivas realizadas mediante un modelo de lenguaje como juez. Sus resultados mostraron que los modelos actuales producen historias atractivas, pero tienen dificultades para implementar mecánicas consistentes y verificables, sobre todo en escenarios largos o complejos, hallazgo que respalda el uso, en este estudio, de instrumentos que contrastan la narración con el resultado mecánico ya resuelto.

Valdivia y Burelli (2025), en *Evaluating Quality of Gaming Narratives Co-Created with AI*, abordaron la falta de un marco para evaluar narrativas de juego co-creadas con inteligencia artificial mediante un estudio Delphi con expertos, orientado a identificar y priorizar las dimensiones de calidad de la historia que resultan más determinantes para la experiencia del jugador. Este antecedente fundamenta la afirmación de que la medición de la calidad narrativa constituye un problema abierto y, en consecuencia, justifica que la presente investigación dedique una parte sustancial de su diseño a validar la sensibilidad de sus instrumentos antes de emplearlos para contrastar hipótesis.

En el ámbito nacional y local no se identificaron investigaciones que aborden la comparación de arquitecturas de inteligencia artificial para la generación de narrativas interactivas ni la evaluación de directores de juego automatizados. En síntesis, los antecedentes muestran que disponer de un estado explícito del juego mejora la generación, que descomponer las

decisiones del director de juego es una estrategia prometedora aunque no exenta de fallos de coordinación, y que la medición automática de la coherencia exige instrumentos validados; sin embargo, ninguno de ellos compara de forma controlada una arquitectura multiagente con una monolítica que comparta el mismo modelo y la misma información de estado en campañas interactivas extensas, vacío que la presente investigación busca cubrir.

2.2. Marco teórico

2.2.1. Marco histórico

La historia de los juegos de rol está ligada a la búsqueda de experiencias narrativas cada vez más dinámicas (Van Velsen et al., 2009), búsqueda cuyo origen se remonta a los juegos de guerra de simulación que, desde el *Kriegsspiel* prusiano de principios del siglo XIX, se emplearon para el estudio de la estrategia militar y, posteriormente, con fines recreativos. De esa tradición surgió *Chainmail*, publicado en 1971, que trasladó la simulación a un escenario medieval y fantástico, y a partir del cual Gary Gygax y Dave Arneson crearon Dungeons & Dragons en 1974, sistema que convirtió la narración colaborativa en la mecánica central del juego y que asignó a un director de juego (*Dungeon Master*) la responsabilidad de describir el mundo, interpretar a los personajes no jugadores, arbitrar las reglas y, en consecuencia, mantener la coherencia de la historia y la causalidad de los eventos (Peterson, 2012).

La transición de esta forma de juego a los medios digitales comenzó con las aventuras conversacionales de los años setenta, como *Colossal Cave Adventure* y *Zork*, que ofrecían mundos explorables mediante comandos en lenguaje natural, aunque con narrativas estáticas y limitadas por eventos programados, y que décadas más tarde se convirtieron en bancos de prueba para agentes de inteligencia artificial capaces de comprender y actuar en mundos textuales (Hausknecht et al., 2020), así como en entornos para el aprendizaje situado del lenguaje (Ammanabrolu & Riedl, 2021). Posteriormente, los videojuegos de rol introdujeron narrativas de mayor escala, si bien estas siguieron siendo lineales o de ramificación limitada e incapaces de reaccionar ante acciones no anticipadas por sus diseñadores

(De Lima et al., 2023), razón por la cual la industria recurrió a la generación procedimental de contenido (Amato et al., 2019), la cual resultó eficaz para producir mapas y mazmorras (van der Linden et al., 2014; Viana & Dos Santos, 2019), pero considerablemente más difícil de aplicar a la narrativa, dado que los generadores de historias basados en planificación y en simulación de personajes debían equilibrar la coherencia de la trama con la variedad y la profundidad de los personajes (Kybartas & Bidarra, 2017).

El panorama actual representa un punto de inflexión impulsado por los modelos de lenguaje de gran escala, cuya aparición suele situarse en 2019 con la publicación de GPT-2 y que, a diferencia de los enfoques anteriores, permiten generar texto fluido, adaptarse en tiempo real a las acciones del jugador y sostener conversaciones complejas, tal como lo evidenció AI Dungeon, una de las primeras aventuras textuales dirigidas por un modelo de lenguaje ajustado (Gallotta et al., 2024). Sobre esta base han surgido los agentes basados en LLMs (Qu et al., 2025) y, con ellos, las arquitecturas multiagente para la generación de historias extensas (Xia et al., 2025), de manera que la posibilidad técnica de automatizar el rol del director de juego ha dejado de ser una cuestión especulativa y ha dado paso al problema que motiva esta investigación, esto es, determinar si la calidad de las narrativas generadas, y en particular su coherencia, se sostiene a lo largo de campañas extensas (Valdivia & Burelli, 2025).

2.2.2. Coherencia narrativa

La coherencia de un texto no se reduce a la presencia de vínculos formales entre sus oraciones, fenómeno que se conoce como cohesión (Halliday & Hasan, 1976), sino que depende de que el lector pueda construir una representación unificada en la que los eventos se conectan causalmente entre sí, dado que los hechos que forman parte de la cadena causal de una historia son los que mejor se recuerdan y se juzgan como más importantes (Trabasso & van den Broek, 1985), y de que las entidades de las que trata el discurso se mantengan de manera reconocible de un enunciado a otro (Grosz et al., 1995). En el ámbito de la generación automática, la coherencia narrativa se entiende, por tanto, como el constructo que expresa la integridad lógica y estructural de la

historia generada y la ausencia de contradicciones en ella, de modo que el relato pueda percibirse como una unidad con sentido (Zhu et al., 2023; Zhou et al., 2023).

En una narrativa interactiva, sin embargo, la coherencia no puede evaluarse con independencia de la libertad del jugador, puesto que el sistema debe conciliar una trama con sentido y personajes creíbles con la capacidad del jugador de alterar el curso de la historia (Riedl & Bulitko, 2013). Por esta razón, la presente investigación descompone la coherencia narrativa en tres dimensiones, adaptadas de los marcos de evaluación de la literatura sobre inteligencia artificial aplicada a D&D (Zhu et al., 2023; Zhou et al., 2023; Pan et al., 2025), las cuales corresponden a tres escalas temporales distintas: el turno individual, la campaña completa y la experiencia narrativa que emerge de la interacción.

2.2.3. Coherencia reactiva

La coherencia reactiva evalúa la validez de cada respuesta del director de juego en el nivel del turno, de manera que una respuesta es coherente cuando resulta sensata, es decir, lógica y plausible en su contexto inmediato, y cuando está arraigada, esto es, cuando continúa la acción del jugador y el estado actual del mundo en lugar de ignorarlos o de iniciar un hilo irrelevante (Zhu et al., 2023; Zhou et al., 2023). En un juego con reglas, esta dimensión incluye además la consistencia entre la narración y el resultado mecánico de las acciones, dado que narrar como éxito una tirada fallida o activar un evento sin que se cumplan sus condiciones constituye una incoherencia verificable, tal como lo operacionalizan las métricas mecánicas de RPGBench (Yu et al., 2025).

2.2.4. Coherencia longitudinal

La coherencia longitudinal mide la memoria y la integridad fáctica de la narración a lo largo de la campaña, es decir, la capacidad del sistema para conservar la identidad, los atributos y el estado de los

personajes, así como los eventos y el estado del mundo establecidos previamente (Zhu et al., 2023; Pan et al., 2025). En el diálogo, este problema se ha estudiado como consistencia de la persona, puesto que un agente que afirma primero ser abogado y luego médico incurre en una contradicción que, aun siendo semánticamente plausible, rompe la credibilidad de la conversación (Welleck et al., 2019; Chen et al., 2023), mientras que en la generación de historias se ha estudiado como coherencia de entidades, dado que los modelos tienden a abandonar a los protagonistas y a introducir entidades irrelevantes a medida que el texto se extiende (Papalampidi et al., 2022).

2.2.5. Calidad narrativa emergente

La calidad narrativa emergente evalúa que, además de ser lógicamente correcta, la narración resulte interesante y responda de manera significativa a las decisiones del jugador, de modo que integra dos componentes: el interés y la creatividad del relato, que se manifiestan en la calidad del lenguaje, en el uso de ganchos narrativos y en la ausencia de repetición (Zhu et al., 2023; Pan et al., 2025), y la agencia, entendida como la capacidad del jugador de realizar acciones con sentido y de ver los resultados de sus decisiones (Murray, 1997). Este segundo componente resulta especialmente sensible en los juegos de rol, dado que la usurpación de la agencia, es decir, que el sistema decida, piense, sienta, hable o actúe en nombre del personaje del jugador, fue el fallo que los evaluadores humanos de FIREBALL señalaron con mayor frecuencia (Zhu et al., 2023), en tanto que la gestión narrativa que nunca suprime las acciones del jugador se asocia con una mayor percepción de agencia (Ware et al., 2023). Por el contrario, el interés y la creatividad constituyen la dimensión más difícil de medir de forma automática, puesto que incluso las evaluaciones mediante modelos de lenguaje como jueces muestran en ella la menor concordancia con el juicio humano (Yu et al., 2025), por lo que las medidas de diversidad léxica solo pueden

tratarse como indicadores aproximados de la repetición y no de la calidad del relato (Li et al., 2016).

2.2.6. Continuidad causal, memoria persistente y estado del mundo

Un pilar de la coherencia a largo plazo es la continuidad causal, principio según el cual los eventos no ocurren de forma aislada, sino como resultado de eventos anteriores y como causa de eventos futuros, lo que se materializa mediante una memoria persistente capaz de registrar las acciones significativas y de hacer que tengan consecuencias duraderas en el estado de la simulación (De Lima et al., 2023). La ausencia de esta memoria rompe la inmersión y la sensación de agencia, puesto que hace que las decisiones del jugador parezcan irrelevantes a largo plazo (Martin et al., 2018), y, desde el punto de vista técnico, puede abordarse mediante grafos de conocimiento que se actualizan durante la interacción (Ammanabrolu & Riedl, 2021) o mediante arquitecturas en las que ciertos componentes se especializan en mantener y consultar el estado del mundo.

Conviene distinguir, no obstante, entre recuperar información y conocer el estado, dado que la generación aumentada por recuperación permite que el modelo consulte fragmentos de una base de conocimiento externa seleccionados por su similitud con la consulta (Lewis et al., 2021), y que sus variantes basadas en grafos organizan esa base en entidades y relaciones para responder preguntas de mayor alcance (Edge et al., 2025; Guo et al., 2025), pero ninguna de ellas responde por sí misma a la pregunta de cuándo un hecho era verdadero. En una campaña de rol, cuyo mundo constituye una serie temporal de estados en la que un personaje puede ser hostil en un momento y aliado en otro, un grafo sin dimensión temporal hace coexistir ambas relaciones y las pone a competir en la recuperación, lo que reproduce justamente la incoherencia longitudinal que se pretende evitar; por esta razón, el sistema estudiado registra el estado de las entidades en una base de datos relacional, consultable de forma exacta, y no recurre a la recuperación por similitud durante la generación, de modo que ambas arquitecturas reciben la misma información estructurada del estado y la

última escena narrada. La recuperación por similitud sobre representaciones vectoriales se empleó únicamente después de generado el corpus, como capa de medición de un instrumento exploratorio de la coherencia longitudinal.

2.2.7. Limitaciones de los modelos de lenguaje para sostener la coherencia

Aun cuando los LLMs generan texto fluido y verosímil, tres limitaciones inherentes a su funcionamiento comprometen la coherencia de una campaña extensa: la pérdida de contexto, la alucinación y la complacencia que conduce a usurpar la agencia del jugador. Las tres se describen a continuación, puesto que cada una se corresponde con una de las dimensiones de la coherencia que el estudio mide.

2.2.8. Pérdida de contexto

Los LLMs pueden olvidar detalles o eventos mencionados previamente, lo que genera inconsistencias conforme la interacción se prolonga (De Lima et al., 2023), dado que su memoria efectiva está acotada por la ventana de contexto y la probabilidad de recordar los eventos tempranos disminuye a medida que la conversación avanza (Gallotta et al., 2024). Además, esta pérdida no es uniforme, puesto que el desempeño de los modelos es mayor cuando la información relevante se ubica al inicio o al final del contexto y se degrada de forma significativa cuando se encuentra en su parte intermedia, incluso en modelos diseñados para contextos largos (Liu et al., 2024).

2.2.9. Alucinación

Se denomina alucinación a la generación de contenido que no está respaldado por la fuente o que la contradice, fenómeno que puede ser intrínseco, cuando el texto contradice la información disponible, o extrínseco, cuando añade información que no puede verificarse a partir de ella (Ji et al., 2023). En un juego de rol, ambos tipos rompen la verosimilitud de la historia, ya que el director de juego

puede narrar la muerte de un personaje que conserva puntos de golpe (Zhu et al., 2023) o introducir misiones, lugares y personajes que no existen en el mundo registrado (Gallotta et al., 2024).

2.2.10. Complacencia y usurpación de la agencia

Los LLMs están entrenados para complacer las peticiones de sus usuarios, lo que en el rol de director de juego conduce a acomodar incluso las solicitudes más extravagantes del jugador sin considerar su impacto sobre la trama (Gallotta et al., 2024) y, en sentido inverso, a completar la escena decidiendo lo que el personaje del jugador piensa, siente, dice o hace, conducta que los jugadores perciben como una pérdida del control sobre su personaje (Zhu et al., 2023). Ambas tendencias afectan simultáneamente a la coherencia y a la agencia, razón por la cual la presente investigación las trata como fallos medibles y no como rasgos de estilo.

2.2.11. Arquitecturas de inteligencia artificial para la dirección de juego

La literatura clásica sobre narrativa interactiva distingue entre los enfoques centrados en la trama, en los que un planificador central construye una secuencia causal de eventos que garantiza la coherencia estructural, y los enfoques centrados en los personajes, en los que la historia emerge de las interacciones de agentes autónomos que persiguen sus propias metas (Riedl & Bulitko, 2013); los primeros se ilustran en los sistemas de generación basados en planificación (George, 2015; Laclaustra et al., 2014) y los segundos en la concepción de los juegos de rol como sociedades artificiales (Casas-Roma et al., 2019). Sin embargo, en los sistemas basados en LLMs la distinción relevante ya no es de dónde procede la trama, sino cuántos componentes intervienen en la construcción de cada turno y cómo se reparten las decisiones entre ellos, de modo que esta investigación emplea los términos monolítico y multiagente en ese sentido arquitectónico.

2.2.12. Arquitectura monolítica

En la arquitectura monolítica, un único modelo de lenguaje resuelve cada turno mediante una sola generación en la que debe, al mismo tiempo, interpretar la acción del jugador, aplicar las reglas, dar voz a los personajes no jugadores, decidir los cambios del mundo y redactar la narración, apoyándose para ello en el contexto que recibe y, opcionalmente, en mecanismos de recuperación de información (Lewis et al., 2021). Su principal ventaja reside en la simplicidad, dado que requiere menos llamadas al modelo y no introduce problemas de coordinación, mientras que su principal riesgo consiste en concentrar en una sola generación todas las decisiones del turno, por lo que cualquier fallo de atención sobre el contexto repercute simultáneamente en la narración, la mecánica y la continuidad de los personajes.

2.2.13. Arquitectura multiagente

En la arquitectura multiagente, el trabajo se distribuye entre varios agentes especializados, cada uno con un rol, un contexto y una responsabilidad acotados, cuya coordinación produce la respuesta final (Barambones et al., 2023), tal como ocurre en StoryWriter, que separa la elaboración del esquema, la planificación y la escritura (Xia et al., 2025), o en los agentes generativos que simulan comportamientos sociales creíbles mediante memoria, reflexión y planificación (Park et al., 2023). En la dirección de juego, esta descomposición permite, por ejemplo, que el agente que interpreta a un personaje no jugador reciba únicamente lo que ese personaje sabe, que el resultado mecánico se resuelva antes de narrarse y que un solo agente redacte la prosa final para evitar que la narración se perciba como un conjunto de fragmentos yuxtapuestos; no obstante, la coordinación entre agentes introduce modos de fallo propios, como la desalineación entre ellos, la pérdida del historial de la conversación o la verificación incompleta de los resultados (Cemri et al., 2025), de manera que sus

beneficios deben demostrarse empíricamente y no pueden darse por supuestos.

2.2.14. Agente jugador autónomo

Entre las funciones que un LLM puede asumir en un juego se encuentra la de jugador, en la que el modelo reemplaza a un participante humano imitando sus objetivos (Gallotta et al., 2024), función que en la evaluación de sistemas conversacionales se vincula con la tradición de la simulación de usuarios, cuyo propósito es someter a los sistemas a interacciones reproducibles sin depender de la disponibilidad ni de la variabilidad de sujetos humanos (Schatzmann et al., 2006). Para que dicho agente produzca comportamientos diversos y no converja hacia una misma postura, puede recurrirse a la incitación analógica, en la que el propio modelo genera ejemplos adaptados a cada caso en lugar de recibir ejemplos fijos (Yasunaga et al., 2024), mientras que la resolución de las tiradas por parte del sistema, y no del agente, evita que el modelo favorezca resultados narrativamente convenientes.

2.2.15. Fundamentos de la medición computacional de la coherencia

La medición automática de la calidad narrativa carece de consenso, dado que un análisis de 72 métricas automáticas frente a criterios humanos puso de manifiesto las debilidades de las métricas vigentes para evaluar historias generadas (Chhun et al., 2022); en consecuencia, los instrumentos empleados en esta investigación no se fundamentan en métricas genéricas de similitud textual, sino en familias de técnicas que la literatura ha vinculado con aspectos específicos de la coherencia y que, en este estudio, se contrastan con el estado persistido del mundo, lo que permite verificar la narración contra hechos registrados y no contra inferencias sobre el propio texto.

2.2.16. Coherencia local basada en entidades

El modelo de rejilla de entidades propone representar un texto mediante la distribución de sus entidades a lo largo de las oraciones y medir la coherencia local a partir de las transiciones de esas entidades entre oraciones adyacentes (Barzilay & Lapata, 2008), idea que se inspira en la teoría del centrado del discurso (Grosz et al., 1995) y que Guinaudeau y Strube (2013) reformularon como un grafo de entidades compartidas cuya densidad refleja la coherencia sin requerir entrenamiento supervisado. En la misma línea, la tasa de correferencia de entidades mide la proporción de frases nominales del texto generado que remiten a entidades ya presentes en el contexto (Roemmele et al., 2017), mientras que las métricas de coherencia y consistencia de entidades evalúan, a escala de todo el relato, si los protagonistas se mantienen presentes y si cada entidad conserva un perfil de atributos propio (Papalampidi et al., 2022).

2.2.17. Seguimiento del estado del mundo

En los mundos textuales, el conocimiento que un agente tiene del entorno puede verificarse formulando preguntas automáticas sobre su estado, como la ubicación del personaje o los objetos cercanos, y comparando las respuestas con el estado real mediante coincidencia exacta y F1 (Ammanabrolu et al., 2020), principio que, trasladado a una campaña de rol, permite comprobar si la narración recuerda los cambios de estado efectivamente registrados. De forma complementaria, la consistencia fáctica de un personaje puede evaluarse como un problema de inferencia en lenguaje natural, en el que se determina si un enunciado contradice lo establecido previamente (Welleck et al., 2019), si bien, cuando el estado del personaje se encuentra registrado de forma estructurada, la contradicción puede verificarse directamente contra ese registro, como ocurre al detectar que un personaje muerto o desaparecido vuelve a actuar en la narración.

2.2.18. Diversidad léxica y legibilidad

La repetición y la monotonía del lenguaje se aproximan habitualmente mediante medidas de diversidad léxica, como la proporción de unigramas y bigramas distintos (Li et al., 2016); sin embargo, la razón entre tipos y ocurrencias depende de la longitud del texto, por lo que se han propuesto medidas menos sensibles a ella, como MTLD (McCarthy & Jarvis, 2010) y MATTR, que promedia dicha razón en ventanas móviles de tamaño fijo (Covington & McFall, 2010). Del mismo modo, la legibilidad de los textos en español puede estimarse mediante fórmulas basadas en el número de sílabas por palabra y de palabras por oración, como las de Fernández Huerta (1959) y Szigriszt-Pazos (1993), aunque ninguna de estas medidas captura por sí sola el interés o la creatividad del relato, razón por la cual se emplean únicamente como evidencia exploratoria o descriptiva.

2.2.19. Validación de los instrumentos de medición

Un instrumento de medición debe ser confiable, es decir, producir resultados consistentes, y válido, es decir, medir efectivamente el constructo que pretende medir; en el caso de los instrumentos aplicados por evaluadores humanos, la confiabilidad se estima mediante coeficientes de acuerdo corregidos por azar, como el kappa de Cohen para dos evaluadores (Cohen, 1960) y el kappa de Fleiss para tres o más (Fleiss, 1971), mientras que en los instrumentos deterministas la confiabilidad está garantizada por construcción y el problema central pasa a ser su validez. Por esta razón, una estrategia pertinente consiste en someter cada instrumento a perturbaciones sintéticas cuyo efecto esperado se conoce de antemano, como insertar contradicciones o alterar el orden de los turnos, y verificar que el instrumento reacciona en la dirección prevista y permanece estable ante las perturbaciones que no deberían afectarlo; esta verificación resulta necesaria, además, para evitar que un indicador se convierta en un objetivo en sí mismo

y deje de reflejar el constructo, riesgo que se conoce como ley de Goodhart (Manheim & Garrabrant, 2019).

2.3. Marco conceptual

Agente jugador autónomo: agente basado en un LLM que desempeña el papel del jugador durante la generación del corpus, configurado con un personaje, un arquetipo y una propensión a desviarse de los ganchos narrativos, cuyas tiradas resuelve el sistema y no el propio agente.

Arquitectura monolítica (G2): arquitectura de dirección de juego en la que un único modelo de lenguaje resuelve cada turno mediante una sola generación que integra narración, arbitraje, interpretación de personajes no jugadores y actualización del mundo.

Arquitectura multiagente (G1): arquitectura de dirección de juego en la que cada turno se distribuye entre roles especializados, en este estudio un enrutador determinista, un árbitro, un actor de personajes no jugadores, un agente del mundo y un narrador, que es el único que redacta la prosa final.

Campaña y par de campañas: una campaña es la secuencia completa de 1,400 turnos generada por una arquitectura a partir de un escenario inicial, mientras que un par está conformado por dos campañas, una por arquitectura, generadas con el mismo escenario, el mismo personaje jugador y el mismo mecanismo de tiradas deterministas.

Delta de estado: registro de un cambio en el estado de una entidad del mundo, como la disposición de un personaje no jugador o su condición de vivo o muerto, acompañado del fragmento literal de la narración que lo justifica.

Director de juego (Dungeon Master o Game Master): participante que asume el rol de narrador, árbitro de las reglas y director de la historia en D&D, describe el mundo, presenta desafíos e interpreta a todos los personajes no controlados por los jugadores, por lo que es responsable de mantener la coherencia de la narración y la causalidad de los eventos.

Estado persistido del mundo: conjunto de datos estructurados, almacenados en una base de datos relacional, que describe en cada turno a

los personajes, lugares, facciones, objetos, misiones y relojes narrativos de la campaña, y que sirve como referencia para verificar la narración.

Extractor: componente que analiza cada turno narrado e identifica los cambios de estado que implica, los cuales solo se registran si pertenecen a una lista cerrada de tipos permitidos y si están respaldados por evidencia literal del texto.

Generación aumentada por recuperación (RAG): técnica que permite a un LLM consultar, durante la generación, fragmentos de una base de conocimiento externa seleccionados por su similitud con la consulta, con el fin de producir respuestas fundamentadas en información que no forma parte de su entrenamiento.

Instrumento confirmatorio, exploratorio o descriptivo: clasificación asignada a cada instrumento según la evidencia de su sensibilidad: el confirmatorio superó la prueba de perturbaciones y puede sostener la decisión sobre una hipótesis, el exploratorio muestra una sensibilidad parcial y solo orienta la interpretación, y el descriptivo se reporta sin fines inferenciales.

Instrumento determinista: procedimiento de medición que, aplicado sobre el mismo texto y el mismo estado, produce siempre el mismo resultado, dado que no depende del juicio de evaluadores ni de modelos estocásticos.

Modelo de lenguaje de gran escala (LLM): modelo neuronal, basado habitualmente en la arquitectura *transformer*, entrenado sobre grandes corpus de texto para generar lenguaje a partir de una entrada textual y capaz de realizar tareas diversas sin reentrenamiento específico.

Personaje jugador (PJ) y personaje no jugador (PNJ): el personaje jugador es el controlado por el jugador, en este estudio por el agente jugador autónomo, mientras que los personajes no jugadores son todos aquellos que el director de juego interpreta.

Prueba de sensibilidad: procedimiento de validación en el que se aplican al corpus perturbaciones sintéticas con un efecto esperado definido de antemano, con el fin de verificar que cada instrumento reacciona en la

dirección prevista y permanece estable ante las perturbaciones que no deberían afectarlo.

Representación vectorial de oraciones: codificación de una oración como un vector numérico de dimensión fija, obtenida mediante un modelo de lenguaje entrenado para que oraciones de significado similar produzcan vectores cercanos, lo que permite comparar textos por su similitud semántica y no solo por las palabras que comparten.

Sistema multiagente (MAS): sistema compuesto por varios agentes autónomos que interactúan entre sí y con su entorno para resolver una tarea, en el que cada agente posee un rol y una información acotados.

Usurpación de la agencia: fallo en el que el director de juego decide, piensa, siente, habla o actúa en nombre del personaje del jugador, sustituyendo una elección que corresponde a este.

2.4. Sistema de hipótesis

2.4.1. Supuestos básicos

La investigación parte del supuesto epistemológico de que la coherencia narrativa, pese a su naturaleza cualitativa, es un constructo susceptible de descomponerse en dimensiones y de medirse de forma sistemática, y de que una parte sustancial de dicha medición puede realizarse de manera determinista al contrastar la narración con el estado persistido del mundo de juego. Este supuesto descansa, a su vez, en la validez de dicho estado como referencia, la cual se sostiene en que el extractor solo registra cambios pertenecientes a una lista cerrada de tipos permitidos y respaldados por evidencia literal del texto, restricción que impide incorporar al estado hechos inventados, aunque no garantiza que todos los cambios narrados queden registrados, razón por la cual la exactitud del extractor se declara como limitación del estudio.

Se asume, asimismo, que un agente jugador autónomo basado en un LLM constituye un sustituto válido y controlado de la agencia de un jugador real, siempre que su comportamiento no converja hacia una única postura; por ello, cada personaje jugador se configura con un arquetipo descriptivo, una agenda coherente con sus rasgos de personalidad, una propensión definida

a desviarse de los ganchos narrativos y ejemplos de conducta generados específicamente para él (Yasunaga et al., 2024), mientras que las tiradas de dados las resuelve el sistema con una semilla determinada por la campaña, el turno y la habilidad, de modo que el agente no puede favorecer resultados narrativamente convenientes; dado que el identificador de la campaña forma parte de la semilla, las secuencias de los dos brazos de un par no son idénticas, aunque se verificó que no favorecen a ninguno de ellos. Cabe precisar que este diseño garantiza la equivalencia de las condiciones iniciales y de la política del jugador, pero no la identidad de las acciones a lo largo de la campaña, dado que el agente responde a narraciones distintas en cada brazo; esta divergencia no se considera una fuente de sesgo, sino parte del efecto que se pretende medir, puesto que la coherencia de un director de juego solo puede observarse en interacción con el jugador.

Se asume, además, que al mantener constantes dentro de cada par el modelo de lenguaje, fijado en una única versión, la base de datos del estado del mundo, el extractor, el escenario inicial, el personaje jugador y la extensión de la campaña, las diferencias observadas entre ambos brazos son atribuibles a la variable independiente, esto es, a la organización de las decisiones narrativas en una o en varias instancias especializadas, y no a asimetrías en los componentes subyacentes. Del mismo modo, se asume que los 27 pares son independientes entre sí, dado que cada uno emplea una ambientación, un tono, una estructura de conflicto y un personaje jugador distintos, y que las diferencias intrapar se distribuyen de forma aproximadamente simétrica alrededor de su mediana, condición que requiere la prueba de rangos con signo de Wilcoxon (Wilcoxon, 1945).

Por último, se asume que los instrumentos que superan la prueba de sensibilidad por perturbaciones sintéticas reflejan el constructo que declaran medir, por lo que solo ellos sostienen las decisiones sobre las hipótesis, mientras que los demás orientan la interpretación sin decidirla, y que la división de cada campaña en siete bloques consecutivos de 200 turnos, equivalentes a una sesión de juego cada uno, constituye una unidad temporal adecuada para observar la evolución de la coherencia a lo largo de la campaña. En consecuencia, los hallazgos se entienden como evidencia

sobre la organización arquitectónica de las decisiones narrativas y no sobre la potencia de un modelo particular, si bien su generalización a otros modelos requiere verificación adicional.

2.4.2. Hipótesis general

H1 (hipótesis alternativa): Los sistemas multiagente producen campañas de Dungeons & Dragons con mayor coherencia narrativa que los sistemas monolíticos.

H0 (hipótesis nula): Los sistemas multiagente producen campañas de Dungeons & Dragons con una coherencia narrativa igual o inferior a la de los sistemas monolíticos.

Dado que la coherencia narrativa se operacionaliza en tres dimensiones, la hipótesis general se contrasta a través de las hipótesis específicas comparativas H1d, H1e y H1f, de modo que se considera sostenida únicamente si las tres se sostienen, mientras que en cualquier otro caso se declara no sostenida en su forma general y la decisión se reporta desagregada por dimensión, criterio conservador que evita aceptar una superioridad global a partir de ventajas parciales.

2.4.3. Hipótesis específicas

Las hipótesis específicas se organizan en dos grupos que corresponden a los dos niveles de análisis del estudio. Las tres primeras, asociadas a los objetivos de evaluación del sistema monolítico, contrastan la premisa que motiva la investigación, según la cual la coherencia de un director de juego basado en un único modelo se degrada conforme la campaña se extiende (Liu et al., 2024; Gallotta et al., 2024), en tanto que las tres últimas, asociadas a los objetivos de comparación, contrastan la ventaja que la literatura atribuye a la arquitectura multiagente en cada dimensión:

H1a: La coherencia reactiva de las respuestas generadas por el sistema monolítico disminuye conforme avanza la campaña.

H0a: La coherencia reactiva de las respuestas generadas por el sistema monolítico no disminuye conforme avanza la campaña.

H1b: La coherencia longitudinal del sistema monolítico disminuye conforme avanza la campaña.

H0b: La coherencia longitudinal del sistema monolítico no disminuye conforme avanza la campaña.

H1c: La calidad narrativa emergente de las campañas generadas por el sistema monolítico disminuye conforme avanza la campaña.

H0c: La calidad narrativa emergente de las campañas generadas por el sistema monolítico no disminuye conforme avanza la campaña.

H1d: Los sistemas multiagente generan respuestas con mayor coherencia reactiva que los sistemas monolíticos.

H0d: Los sistemas multiagente generan respuestas con una coherencia reactiva igual o inferior a la de los sistemas monolíticos.

H1e: Los sistemas multiagente mantienen una mayor coherencia longitudinal a lo largo de la campaña que los sistemas monolíticos.

H0e: Los sistemas multiagente mantienen una coherencia longitudinal igual o inferior a la de los sistemas monolíticos a lo largo de la campaña.

H1f: Los sistemas multiagente producen una calidad narrativa emergente superior a la de los sistemas monolíticos.

H0f: Los sistemas multiagente producen una calidad narrativa emergente igual o inferior a la de los sistemas monolíticos.

La docimasia de cada hipótesis se realiza según el procedimiento que se describe a continuación, el cual se desarrolla en el Capítulo III. Para H1a, H1b y H1c, cada una de las 27 campañas del sistema monolítico se divide en siete bloques consecutivos de 200 turnos y en cada bloque se calcula el valor de los instrumentos de la dimensión correspondiente, de manera que la hipótesis de degradación se contrasta mediante la prueba de tendencia de Page para alternativas ordenadas en diseños de medidas repetidas (Page, 1963), unilateral en el sentido de la degradación, y se complementa con la prueba de rangos con signo de Wilcoxon entre el primer y el último bloque; en los instrumentos que cuentan eventos, la tasa de cada bloque se relativiza respecto del número de entidades expuestas al fallo en ese

bloque, dado que el número de personajes que pueden, por ejemplo, reaparecer tras su muerte crece a lo largo de la campaña. Para H1d, H1e y H1f, la diferencia entre ambas arquitecturas se contrasta dentro de cada uno de los 27 pares mediante la prueba de rangos con signo de Wilcoxon, unilateral en el sentido de la hipótesis alternativa, reportando además el valor bilateral, el estimador de Hodges-Lehmann con su intervalo de confianza y el tamaño del efecto.

En todos los casos, el nivel de significancia es $\alpha = 0.05$, la decisión sobre cada hipótesis se sustenta exclusivamente en los instrumentos clasificados como confirmatorios para su dimensión, con corrección de Holm cuando la familia confirmatoria incluye más de un instrumento (Holm, 1979), y, cuando una dimensión no cuenta con ningún instrumento confirmatorio, la hipótesis se declara sin decisión confirmatoria y la evidencia exploratoria se reporta únicamente como orientación. Si un instrumento confirmatorio resultara significativo en el sentido contrario al de la hipótesis alternativa, no se rechaza la hipótesis nula y dicho resultado se reporta de forma explícita como evidencia en la dirección opuesta.

2.4.4. Variables e indicadores

La variable independiente es el tipo de arquitectura del sistema de inteligencia artificial, variable nominal con dos niveles, la arquitectura multiagente (G1) y la arquitectura monolítica (G2), mientras que la variable dependiente es la coherencia narrativa, operacionalizada en tres dimensiones y seis indicadores medidos mediante instrumentos deterministas, de manera que cada indicador puede contar con varios instrumentos que lo abordan desde ángulos complementarios. Asimismo, con el fin de aislar el efecto de la variable independiente, se controlan dentro de cada par el modelo de lenguaje, la base de datos del estado del mundo, el extractor, el mecanismo de tiradas deterministas, el escenario inicial, el personaje jugador y la extensión de la campaña, en tanto que la ambientación, el tono y la estructura del conflicto varían deliberadamente entre pares para evitar que los resultados dependan de un único escenario. La Tabla 1 detalla la operacionalización de ambas variables y la clasificación de cada instrumento según la prueba de sensibilidad.

Tabla 1. Operacionalización de variables.

Variable	Definición conceptual	Definición operacional	Dimensión	Indicadores	Escala	Instrumentos
VD: Coherencia narrativa	Constructo que expresa la integridad lógica y estructural de la historia generada y la ausencia de contradicciones en ella, de modo que el relato pueda percibirse como una unidad con sentido (Zhu et al., 2023; Zhou et al., 2023).	Valores por campaña y por bloque de 200 turnos obtenidos mediante instrumentos deterministas que contrastan la narración con el estado persistido del mundo, clasificados por su sensibilidad en confirmatorios (C), confirmatorios	Coherencia reactiva	CR-1: Fluidez y corrección de la respuesta inmediata	Razón	Gramaticalidad (LanguageTool) (D); pifia narrada como éxito (D); caracteres de otro alfabeto (D)
				CR-2: Arraigo contextual a la acción del jugador	Intervalo y razón	Respuesta a la acción específica en z (C); solapamiento con la acción, anclaje al escenario, anclaje sin nombres propios y nombres no reconocidos (E)

		condicionados (CC), exploratorios (E) o descriptivos (D).	Coherencia longitudinal	CL-1: Consistencia de personajes	Razón	Coherencia de entidad C y consistencia de atributos V (E); tasa de correferencia de entidades (D)
				CL-2: Consistencia de eventos y estado del mundo	Razón	Recall de cambios de estado Jericho-QA, PNJ inactivo mencionado y como sujeto, turno de primera mención de PNJ no vivo (E); ciclos de ubicación (D)
			Calidad narrativa emergente	QN-1: Interés y creatividad, aproximados mediante diversidad léxica	Razón	MTLD, MATTR, TTR y bigramas a 100 palabras (E); legibilidad Fernández Huerta y Szigriszt-Pazos (D)
				QN-2: Reactividad a la agencia del jugador	Razón	Usurpación de la agencia del PJ, total y por decisión, pensamiento, emoción y habla (CC)
VI: Tipo de arquitectura del sistema de IA	Paradigma bajo el cual se organizan las decisiones que el sistema toma para generar cada turno de la campaña, que difiere en el número de instancias que intervienen y en la distribución de las responsabilidades narrativas entre ellas.	Implementación de dos sistemas que comparten el modelo google/gemma-4-31B-it, la base de datos del estado, el extractor y el mecanismo de tiradas deterministas, y que difieren en la organización de las decisiones del turno.	Organización de las decisiones narrativas	G1: turno distribuido entre cinco roles especializados; G2: turno resuelto en una sola generación	Nominal dicotómica	Código versionado de ambas arquitecturas y registro de llamadas al modelo por rol

2.4.5. Matriz de consistencia

La Tabla 2 sintetiza la correspondencia entre los problemas, los objetivos y las hipótesis de la investigación, así como las variables, los indicadores, los instrumentos y la metodología con que se aborda cada uno de ellos.

Tabla 2. Matriz de consistencia de la investigación.

Problema general	Objetivo general	Hipótesis general	Variables	Indicadores	Instrumentos	Metodología
¿Es superior la coherencia narrativa de campañas de Dungeons & Dragons generadas por sistemas multiagente en comparación con sistemas monolíticos de inteligencia artificial?	Comparar la coherencia narrativa de las campañas de Dungeons & Dragons generadas por una arquitectura de sistema multiagente frente a una arquitectura monolítica.	Los sistemas multiagente producen campañas de Dungeons & Dragons con mayor coherencia narrativa que los sistemas monolíticos.	VI: Tipo de arquitectura del sistema de IA (G1 multiagente, G2 monolítica). VD: Coherencia narrativa.	Seis indicadores en tres dimensiones: CR-1, CR-2, CL-1, CL-2, QN-1 y QN-2	Batería de instrumentos deterministas (Anexo 1)	Enfoque: cuantitativo. Tipo: aplicada. Nivel: explicativo. Diseño: experimental de medidas repetidas con pares emparejados. Población: campañas que ambas arquitecturas pueden generar bajo las condiciones del estudio. Muestra: 27 pares (54 campañas, 75,600 turnos).
Problemas específicos	**Objetivos específicos**	**Hipótesis específicas**				
¿Cuál es el nivel de coherencia reactiva que alcanza el sistema monolítico ante las acciones inmediatas del jugador?	Evaluar la coherencia reactiva de las respuestas inmediatas generadas por el sistema monolítico.	La coherencia reactiva de las respuestas generadas por el sistema monolítico disminuye conforme avanza la campaña.		CR-1, CR-2	Respuesta a la acción específica en z (C)	
¿Cuál es el nivel de	Evaluar la coherencia	La coherencia		CL-1, CL-2	Instrumentos	

coherencia longitudinal y de preservación del estado del mundo que alcanza el sistema monolítico a lo largo de la campaña?	longitudinal a lo largo de las campañas generadas por el sistema monolítico.	longitudinal del sistema monolítico disminuye conforme avanza la campaña.			de consistencia de personajes y de estado del mundo (E)	Análisis: prueba de tendencia de Page (H1a–H1c) y prueba de rangos con signo de Wilcoxon pareada (H1d–H1f), α = 0.05.
¿Cuál es el nivel de calidad narrativa emergente, en términos de creatividad y de respuesta a la agencia del jugador, que alcanza el sistema monolítico?	Evaluar la calidad narrativa emergente en las campañas generadas por el sistema monolítico.	La calidad narrativa emergente de las campañas generadas por el sistema monolítico disminuye conforme avanza la campaña.		QN-1, QN-2	Usurpación de la agencia del PJ (CC); diversidad léxica (E)	
¿En qué medida difiere la coherencia reactiva de las respuestas generadas por el sistema multiagente y por el sistema monolítico?	Comparar la coherencia reactiva de las respuestas inmediatas generadas por ambos tipos de arquitectura.	Los sistemas multiagente generan respuestas con mayor coherencia reactiva que los sistemas monolíticos.		CR-1, CR-2	Respuesta a la acción específica en z (C)	
¿En qué medida difiere la coherencia longitudinal y la preservación del estado del mundo entre las campañas	Comparar la coherencia longitudinal a lo largo de las campañas generadas por ambos sistemas.	Los sistemas multiagente mantienen una mayor coherencia longitudinal a lo largo de la		CL-1, CL-2	Instrumentos de consistencia de personajes y de estado del mundo (E)	

generadas por ambas arquitecturas?		campaña que los sistemas monolíticos.				
¿En qué medida difiere la calidad narrativa emergente entre las campañas generadas por el sistema multiagente y por el sistema monolítico?	Comparar la calidad narrativa emergente producida por la arquitectura multiagente frente a la monolítica.	Los sistemas multiagente producen una calidad narrativa emergente superior a la de los sistemas monolíticos.		QN-1, QN-2	Usurpación de la agencia del PJ (CC); diversidad léxica (E)	

III. METODOLOGÍA EMPLEADA

3.1. Tipo y nivel de investigación

De acuerdo con su finalidad, la investigación es de tipo aplicada, puesto que busca resolver un problema práctico del campo de la inteligencia artificial aplicada al entretenimiento digital, esto es, determinar qué organización arquitectónica conviene adoptar para que un director de juego automatizado sostenga la coherencia de campañas extensas, y adopta un enfoque cuantitativo, dado que la variable dependiente se expresa mediante valores numéricos obtenidos con instrumentos deterministas y las hipótesis se contrastan mediante pruebas estadísticas. En cuanto a su nivel, la investigación es explicativa, ya que no se limita a describir la coherencia de las campañas, sino que busca establecer si la arquitectura del sistema produce diferencias en ella, lo que corresponde al carácter explicativo que Arias (2012) atribuye a la investigación experimental, y, en cuanto a su diseño, es experimental, puesto que los investigadores manipulan deliberadamente la variable independiente, el tipo de arquitectura, en dos niveles y observan su efecto sobre la variable dependiente bajo condiciones controladas.

3.1.1. Nivel de madurez tecnológica

La investigación se sitúa en el nivel 4 de madurez tecnológica (TRL 4), que corresponde a la validación de componentes o de sistemas en un entorno de laboratorio (Mankins, 1995), dado que ambas arquitecturas se implementan como prototipos funcionales completos y se evalúan de forma controlada mediante un agente jugador simulado, sin exponerse todavía a jugadores reales ni a condiciones de operación comercial. Si bien los modelos de lenguaje que las componen han sido validados individualmente en numerosos contextos, su integración en dos arquitecturas de dirección de juego comparables y la evaluación sistemática de la coherencia que producen en campañas de 1,400 turnos constituyen una validación experimental que no se ha reportado de manera controlada en la literatura revisada.

En consecuencia, la investigación no persigue desarrollar un producto listo para su explotación comercial, sino producir evidencia empírica sobre las

diferencias entre ambas arquitecturas en cada dimensión de la coherencia narrativa, de modo que sus resultados sirvan de base para decidir qué componentes conviene especializar en desarrollos posteriores de mayor madurez tecnológica, los cuales requerirían validar el sistema con jugadores humanos en un entorno de uso real.

3.1.2. Método de investigación

La investigación adopta el método hipotético-deductivo con enfoque cuantitativo, puesto que parte de hipótesis derivadas de la literatura sobre la degradación de la coherencia en los modelos de lenguaje y sobre las ventajas atribuidas a la especialización de agentes, deduce de ellas consecuencias observables en términos de los indicadores de la coherencia narrativa y las contrasta con los datos obtenidos del corpus experimental. Para ello, la coherencia narrativa se operacionaliza mediante los seis indicadores de la Rúbrica D&D-IA, adaptada de los marcos de evaluación de la literatura sobre inteligencia artificial aplicada a D&D (Zhu et al., 2023; Zhou et al., 2023; Pan et al., 2025), los cuales se miden mediante una batería de instrumentos deterministas que contrastan la narración con el estado persistido del mundo, de modo que cada medición puede reproducirse de forma exacta a partir del mismo corpus.

3.2. Población y muestra de estudio

La población de la investigación está constituida por el conjunto de campañas de Dungeons & Dragons que las dos arquitecturas estudiadas pueden generar bajo las condiciones técnicas del estudio, conjunto que, al no existir un registro de sus elementos y al ser teóricamente ilimitado, corresponde a una población infinita en el sentido de Arias (2012). La unidad de análisis es el par de campañas, en tanto que las unidades de observación son el turno, el bloque de 200 turnos y la campaña completa, según el nivel al que opere cada instrumento.

Dado que la población no es accesible en su totalidad, se trabajó con una muestra de 27 pares, es decir, 54 campañas de 1,400 turnos cada una y 75,600 turnos en total, seleccionada mediante un muestreo no probabilístico intencional, en el que los elementos se escogen según criterios

preestablecidos por el investigador (Arias, 2012). Los criterios aplicados fueron que cada par empleara una ambientación original y distinta de las demás, que el tono narrativo variara a lo largo del corpus, que la estructura del conflicto no se repitiera entre pares y que cada par contara con un personaje jugador distinto, tomado de un conjunto de 27 personajes generados con semilla fija y distribuidos a lo largo de un espectro de conducta que comprende 8 personajes de conducta principista, 14 de moral ambigua y 5 sin escrúpulos, 9 de los cuales, todos de moral ambigua, modifican su conducta a lo largo de la campaña. El propósito de estos criterios fue evitar que los resultados dependieran del estilo narrativo que mejor manejara una de las arquitecturas.

El tamaño de la muestra se determinó mediante un análisis de potencia a priori con el programa G*Power (Faul et al., 2007), para una prueba unilateral de diferencias pareadas, a partir de la expresión:

Donde:

N: tamaño de la muestra, es decir, número de pares requeridos.

$z(1-\alpha)$: valor crítico de la distribución normal para un nivel de significancia unilateral $\alpha = 0.05$, igual a 1.645.

$z(1-\beta)$: valor crítico correspondiente a una potencia estadística de 0.80, igual a 0.842.

d(z): tamaño del efecto estandarizado para diferencias pareadas, fijado en 0.5, que corresponde a un efecto medio.

C: corrección por el uso de la distribución t no central, calculada de forma iterativa por G*Power.

Al sustituir los parámetros, el término normal de la expresión asciende a 24.7 y, tras la corrección por los grados de libertad de la distribución t no central, G*Power determinó que se requieren N = 27 pares para alcanzar una potencia de 0.81 en la detección de un efecto medio. Cabe precisar, no obstante, que este cálculo toma como referencia la prueba t para diferencias pareadas, mientras que el contraste se realiza con la prueba de rangos con signo de Wilcoxon, cuya eficiencia relativa asintótica respecto de aquella es

de 3/π, aproximadamente 0.955, cuando las diferencias siguen una distribución normal (Lehmann, 2006), de modo que la potencia efectiva estimada para 27 pares es de 0.79 en el contraste unilateral, valor que se declara como una limitación menor del diseño y que se reduce en los contrastes bilaterales que se reportan con fines complementarios.

Por último, antes del corpus experimental se generaron tres pares piloto de 250 turnos por campaña, destinados a verificar el funcionamiento integral de las arquitecturas y de los instrumentos, los cuales no forman parte de la muestra, en tanto que las tres campañas evaluadas por el panel de expertos durante la fase inicial del proyecto proceden de una versión preliminar del sistema y, por ello, tampoco se integran al análisis confirmatorio.

3.3. Diseño de investigación

El estudio se ajusta a un diseño experimental de medidas repetidas con pares emparejados, en el que cada unidad experimental, un escenario de campaña compuesto por una ambientación, un tono, una estructura de conflicto y un personaje jugador, recibe ambos tratamientos, de manera que cada escenario actúa como su propio control. Si bien Arias (2012) reserva la denominación de experimento puro para los diseños que asignan aleatoriamente los sujetos a los grupos, en este caso la asignación resulta innecesaria, dado que no existen grupos distintos que igualar, sino un mismo escenario que se genera dos veces, y dado que ambas campañas del par se generan como copias independientes y simultáneas, sin que una influya sobre la otra, tampoco se producen efectos de orden ni de arrastre que exijan contrabalancear la secuencia de los tratamientos. Por esta razón, el emparejamiento controla de forma más eficiente que la aleatorización la variabilidad asociada al escenario, que constituye la principal fuente de variación ajena a la arquitectura, y permite analizar las diferencias dentro de cada par.

$$\text{Gpar } (n = 27): \quad X_1 \rightarrow O_1 \quad | \quad X_2 \rightarrow O_2$$

Donde:

Gpar: conjunto de 27 pares de campañas, en el que ambas campañas de cada par se generan a partir del mismo escenario inicial, del mismo personaje jugador y bajo el mismo mecanismo de tiradas deterministas.

X_1 (tratamiento experimental): generación de la campaña mediante la arquitectura multiagente (G1).

X_2 (tratamiento de control): generación de la campaña mediante la arquitectura monolítica (G2).

O_1 y O_2: mediciones de la coherencia narrativa sobre la campaña experimental y sobre la de control del mismo par, cuya diferencia intrapar constituye la unidad de análisis de las hipótesis H1d a H1f.

$O(b_1)$ a $O(b_7)$: mediciones de la coherencia narrativa en los siete bloques consecutivos de 200 turnos de cada campaña del sistema monolítico, cuya evolución constituye la unidad de análisis de las hipótesis H1a a H1c.

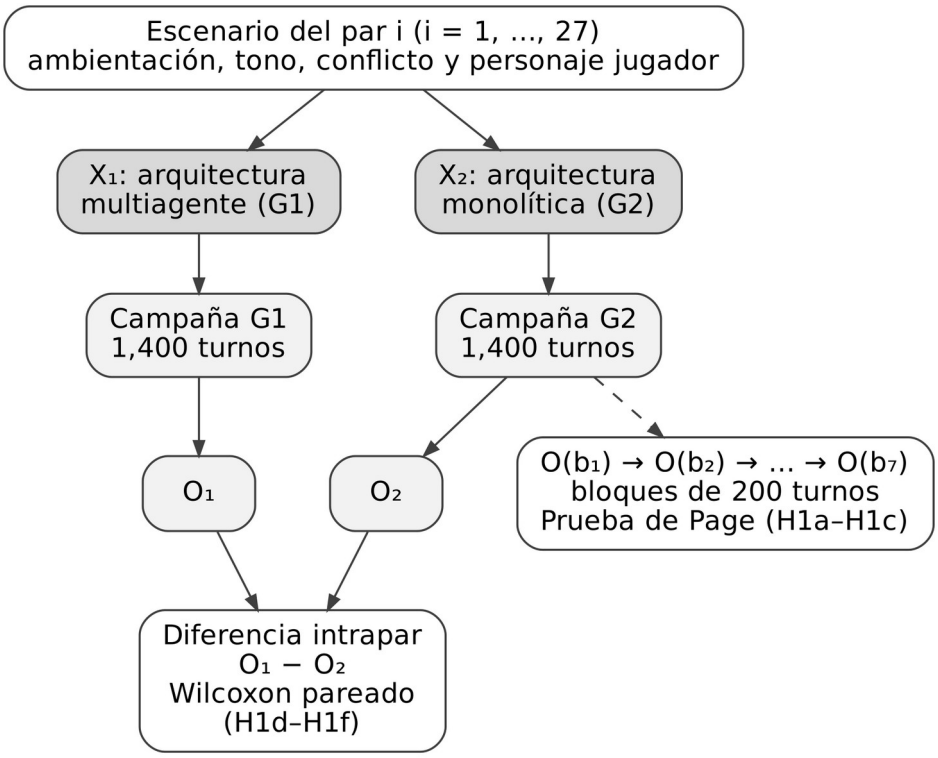
O: batería de instrumentos deterministas descrita en el apartado 3.4.3 y resumida en la Tabla 1.

Con el fin de aislar el efecto de la variable independiente, el diseño mantiene constantes dentro de cada par el modelo de lenguaje, google/gemma-4-31B-it, consumido a través de un único proveedor de inferencia y sin enrutadores intermedios, la base de datos del estado del mundo, el extractor de cambios de estado, el módulo de tiradas deterministas, el escenario inicial, el personaje jugador, el agente jugador y la extensión de la campaña, mientras que la estabilidad del modelo se verificó antes de cada tanda de generación mediante un manifiesto de huellas, que compara las salidas del modelo ante un conjunto fijo de peticiones con las registradas al inicio del proyecto, dado que un proveedor puede modificar la cuantización o el motor de inferencia sin cambiar el identificador del modelo. Además, ambas campañas de cada par se generaron de forma simultánea, lo que reduce la ventana temporal en la que un cambio no declarado del proveedor podría afectar a un brazo y no al otro.

$$\text{G2 } (n = 27): \quad X_2 \rightarrow O(b_1) \rightarrow O(b_2) \rightarrow \ldots \rightarrow O(b_7)$$

De manera complementaria, las hipótesis H1a a H1c se contrastan mediante un diseño de medidas repetidas dentro de las campañas del sistema monolítico, en el que la misma campaña se observa en siete momentos sucesivos, cada uno equivalente a una sesión de juego de 200 turnos, de modo que la hipótesis nula de ausencia de degradación dispone de un punto de referencia no arbitrario, esto es, el propio desempeño del sistema al inicio de la campaña. La Figura 1 sintetiza ambos componentes del diseño.

Figura 1. Diseño experimental de medidas repetidas con pares emparejados.



Nota. Dentro de cada par se mantienen constantes el modelo de lenguaje, la base de datos del estado del mundo, el extractor, el mecanismo de tiradas deterministas, el agente jugador y la extensión de la campaña. La línea discontinua indica el componente de medidas repetidas dentro de las campañas del sistema monolítico. Elaboración propia.

3.4. Técnicas e instrumentos de investigación

3.4.1. Técnica e instrumentos de generación del corpus

La primera fase de la recolección de datos emplea una técnica de simulación experimental interactiva, en la que cada campaña se genera mediante la interacción turno a turno entre una de las dos arquitecturas y el agente jugador autónomo, de modo que ningún investigador interviene en el desarrollo de la partida. En cada turno, el sistema

construye el contexto de la escena a partir del estado persistido del mundo, el agente jugador declara su acción y, cuando corresponde, la habilidad que emplea, el módulo de tiradas resuelve la prueba con una semilla derivada de la campaña, del turno y de la habilidad, añadiendo el modificador de la ficha del personaje, el director de juego narra el resultado y el extractor registra los cambios de estado que la narración implica, siempre que pertenezcan a la lista de tipos permitidos y estén respaldados por evidencia literal del texto.

Los instrumentos de esta fase son, por tanto, el propio sistema DM-IA en sus dos configuraciones, el agente jugador, configurado para cada personaje con un arquetipo, una agenda, una propensión al desvío y ejemplos de conducta generados específicamente para él (Yasunaga et al., 2024), y la base de datos relacional que registra de forma permanente la narración de cada turno, las tiradas y el historial de cambios de estado, registro que constituye el corpus sobre el que operan los instrumentos de medición.

3.4.2. Técnica e instrumentos de medición

La segunda fase emplea una técnica de análisis de contenido cuantitativo automatizado sobre las transcripciones y sobre el historial del estado, en la que los instrumentos son programas que, conforme a la definición de Arias (2012), constituyen recursos digitales para obtener, registrar y almacenar la información. En concreto, el instrumento reporte_validacion.py agrupa ocho secciones de verificación, a saber, los campos inmutables de los personajes, los ciclos de ubicación, el avance de los relojes narrativos, la coherencia y consistencia de entidades (Papalampidi et al., 2022), el recuerdo de los cambios de estado (Ammanabrolu et al., 2020), la tasa de correferencia de entidades (Roemmele et al., 2017), la gramaticalidad y la densidad del grafo de entidades (Guinaudeau & Strube, 2013), mientras que medidas_cierre.py calcula las medidas complementarias de repetición, de diversidad léxica y de estabilidad entre bloques, y el detector persona2 identifica los turnos en los que el director de juego decide, piensa, siente o habla en nombre del personaje jugador.

De manera complementaria, una vez generado el corpus se construyó un instrumento exploratorio del recuerdo de los cambios de estado basado en representaciones vectoriales de oraciones, el cual opera sobre una capa de medición añadida a la base de datos, de modo que no modifica el corpus ni intervino en la generación de las campañas.

Estos instrumentos se organizan según los seis indicadores de la variable dependiente, tal como se detalla en la Tabla 1 y en la ficha de instrumentos del Anexo 1, de manera que la coherencia reactiva se mide mediante la gramaticalidad, la consistencia entre el resultado de la tirada y la narración y el arraigo de la respuesta a la acción del jugador; la coherencia longitudinal, mediante la persistencia de las entidades, el recuerdo de los cambios de estado y la reaparición de personajes muertos o desaparecidos; y la calidad narrativa emergente, mediante la diversidad léxica, la legibilidad y la usurpación de la agencia del jugador. Todos los instrumentos se aplican sobre el texto normalizado de los turnos 2 a 1,400, excluyendo el turno de apertura, y producen un valor por campaña y, cuando el instrumento lo permite, por bloque de 200 turnos.

3.4.3. Validación de los instrumentos

Dado que un instrumento determinista es confiable por construcción, su validación se centró en comprobar que mide el constructo que declara medir, para lo cual cada instrumento se sometió, antes del análisis del corpus, a una prueba de sensibilidad por perturbaciones sintéticas, en la que se inyectaron sobre ventanas del corpus real defectos de efecto conocido, como la alteración del orden de los turnos, el desalineamiento entre acciones y respuestas o la inserción y supresión del evento que el instrumento debe reconocer, junto con perturbaciones de control que no deberían afectarlo. Las direcciones esperadas de cada perturbación se registraron de antemano y se protegieron mediante un resumen criptográfico SHA-256, de modo que no pudieran ajustarse después de observar los resultados, y un instrumento se consideró sensible cuando reaccionó en la dirección prevista con un tamaño de efecto no despreciable, medido mediante el delta de Cliff con un umbral de 0.147

(Cliff, 1993; Romano et al., 2006), y con significancia tras la corrección de Holm, sin reaccionar ante los controles.

A partir de esta prueba, cada instrumento se clasificó como confirmatorio, cuando superó la perturbación objetivo y los controles; confirmatorio condicionado, cuando superó la prueba pero su concordancia con el juicio humano no quedó establecida de forma concluyente; exploratorio, cuando mostró una sensibilidad parcial o un control débil; y descriptivo, cuando no admitía una perturbación confirmatoria o se encontraba saturado en todo el corpus. De manera complementaria, los instrumentos cuya validez depende de interpretar el texto se contrastaron con el juicio de evaluadores humanos externos al equipo investigador, dado que la participación de los autores en la validación introduciría un sesgo, real o percibido, incompatible con el diseño; en particular, el detector de personajes no jugadores inactivos que vuelven a actuar se comparó con el etiquetado ciego de tres evaluadores voluntarios sobre una muestra estratificada de 60 turnos, que resultó en 59 casos únicos, y el detector persona2 se contrastó con el etiquetado ciego de tres directores de juego externos sobre una submuestra estratificada del 20 % de una sonda de 515 ítems, esto es, 102 ítems, mientras que una primera pasada sobre la sonda completa, realizada con asistencia de inteligencia artificial, se documenta como tal y se emplea únicamente como estimación preliminar, no como evaluación humana.

Por último, la Rúbrica D&D-IA en su versión basada en escala Likert se aplicó durante la fase inicial del proyecto por un panel de cinco directores de juego expertos sobre tres campañas de la versión preliminar del sistema monolítico, evaluación que se conserva en el Anexo 2 como estudio piloto, dado que sus hallazgos cualitativos, en particular la colisión de identidades entre personajes no jugadores, orientaron el diseño de varios de los instrumentos deterministas, aunque sus valores no son comparables con los del corpus experimental.

3.5. Procedimiento de ejecución del estudio

La ejecución del estudio se organizó en seis fases secuenciales, que abarcan desde la implementación de las arquitecturas hasta el análisis estadístico, y cuyo desarrollo se documentó de forma continua con el fin de asegurar la trazabilidad de cada decisión y la reproducibilidad del corpus. La primera fase, que corresponde a la implementación y al congelamiento de ambas arquitecturas, se describe en el apartado 4.1 como propuesta de la investigación, mientras que las fases restantes se detallan a continuación.

3.5.1. Estudio piloto

En la segunda fase se generaron tres pares piloto de 250 turnos por campaña, sobre los cuales se ejecutaron por primera vez los instrumentos de medición contra datos reales, lo que permitió detectar y corregir errores de integración entre componentes que no se manifestaban en pruebas aisladas, así como calibrar el extractor y el agente jugador antes de iniciar la generación del corpus experimental.

3.5.2. Generación del corpus experimental

En la tercera fase se generaron los 27 pares de campañas de 1,400 turnos, equivalentes a siete sesiones de 200 turnos, ejecutando ambas campañas de cada par de forma simultánea y desatendida, con capacidad de reanudación ante interrupciones y con la verificación de la huella del modelo antes de cada tanda. Las incidencias registradas durante esta fase, como el cambio del modelo del agente jugador de NousResearch/Hermes-3-Llama-3.1-70B a google/gemma-4-31B-it a partir del par 4, con excepción de los primeros turnos de los pares 4 a 6, la incorporación de las estadísticas por personaje desde el par 3, la reanudación de una campaña del par 5 y la incorporación del avance determinista de los relojes narrativos desde el par 18, afectaron por igual a ambos brazos de cada par y se declaran en el apartado 1.4.

3.5.3. Medición y validación de los instrumentos

En la cuarta fase se ejecutaron los instrumentos de medición sobre las 54 campañas, sin intervención humana y con un resultado idéntico en cada ejecución, y en la quinta fase se completó la validación de los

instrumentos mediante la prueba de sensibilidad por perturbaciones y las auditorías humanas descritas en el apartado 3.4.3, de manera que la clasificación de cada instrumento quedara establecida antes de contrastar las hipótesis. Finalmente, en la sexta fase se realizó el análisis estadístico conforme a los procedimientos del apartado 3.6.

3.5.4. Desviaciones respecto del protocolo aprobado

El proyecto de investigación aprobado contemplaba evaluar el corpus mediante un panel de cinco directores de juego expertos que aplicarían la Rúbrica D&D-IA en escala Likert bajo condiciones de doble ciego; sin embargo, el 14 de setiembre de 2026, los investigadores y el asesor acordaron sustituir dicha evaluación por la batería de instrumentos deterministas, decisión motivada tanto por la imposibilidad de capacitar, calibrar y coordinar un panel humano sobre 54 campañas de 1,400 turnos dentro del plazo y del presupuesto disponibles como por la conveniencia de adoptar un procedimiento reproducible, acorde con los estándares de las revistas especializadas del área. Como consecuencia de este cambio, las hipótesis H1a a H1c, formuladas originalmente como la superioridad de la puntuación del sistema monolítico respecto del punto medio de la escala Likert, se reformularon como hipótesis de degradación a lo largo de la campaña, dado que los instrumentos deterministas carecen de un punto medio teórico y fijar uno para cada instrumento habría introducido un criterio arbitrario.

Asimismo, durante la validación del detector de personajes no jugadores inactivos se excluyó a uno de los tres evaluadores voluntarios, tras constatar que su registro presentaba signos de respuesta apresurada, como una mediana de 12 segundos por caso frente a 60 y 38 segundos en los otros dos evaluadores y un acuerdo con ellos cercano al azar, por lo que el acuerdo se reporta con los dos evaluadores restantes y la exclusión se documenta junto con la evidencia que la sustenta.

Del mismo modo, en la validación externa de persona2 se aplicó el mismo criterio de calidad a los tres directores de juego evaluadores, lo que llevó a tomar como referencia principal a uno de ellos, dado que otro

respondió «no viola» en la totalidad de los ítems y el tercero presentó signos de respuesta apresurada y un acuerdo inferior al azar. Por último, con posterioridad a la generación del corpus y a la clasificación de los instrumentos, se realizaron análisis complementarios orientados a cerrar las brechas metodológicas identificadas en cada objetivo, como la auditoría censal del indicador de nombres no reconocidos, la descomposición de las versiones del arraigo contextual, el instrumento semántico basado en representaciones vectoriales y la estimación del costo computacional de cada arquitectura, análisis que no modificaron el corpus ni la clasificación de los instrumentos fijada antes del contraste y que se reportan con carácter exploratorio. Todas estas desviaciones se declaran de forma explícita con el propósito de que el lector pueda valorar su efecto sobre las conclusiones.

3.6. Procesamiento y análisis de datos

Los datos obtenidos por los instrumentos se procesaron y analizaron mediante programas desarrollados en Python, conforme a procedimientos diferenciados según el grupo de hipótesis, con un nivel de significancia de $\alpha = 0.05$ en todos los contrastes.

3.6.1. Preparación de los datos

Para cada campaña se consolidaron los valores de los instrumentos a nivel de campaña y de bloque, se excluyó el turno de apertura, que corresponde a la presentación del escenario y no responde a ninguna acción del jugador, y, en los instrumentos que cuentan eventos, se calcularon tasas relativizadas respecto del número de entidades expuestas al fallo en cada bloque, dado que, por ejemplo, la posibilidad de que un personaje reaparezca tras su muerte solo existe una vez que ha muerto, de modo que una tasa sin relativizar crecería a lo largo de la campaña por efecto de la exposición y no de la degradación. Asimismo, para cada instrumento se calcularon la mediana, los cuartiles, el rango intercuartílico, la media y la desviación estándar, y se evaluó la normalidad mediante la prueba de Shapiro-Wilk (Shapiro & Wilk, 1965), la cual orientó la elección de pruebas no paramétricas.

3.6.2. Contraste de las hipótesis de degradación

Las hipótesis H1a a H1c se contrastaron mediante la prueba de tendencia de Page para alternativas ordenadas (Page, 1963), aplicada a los valores de los siete bloques de cada una de las 27 campañas del sistema monolítico, en su versión unilateral en el sentido de la degradación, que para cada instrumento corresponde a una disminución o a un aumento según su dirección de mejora, y se complementaron con la prueba de rangos con signo de Wilcoxon entre el primer y el último bloque (Wilcoxon, 1945). Cuando la relativización de una tasa dejó bloques sin entidades expuestas, las campañas afectadas se excluyeron del contraste correspondiente y el número de campañas efectivamente analizadas se reporta junto con el resultado.

3.6.3. Contraste de las hipótesis comparativas

Las hipótesis H1d a H1f se contrastaron mediante la prueba exacta de rangos con signo de Wilcoxon sobre la diferencia G1 − G2 dentro de cada uno de los 27 pares (Wilcoxon, 1945), condicional a los empates y con exclusión de las diferencias nulas, en su versión unilateral en el sentido de la hipótesis alternativa, reportando además el valor bilateral, el estimador de Hodges-Lehmann de la mediana de las diferencias con su intervalo de confianza del 95 % (Hodges & Lehmann, 1963) y el tamaño del efecto mediante la correlación biserial de rangos (Kerby, 2014). En los instrumentos que registran el turno en que ocurre por primera vez un fallo, como la primera mención de un personaje no vivo, se estimaron además curvas de supervivencia de Kaplan-Meier (Kaplan & Meier, 1958), con censura en el turno 1,400 para las campañas en las que el fallo no ocurre, y se compararon ambas arquitecturas mediante la prueba de rangos logarítmicos (Mantel, 1966).

3.6.4. Análisis de robustez y de acuerdo

Dado que el motor incorporó el avance determinista de los relojes narrativos a partir del par 18, los contrastes se repitieron por separado

para los pares 1 a 17 y 18 a 27, con el fin de verificar que las conclusiones no dependieran de una versión particular del sistema. Por su parte, la precisión y la exhaustividad de los detectores frente al juicio humano se estimaron con intervalos de confianza de Wilson (Wilson, 1927), mientras que el acuerdo entre evaluadores se estimó mediante el kappa de Cohen para pares de evaluadores (Cohen, 1960) y el kappa de Fleiss para tres evaluadores (Fleiss, 1971), complementados con índices menos sensibles a la prevalencia, como PABAK y AC1, cuando la distribución de las categorías resultó desbalanceada (Byrt et al., 1993; Gwet, 2008).

3.6.5. Reglas de decisión

La decisión sobre cada hipótesis específica se sustenta exclusivamente en los instrumentos clasificados como confirmatorios o confirmatorios condicionados para su dimensión, con corrección de Holm dentro de la familia confirmatoria de cada hipótesis cuando esta incluye más de un instrumento (Holm, 1979), de modo que se rechaza la hipótesis nula cuando el valor p ajustado es menor que 0.05 en el sentido de la hipótesis alternativa; cuando el resultado es significativo en el sentido contrario, no se rechaza la hipótesis nula y se reporta explícitamente la evidencia en la dirección opuesta, y cuando la dimensión no cuenta con instrumentos confirmatorios, la hipótesis se declara sin decisión confirmatoria. Los instrumentos exploratorios se reportan sin corrección, como orientación para la interpretación, y los descriptivos, sin contraste inferencial, mientras que la hipótesis general se decide a partir de H1d, H1e y H1f conforme al criterio establecido en el apartado 2.4.

IV. **PRESENTACIÓN DE RESULTADOS**

Los resultados que se presentan a continuación corresponden al corpus experimental de 27 pares de campañas, es decir, 54 campañas y 75,600 turnos, generado por DM-IA bajo sus dos arquitecturas, las cuales comparten el modelo google/gemma-4-31B-it, la base de datos del estado del mundo, el extractor y el módulo de tiradas deterministas, y difieren en la organización de las decisiones del turno, dado que la arquitectura monolítica (G2) resuelve cada turno en una sola generación, mientras que la arquitectura multiagente (G1) lo distribuye entre un enrutador determinista, un árbitro, un actor de personajes no jugadores, un agente del mundo y un narrador. Conforme a la reformulación metodológica descrita en el apartado 3.5.4, los seis indicadores de la Rúbrica D&D-IA se miden mediante la batería de instrumentos deterministas resumida en la Tabla 1 y detallada en el Anexo 1, en lugar de la escala Likert aplicada por el panel de expertos, cuya evaluación piloto se conserva en el Anexo 2.

El capítulo se organiza en tres apartados. El primero describe la propuesta de la investigación, esto es, el sistema DM-IA y sus dos arquitecturas; el segundo presenta, para cada objetivo específico, su definición, los resultados obtenidos y su análisis e interpretación; y el tercero desarrolla la docimasia de las hipótesis específicas y de la hipótesis general. Para los objetivos OE-1 a OE-3 se presentan los estadísticos descriptivos del sistema monolítico sobre sus 27 campañas, cuyo contraste de degradación mediante la prueba de tendencia de Page sobre siete bloques de 200 turnos se desarrolla en la docimasia, mientras que para los objetivos OE-4 a OE-6 se presenta la comparación pareada entre ambas arquitecturas mediante la prueba de rangos con signo de Wilcoxon dentro de cada uno de los 27 pares. La discusión de estos resultados frente a los antecedentes y el cierre de la brecha metodológica identificada en cada objetivo se desarrollan en el Capítulo V.

En todas las tablas, cada instrumento se identifica con su clasificación según la prueba de sensibilidad descrita en el apartado 3.4.3, es decir, confirmatorio, confirmatorio condicionado, exploratorio o descriptivo, de modo que solo los instrumentos confirmatorios y confirmatorios condicionados sustentan la decisión sobre cada hipótesis, conforme a las reglas del apartado 3.6.5, mientras que los demás se reportan como orientación para la interpretación.

4.1. Propuesta de investigación: el sistema DM-IA y sus dos arquitecturas

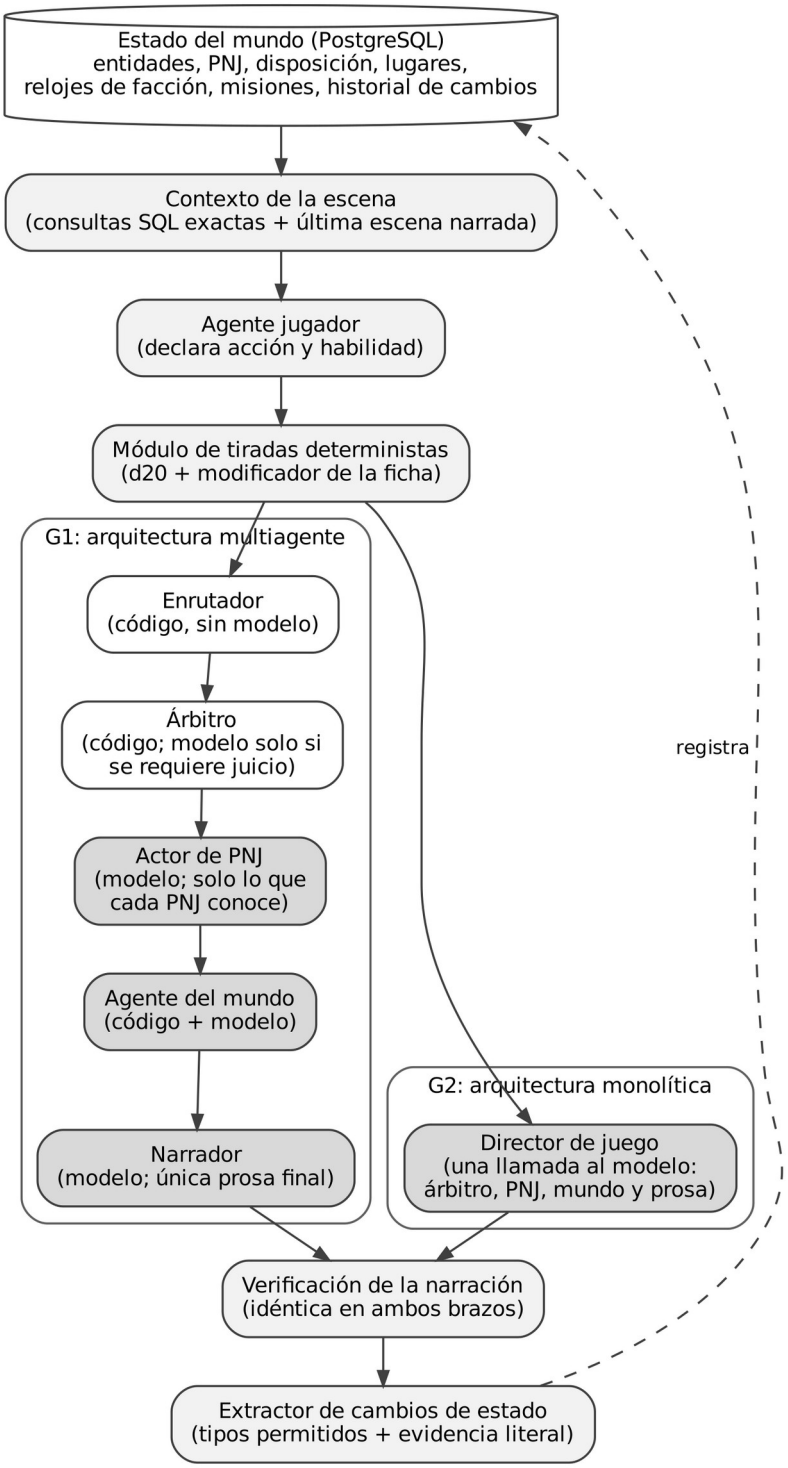
La propuesta de la investigación es DM-IA, un director de juego automatizado para campañas de D&D en español, implementado en dos arquitecturas que comparten un núcleo común, conformado por el modelo de lenguaje, la base de datos relacional del estado del mundo, el extractor de cambios de estado, el módulo de tiradas deterministas y el agente jugador. Sobre ese núcleo, la arquitectura monolítica resuelve cada turno mediante una sola llamada al director de juego, mientras que la arquitectura multiagente distribuye el turno entre un enrutador determinista, un árbitro que resuelve el resultado mecánico, un actor que interpreta a los personajes no jugadores con acceso únicamente a lo que cada uno conoce, un agente del mundo que propone los cambios del entorno y un narrador que redacta la prosa final. Una vez completada la implementación, el código compartido se sometió a una auditoría de simetría que verificó que toda corrección se aplicara por igual a ambos brazos, y las herramientas que modifican el estado, incluida la creación de nuevas entidades, se pusieron a disposición de ambas arquitecturas, con el fin de que ninguna obtuviera ventaja por una diferencia en sus capacidades de registro.

El estado del mundo se almacena en una base de datos PostgreSQL que registra, entre otros elementos, las entidades de la campaña, el estado y la disposición de cada personaje no jugador hacia el personaje jugador, lo que cada uno conoce, los lugares, los relojes de facción, las misiones y el historial completo de los cambios de estado, de modo que el sistema no depende de que el modelo recuerde estos datos, sino que los consulta de forma exacta en cada turno. En ambos brazos, cada

turno sigue el mismo ciclo: el sistema construye el contexto de la escena a partir de consultas exactas al estado y de la última escena narrada, el agente jugador declara su acción, el módulo de tiradas resuelve la prueba con un d20 más el modificador de la ficha del personaje, el director de juego, en su configuración monolítica o multiagente, produce la narración, un verificador común revisa que esta no incluya comentarios sobre sus propias reglas ni narre como éxito una tirada fallida y, por último, el extractor clasifica los cambios de estado que la narración implica en una lista cerrada de tipos, cada uno respaldado por una cita literal del texto, antes de que se escriban en la base de datos. La recuperación por similitud sobre representaciones vectoriales no interviene en este ciclo.

La diferencia entre ambas arquitecturas se limita a la etapa del director de juego. En la arquitectura multiagente, el enrutador clasifica el turno, sin recurrir al modelo, según si la acción ocurre dentro o fuera del rol, si requiere arbitraje y qué personajes no jugadores deben responder; el árbitro compara la tirada con la clase de dificultad correspondiente, ajustada según la disposición del personaje no jugador, y solo recurre al modelo cuando la situación exige un juicio, como una solución ingeniosa sin tirada previa; el actor genera la respuesta de cada personaje no jugador presente a partir de su propia ficha y de lo que este conoce; el agente del mundo resuelve en código el avance de los relojes y la persistencia de los lugares, y recurre al modelo únicamente para los elementos creativos del entorno; y el narrador integra estas decisiones en la única prosa que recibe el jugador. En consecuencia, del lado del director de juego la arquitectura multiagente realizó, en mediana, 2.86 llamadas al modelo por turno frente a una de la arquitectura monolítica, diferencia de costo que se examina en el Capítulo V. La Figura 2 representa el ciclo del turno en ambas arquitecturas.

Figura 2. Ciclo del turno en las arquitecturas monolítica (G2) y multiagente (G1) de DM-IA.



Nota. Los componentes fuera de los recuadros son idénticos en ambos brazos. Los nodos en gris oscuro recurren al modelo de lenguaje google/gemma-4-31B-it en cada turno, y los nodos en blanco se resuelven en código. Elaboración propia a partir del código fuente de DM-IA.

4.2. Análisis e interpretación de resultados

4.2.1. Coherencia reactiva del sistema monolítico (OE-1)

Objetivo

OE-1 busca establecer el nivel de coherencia reactiva que el sistema monolítico (G2) alcanza ante las acciones del jugador y verificar si dicho nivel se degrada conforme avanza la campaña, para lo cual se emplean los instrumentos de los indicadores CR-1, fluidez y corrección de la respuesta inmediata, y CR-2, arraigo contextual a la acción del jugador, aplicados sobre las 27 campañas G2 del corpus.

Resultados

Tabla 3. Estadísticos descriptivos — Coherencia reactiva, sistema monolítico (G2), n = 27 campañas.

Indicador	Instrumento	Mdn	Q1	Q3	RIQ	Mín	Máx	Media (DE)	Shapiro-Wilk p	¿Normal?
CR-1	Gramaticalidad (LanguageTool)	0.9992	0.9991	0.9994	0.0003	0.9984	0.9998	0.9992 (0.0004)	0.3445	sí
CR-1	Pifia narrada como éxito (% de turnos)	0.07 %	0.00 %	0.14 %	0.14 %	0.00 %	0.50 %	0.09 % (0.11 %)	<0.0001	no
CR-1	Caracteres de otro alfabeto o U+FFFD (%)	0.07 %	0.07 %	0.14 %	0.07 %	0.00 %	0.29 %	0.10 % (0.08 %)	0.0045	no
CR-2	Respuesta a la acción específica (z), confirmatorio	2.81	2.61	3.01	0.40	2.45	3.51	2.82 (0.27)	0.2746	sí
CR-2	Solapamiento con la acción (crudo)	0.125	0.114	0.134	0.020	0.104	0.163	0.125 (0.014)	0.2788	sí
CR-2	Anclaje al escenario (coseno, ventana de 8)	0.072	0.061	0.082	0.021	0.047	0.145	0.076 (0.024)	0.0130	no
CR-2	Turnos con algún nombre no reconocido	5.08 %	3.40 %	7.72 %	4.32 %	2.43 %	24.23 %	6.75 % (5.08 %)	<0.0001	no

Nota. Elaboración propia a partir de los instrumentos reporte_validacion.py y medidas_cierre.py aplicados sobre las 27 campañas G2. La tabla incluye los instrumentos de mayor relevancia interpretativa; la ficha completa se presenta en el Anexo 1.

Análisis e interpretación

El único instrumento de CR-2 validado como confirmatorio mediante la prueba de sensibilidad por perturbación —la respuesta a la acción específica normalizada en z— sitúa a G2 en 2.82 de media, con dispersión moderada (RIQ = 0.40) y sin evidencia de asimetría marcada (Shapiro-Wilk no rechaza normalidad, p = 0.27). La gramaticalidad se mantiene prácticamente en el techo de la escala (0.9992 de mediana), consistente con el hallazgo cualitativo del panel piloto de que la fluidez local no era, en general, un problema del sistema monolítico. El indicador exploratorio de turnos con algún nombre no reconocido —proxy imperfecto de arraigo, que no distingue nombres inventados de personajes no jugadores legítimos nuevos— muestra una mediana de 5.08 % con una cola larga hacia arriba (máximo 24.23 %), y se reporta como exploratorio, no como evidencia confirmatoria, precisamente por esa limitación de precisión, cuya depuración mediante una auditoría censal se presenta en el apartado 5.1.

4.2.2. Coherencia longitudinal del sistema monolítico (OE-2)

Objetivo

OE-2 evalúa la capacidad del sistema monolítico (G2) para mantener la integridad fáctica y la consistencia narrativa a lo largo de campañas de 1,400 turnos, así como la evolución de dicha capacidad conforme avanza la campaña, mediante los instrumentos de CL-1, consistencia de personajes, que comprenden la coherencia y la consistencia de entidades y la tasa de correferencia de entidades, y de CL-2, consistencia de eventos y del estado del mundo, que comprenden el recuerdo de los cambios de estado, la mención de personajes no jugadores inactivos y los ciclos de ubicación.

Resultados

Tabla 4. Estadísticos descriptivos — Coherencia longitudinal, sistema monolítico (G2), n = 27 campañas.

Indicador	Instrumento	Mdn	Q1	Q3	RIQ	Mín	Máx	Media (DE)	Shapiro-Wilk p	¿Normal?
CL-1	Papalampidi C: coherencia de entidad	1.67	0.92	2.29	1.38	0.00	3.33	1.60 (0.88)	0.6394	sí
CL-1	Papalampidi V: consistencia de atributos	0.058	0.048	0.079	0.031	0.030	0.151	0.067 (0.032)	0.0016	no
CL-1	Entity Coreference Rate	0.998	0.998	0.998	0.001	0.997	0.999	0.998 (0.000)	0.2287	sí
CL-2	Jericho: recall de cambios de estado narrados	0.22	0.13	0.36	0.23	0.00	0.50	0.24 (0.16)	0.1312	sí
CL-2	PNJ inactivo mencionado (% de turnos)	0.21 %	0.00 %	2.50 %	2.50 %	0.00 %	15.94 %	2.29 % (3.93 %)	<0.0001	no
CL-2	Turno de la primera mención de un PNJ no vivo (1401 = nunca)	891	380	1401	1021	83	1401	865 (520)	0.0005	no
CL-2	Bucles: ciclos de ubicaciones (fracción de campañas con ciclo)	1.00	1.00	1.00	0.00	1.00	1.00	1.00 (0.00)	—	—

Nota. Elaboración propia a partir de reporte_validacion.py sobre las 27 campañas G2. Las medidas de coherencia (C) y consistencia (V) de entidades no cuentan con una perturbación objetivo propia en la prueba de sensibilidad, por lo que se clasifican como exploratorias, en tanto que la tasa de correferencia de entidades se encuentra saturada cerca de 1 en todo el corpus y se clasifica como descriptiva.

Análisis e interpretación

La coherencia de entidad sitúa a G2 en una mediana de 1.67 sobre un máximo posible de 4.5, con un mínimo de 0.00, lo que significa que en al menos una campaña ninguna de las entidades más mencionadas se mantuvo como referente rastreable entre su primera y su última mención, caso que corresponde al par 6 y que probablemente refleja un abandono genuino de las entidades iniciales. Por su parte, el recuerdo de los cambios de estado es bajo en términos absolutos (Mdn = 0.22), aunque su capacidad de discriminación se concentra en los cambios de condición de los personajes, tal como se documenta en el cierre de brecha de este objetivo, mientras que la mención de personajes no jugadores inactivos presenta una mediana baja (0.21 %) con una cola derecha marcada (máximo de 15.94 %), y el turno de la primera mención de un personaje no vivo tiene una mediana de 891, con una proporción notable de campañas en las que el evento no ocurre dentro de los 1,400 turnos.

4.2.3. Calidad narrativa emergente del sistema monolítico (OE-3)

Objetivo

OE-3 evalúa la capacidad del sistema monolítico (G2) para generar una narrativa de calidad creativa y para respetar la agencia del jugador, así como la evolución de ambas capacidades a lo largo de la campaña, mediante los instrumentos de QN-1, que comprenden la diversidad léxica mediante TTR, MTLD y MATTR, la legibilidad mediante las fórmulas de Fernández Huerta y Szigriszt-Pazos y la repetición de bigramas y de frases, y de QN-2, que corresponde al detector persona2 de usurpación de la agencia del personaje jugador, clasificado como confirmatorio condicionado a la auditoría de su precisión.

Resultados

Tabla 5. Estadísticos descriptivos — Calidad narrativa emergente, sistema monolítico (G2), n = 27 campañas.

Indicador	Instrumento	Mdn	Q1	Q3	RIQ	Mín	Máx	Media (DE)	Shapiro-Wilk p	¿Normal?
QN-1	TTR (diversidad léxica, por turno)	0.725	0.719	0.732	0.013	0.701	0.737	0.723 (0.009)	0.0432	no
QN-1	MTLD de la campaña (no depende de la longitud)	108.9	104.9	110.7	5.9	101.7	114.2	108.5 (3.8)	0.1985	sí
QN-1	MATTR de la campaña, ventana de 50	0.828	0.825	0.829	0.005	0.820	0.833	0.827 (0.004)	0.2126	sí
QN-1	Legibilidad Fernández-Huerta	61.8	60.6	63.7	3.1	55.1	66.1	61.9 (2.5)	0.6640	sí
QN-1	Szigriszt-Pazos (banda INFLESZ: normal)	57.6	56.3	59.6	3.2	50.8	62.0	57.7 (2.5)	0.6614	sí
QN-1	Repetición de bigramas (por turno)	0.018	0.017	0.019	0.002	0.016	0.022	0.018 (0.002)	0.2580	sí
QN-1	Frases idénticas repetidas ≥ 3 veces (% de turnos)	0.00 %	0.00 %	0.46 %	0.46 %	0.00 %	1.79 %	0.31 % (0.44 %)	<0.0001	no
QN-2	Usurpación mental/verbal/de decisión del PJ (% de turnos), confirmatorio condicionado	3.47 %	2.10 %	5.50 %	3.40 %	1.36 %	11.40 %	4.27 % (2.76 %)	0.0017	no

Nota. Elaboración propia a partir de los instrumentos aplicados sobre las 27 campañas G2. MTLD, MATTR y Szigriszt-Pazos complementan a TTR y a Fernández Huerta sin reemplazarlos, y persona2 se clasifica como confirmatorio condicionado, dado que su precisión frente al juicio humano externo se estimó sin un acuerdo fiable entre evaluadores.

Análisis e interpretación

La diversidad léxica de G2 medida sin controlar por longitud de turno (TTR = 0.725 de mediana) no es comparable en sentido absoluto con la de otros sistemas sin ese control, dado que TTR decrece mecánicamente con la longitud del texto; MTLD (108.9) y MATTR (0.828), que no dependen de la longitud, ofrecen una lectura más estable de la misma propiedad. La legibilidad se ubica en la banda "normal" tanto por Fernández-Huerta (61.9 de media) como por Szigriszt-Pazos (57.7 de media, banda INFLESZ "normal"), dos fórmulas de la misma familia de regresión lineal sobre sílabas y longitud de frase, por lo que su coincidencia no debe leerse como confirmación independiente. La usurpación de agencia del jugador (`persona2`) tiene una mediana de 3.47 % de los turnos, cifra que corresponde a las marcas del detector y que, dado que su precisión frente al evaluador externo de referencia fue de 33.3 %, sobrestima la usurpación explícita real, tal como se examina en los apartados 5.3 y 5.6.

4.2.4. Comparación de la coherencia reactiva (OE-4)

Objetivo

OE-4 contrasta la coherencia reactiva de G1 frente a G2 mediante el diseño de medidas repetidas con pares emparejados descrito en el apartado 3.3, comparando la diferencia G1 − G2 dentro de cada uno de los 27 pares con la prueba exacta de rangos con signo de Wilcoxon descrita en el apartado 3.6, de modo que este objetivo, junto con OE-5 y OE-6, decide las hipótesis comparativas y, a través de ellas, la hipótesis general de la investigación.

Resultados

Tabla 6. Comparación pareada G1−G2, 27 parejas — Coherencia reactiva (H1d).

Indicador	Instrumento	Uso	Mdn G1	Mdn G2	Mdn dif.	HL [IC 95 %]	n efect.	p bilateral	p unil. «G1 mejor»	p unil. «G2 mejor»	r	p Holm
CR-1	Gramaticalidad	Descriptivo/no usar	0.9994	0.9992	+0.0001	+0.0001 [-0.0001, +0.0003]	27	0.2176	0.1088	0.8935	+0.28	—
CR-2	Respuesta a la acción específica (z)	Confirmatorio	2.70	2.81	-0.18	-0.13 [-0.25, -0.03]	27	0.0319	0.9850	0.0159	-0.47	0.0319
CR-2	Solapamiento con la acción (crudo)	Exploratorio	0.135	0.125	+0.009	+0.011 [+0.006, +0.015]	27	<0.0001	<0.0001	1.0000	+0.84	—
CR-2	Anclaje al escenario (coseno)	Exploratorio	0.143	0.072	+0.060	+0.059 [+0.035, +0.082]	27	<0.0001	<0.0001	1.0000	+0.83	—
CR-2	Anclaje sin nombres propios	Exploratorio	0.073	0.063	+0.012	+0.013 [+0.005, +0.020]	27	0.0036	0.0018	0.9984	+0.62	—
CR-2	Turnos con nombre no reconocido	Exploratorio	3.00 %	5.08 %	-2.00 pp	-0.79 pp [-3.04, +3.70]	27	0.7676	0.3838	0.6252	-0.07	—

Nota. Elaboración propia a partir de la comparación pareada de los 27 pares. La tabla incluye los instrumentos de mayor relevancia interpretativa; r corresponde a la correlación biserial de rangos de la diferencia G1 − G2, cuyo signo debe leerse según la dirección de mejora de cada instrumento.

Análisis e interpretación

El único instrumento validado como confirmatorio por la prueba de sensibilidad por perturbaciones, la respuesta a la acción específica normalizada en z, muestra una diferencia mediana de -0.18 a favor de G2 (HL -0.13, IC 95 % [-0.25, -0.03]), estadísticamente significativa (p bilateral = 0.0319; p unilateral «G2 mejor» = 0.0159) con un tamaño de efecto moderado (r = -0.47). Sin embargo, las tres versiones exploratorias del mismo constructo —arraigo contextual, medido sin normalizar— muestran la dirección opuesta con tamaños de efecto grandes: solapamiento crudo (r = +0.84), anclaje al escenario por coseno (r = +0.83) y anclaje sin nombres propios (r = +0.62), las tres a favor de G1 con p < 0.01. La gramaticalidad no muestra diferencia significativa (p = 0.2176). La descomposición de esta discordancia en un componente específico y uno genérico se presenta en el apartado 5.4.

4.2.5. Comparación de la coherencia longitudinal (OE-5)

Objetivo

OE-5 contrasta la coherencia longitudinal de G1 frente a G2 mediante el mismo diseño de pares emparejados y la misma prueba de Wilcoxon que OE-4, sobre los indicadores de CL-1, consistencia de personajes, y de CL-2, consistencia de eventos y del estado del mundo, complementados con un análisis de supervivencia sobre el turno de la primera mención de un personaje no vivo.

Resultados

Tabla 7. Comparación pareada G1−G2, 27 parejas — Coherencia longitudinal (H1e).

Indicador	Instrumento	Uso	Mdn G1	Mdn G2	Mdn dif.	HL [IC 95 %]	n efect.	p bilateral	p unil. «G1 mejor»	p unil. «G2 mejor»	r
CL-1	Papalampidi C: coherencia de entidad	Exploratorio	2.17	1.67	+0.50	+0.58 [+0.17, +1.00]	25	0.0170	0.0085	0.9919	+0.54
CL-1	Papalampidi V: consistencia de atributos	Exploratorio	0.074	0.058	+0.012	+0.016 [-0.001, +0.032]	27	0.0859	0.0430	0.9593	+0.38
CL-2	Jericho: recall de cambios de estado	Exploratorio	0.21	0.22	-0.04	-0.03 [-0.13, +0.08]	25	0.6387	0.6855	0.3194	-0.11
CL-2	PNJ inactivo mencionado (% de turnos)	Exploratorio	3.86 %	0.21 %	+3.86 pp	+4.66 pp [+0.11, +8.86]	24	0.0315	0.9854	0.0157	+0.50
CL-2	PNJ inactivo como sujeto (refinado)	Exploratorio	0.00	0.00	+0.00	+0.00 [-0.36, +0.00]	6	0.4375	0.2188	0.8438	-0.43

Nota. Elaboración propia a partir de la comparación pareada de los 27 pares. Ningún instrumento de CL-1 ni de CL-2 alcanzó la clasificación confirmatoria en la prueba de sensibilidad; n efect. corresponde a los pares con diferencia no nula.

Análisis e interpretación

Papalampidi C (centralidad de entidad) favorece a G1 con significación nominal ($p = 0.0170$, $r = +0.54$): las entidades sembradas se mantienen, en promedio, mejor rastreadas como referentes narrativos a lo largo de la campaña bajo la arquitectura multiagente. En la dirección opuesta, el indicador de PNJ inactivo mencionado —un personaje no jugador narrado como presente después de que su estado pasara a inactivo— es significativamente más frecuente en G1 que en G2 ($p = 0.0315$, $r = +0.50$ en la escala donde menor es mejor, es decir, desfavorable para G1); sin embargo, la versión refinada del mismo indicador, que exige que el personaje inactivo sea sujeto gramatical de la oración y no solo mencionado o referido retrospectivamente, pierde por completo la significación ($p = 0.4375$, $n = 6$). Ningún instrumento de esta dimensión fue validado como confirmatorio por la prueba de sensibilidad por perturbaciones.

4.2.6. Comparación de la calidad narrativa emergente (OE-6)

Objetivo

OE-6 contrasta la calidad narrativa emergente de G1 frente a G2 mediante el mismo diseño de pares emparejados, sobre los indicadores de QN-1, que comprenden la diversidad léxica, la legibilidad y la repetición, y de QN-2, que corresponde a la usurpación de la agencia del jugador medida por persona2.

Resultados

Tabla 8. Comparación pareada G1–G2, 27 parejas — Calidad narrativa emergente (H1f).

Indicador	Instrumento	Uso	Mdn G1	Mdn G2	Mdn dif.	HL [IC 95 %]	n efect.	p bilateral	r	p Holm
QN-1	TTR (por turno, sin controlar longitud)	Exploratorio	0.679	0.725	-0.044	-0.045 [-0.049, -0.041]	27	<0.0001	-1.00	—
QN-1	Repetición de bigramas (por turno)	Exploratorio	0.030	0.018	+0.010	+0.011 [+0.010, +0.012]	27	<0.0001	+1.00	—
QN-1	TTR a 100 palabras (control de longitud)	Exploratorio	0.7409	0.7393	+0.0023	+0.0022 [+0.0004, +0.0039]	27	0.0200	+0.51	—
QN-1	Bigramas a 100 palabras (control de longitud)	Exploratorio	0.0139	0.0154	-0.0017	-0.0014 [-0.0019, -0.0009]	27	<0.0001	-0.83	—
QN-1	MTLD de la campaña	Exploratorio	109.0	108.9	+0.2	+0.2 [-1.4, +1.9]	27	0.8408	+0.05	—
QN-1	MATTR de la campaña	Exploratorio	0.824	0.828	-0.004	-0.004 [-0.005, -0.002]	25	0.0018	-0.68	—
QN-1	Legibilidad Fernández-Huerta	Descriptivo/no usar	60.5	61.8	-1.6	-1.8 [-2.8, -0.7]	27	0.0055	-0.60	—
QN-1	Szigriszt-Pazos	Descriptivo/no usar	56.3	57.6	-1.6	-1.8 [-2.8, -0.8]	27	0.0055	-0.60	—
QN-2	Usurpación total del PJ	Confirmatorio condicionado	0.17 %	3.47 %	-3.39 pp	-3.66 pp [-4.87, -2.74]	27	<0.0001	-1.00	<0.0001
QN-2	· decisión	Confirmatorio condicionado	0.00 %	0.17 %	-0.17 pp	-0.16 pp [-0.21, -0.11]	20	<0.0001	-1.00	<0.0001
QN-2	· pensamiento	Confirmatorio condicionado	0.09 %	2.38 %	-2.30 pp	-2.63 pp [-3.69, -1.89]	27	<0.0001	-1.00	<0.0001
QN-2	· emoción	Confirmatorio condicionado	0.00 %	0.22 %	-0.22 pp	-0.23 pp [-0.29, -0.17]	25	<0.0001	-1.00	<0.0001
QN-2	· habla	Confirmatorio condicionado	0.00 %	0.43 %	-0.34 pp	-0.42 pp [-0.68, -0.24]	26	<0.0001	-0.98	<0.0001

Nota. Elaboración propia a partir de la comparación pareada de los 27 pares. La mediana de palabras por turno es de 158 en G1 y de 116 en G2 (diferencia de +41, p < 0.0001), diferencia que motiva reportar TTR y la repetición de bigramas por turno como exploratorios y sus versiones calculadas sobre las primeras 100 palabras como control.

Análisis e interpretación

Las cinco filas de `persona2` —el único grupo de instrumentos confirmatorios (condicionados) de todo el capítulo— favorecen a G1 de forma unánime y con el tamaño de efecto máximo posible en una prueba pareada (r entre -0.98 y -1.00, es decir, G1 obtiene una tasa de usurpación de agencia del jugador menor que G2 en prácticamente los 27 pares sin excepción), con $p < 0.0001$ en las cinco filas incluso tras la corrección de Holm dentro de la familia confirmatoria. La diversidad léxica sin controlar por longitud (TTR, bigramas) favorece a G2 con efectos también extremos ($r = \pm 1.00$), pero esta diferencia se explica en gran medida por la diferencia de longitud de turno entre arquitecturas (G1: 158 palabras de mediana; G2: 116): al recalcular ambos instrumentos sobre las primeras 100 palabras de cada turno, la dirección del efecto se invierte para ambos (TTR a 100 palabras favorece a G1, $r = +0.51$; bigramas a 100 palabras favorece a G1, $r = -0.83$), y MTLD —que no depende de la longitud— no muestra diferencia significativa entre arquitecturas ($p = 0.8408$). La legibilidad (Fernández-Huerta y Szigriszt-Pazos, misma familia de fórmulas) favorece levemente a G2, pero se reporta como descriptiva por no tener un sentido de mejora definido para la calidad narrativa. Por último, al corregir la tasa de cada brazo por la precisión del detector estimada por el evaluador externo de referencia, G1 se mantiene por debajo de G2 en los 27 pares, análisis de sensibilidad que se detalla en el apartado 5.6.

4.3. Docimasia de hipótesis

4.3.1. Hipótesis H1a: degradación de la coherencia reactiva del sistema monolítico

H1a: La coherencia reactiva de las respuestas generadas por el sistema monolítico disminuye conforme avanza la campaña.

H0a: La coherencia reactiva de las respuestas generadas por el sistema monolítico no disminuye conforme avanza la campaña.

La Tabla 9 presenta el contraste de la hipótesis de degradación sobre los siete bloques de 200 turnos de las 27 campañas G2. El instrumento confirmatorio de la dimensión, la respuesta a la acción específica en z, pasa de una mediana de 2.768 en el primer bloque a 2.742 en el último, variación que no resulta significativa ni en la prueba de tendencia de Page (p unilateral = 0.310) ni en la comparación entre el primer y el último bloque mediante la prueba de Wilcoxon (p = 0.420); en consecuencia, no se rechaza H0a y se concluye que, en el corpus estudiado, la coherencia reactiva del sistema monolítico no disminuye conforme avanza la campaña.

Tabla 9. Contraste de degradación por bloques de 200 turnos — Coherencia reactiva, sistema monolítico (G2), n = 27 campañas.

Hipótesis	Instrumento	Uso	Dirección de degradación	n	Mdn bloque 1	Mdn bloque 7	p Page (unilateral)	p Wilcoxon (bloque 1 vs. 7)
H1a	Respuesta a la acción específica (z)	Confirmatorio	Disminuye	27	2.768	2.742	0.310	0.420

Nota. Elaboración propia a partir de los valores por bloque de las 27 campañas G2. El bloque 1 excluye el turno de apertura; el valor p de Page es unilateral en el sentido de la degradación.

4.3.2. Hipótesis H1b: degradación de la coherencia longitudinal del sistema monolítico

H1b: La coherencia longitudinal del sistema monolítico disminuye conforme avanza la campaña.

H0b: La coherencia longitudinal del sistema monolítico no disminuye conforme avanza la campaña.

La Tabla 10 presenta el contraste de degradación de la dimensión longitudinal, la cual no cuenta con instrumentos confirmatorios, por lo que, conforme a las reglas del apartado 3.6.5, H1b se declara sin decisión confirmatoria y los resultados se reportan como evidencia exploratoria. En su versión sin relativizar, la mención de personajes no jugadores inactivos mostró una tendencia creciente significativa (Page, p = 0.035; Wilcoxon, p = 0.013); sin embargo, al relativizar la tasa de cada bloque respecto de los personajes ya inactivos en él, la tendencia desaparece (Page, p = 0.451; n = 10), lo que confirma que el aumento observado respondía al crecimiento del número de

personajes expuestos a este fallo y no a una degradación de la coherencia. Cabe precisar que la relativización excluyó 17 campañas que tenían algún bloque sin personajes inactivos, por lo que el resultado nulo podría deberse en parte a la menor potencia del contraste, mientras que la similitud léxica en la descripción de los lugares aumentó de forma significativa (p bilateral = 0.039), resultado que no se interpreta como mejora ni como degradación, dado que el instrumento no distingue la continuidad descriptiva del estancamiento.

Tabla 10. Contraste de degradación por bloques de 200 turnos — Coherencia longitudinal, sistema monolítico (G2).

Hipótesis	Instrumento	Uso	Dirección de degradación	n	Mdn bloque 1	Mdn bloque 7	p Page (unilateral)	p Wilcoxon (bloque 1 vs. 7)
H1b	PNJ inactivo mencionado, sin relativizar	Exploratorio	Aumenta	27	0.000	0.000	0.035	0.013
H1b	PNJ inactivo mencionado, relativizado por exposición	Exploratorio	Aumenta	10	0.000	0.000	0.451	0.500

Nota. Elaboración propia a partir de los valores por bloque de las campañas G2. La versión sin relativizar está confundida por el número creciente de personajes inactivos a lo largo de la campaña, por lo que solo la versión relativizada admite una lectura de degradación; se excluyen las campañas con algún bloque sin personajes inactivos.

4.3.3. Hipótesis H1c: degradación de la calidad narrativa emergente del sistema monolítico

H1c: La calidad narrativa emergente de las campañas generadas por el sistema monolítico disminuye conforme avanza la campaña.

H0c: La calidad narrativa emergente de las campañas generadas por el sistema monolítico no disminuye conforme avanza la campaña.

La Tabla 11 presenta el contraste de degradación de la calidad narrativa emergente, cuya familia confirmatoria está conformada por el detector persona2. La tasa de usurpación de la agencia pasó de una mediana de 3.0 % en el primer bloque a 3.5 % en el último, aumento que no resulta significativo tras la corrección de Holm (Page, p = 0.089; p ajustado = 0.178; Wilcoxon, p = 0.067), por lo que no se rechaza H0c, mientras que, de forma concordante, la diversidad léxica medida mediante MATTR, de carácter exploratorio, se

mantiene constante entre el primer y el último bloque (0.828 en ambos; Page, p = 0.570). En consecuencia, en el corpus estudiado la calidad narrativa emergente del sistema monolítico no disminuye conforme avanza la campaña, si bien la tendencia de la usurpación de la agencia, próxima a la significancia antes de la corrección, justifica su seguimiento en campañas de mayor extensión.

Tabla 11. Contraste de degradación por bloques de 200 turnos — Calidad narrativa emergente, sistema monolítico (G2), n = 27 campañas.

Hipótesis	Instrumento	Uso	Dirección de degradación	n	Mdn bloque 1	Mdn bloque 7	p Page (unilateral)	p Wilcoxon (bloque 1 vs. 7)
H1c	Usurpación de la agencia del PJ (persona2)	Confirmatorio condicionado	Aumenta	27	3.0 %	3.5 %	0.089 (Holm: 0.178)	0.067
H1c	MATTR, ventana de 50	Exploratorio	Disminuye	27	0.828	0.828	0.570	0.525

Nota. Elaboración propia a partir de los valores por bloque de las 27 campañas G2. La corrección de Holm se aplica dentro de la familia confirmatoria de H1c; MATTR se reporta sin corrección como evidencia exploratoria.

4.3.4. Hipótesis H1d: mayor coherencia reactiva del sistema multiagente

H1d: Los sistemas multiagente generan respuestas con mayor coherencia reactiva que los sistemas monolíticos.

H0d: Los sistemas multiagente generan respuestas con una coherencia reactiva igual o inferior a la de los sistemas monolíticos.

Con el único instrumento confirmatorio de la dimensión, la respuesta a la acción específica en z, el contraste unilateral en el sentido de H1d no resulta significativo (p = 0.985), por lo que no se rechaza H0d y H1d no se sostiene. Además, el contraste bilateral revela una diferencia significativa en el sentido opuesto, a favor de G2 (p = 0.0319; HL = −0.13, IC 95 % [−0.25, −0.03]; r = −0.47), resultado que se reporta como evidencia en la dirección contraria a la hipótesis alternativa, si bien, dada su discordancia con las tres mediciones exploratorias del mismo constructo, no se interpreta como una superioridad concluyente del sistema monolítico. La descomposición presentada en el apartado 5.4

muestra, además, que la ventaja de G1 en la versión cruda proviene de un componente genérico asociado a la mayor extensión de sus respuestas, mientras que el componente específico de la respuesta a la acción no difiere entre arquitecturas ($p = 0.59$), por lo que ninguna de ellas responde de forma sustantivamente mejor a la acción específica del jugador.

4.3.5. Hipótesis H1e: mayor coherencia longitudinal del sistema multiagente

H1e: Los sistemas multiagente mantienen una mayor coherencia longitudinal a lo largo de la campaña que los sistemas monolíticos.

H0e: Los sistemas multiagente mantienen una coherencia longitudinal igual o inferior a la de los sistemas monolíticos a lo largo de la campaña.

Ningún instrumento de CL-1 ni de CL-2 alcanzó la clasificación confirmatoria en la prueba de sensibilidad descrita en el apartado 3.4.3, por lo que no existe evidencia confirmatoria para rechazar o no rechazar H0e con el nivel de rigor exigido al resto de las hipótesis, y H1e se declara sin decisión confirmatoria, ausencia que se documenta como una limitación explícita de la dimensión longitudinal y que no se sustituye con evidencia exploratoria ni se resuelve por defecto a favor de alguna de las dos hipótesis.

4.3.6. Hipótesis H1f: mayor calidad narrativa emergente del sistema multiagente

H1f: Los sistemas multiagente producen una calidad narrativa emergente superior a la de los sistemas monolíticos.

H0f: Los sistemas multiagente producen una calidad narrativa emergente igual o inferior a la de los sistemas monolíticos.

Con las cinco filas confirmatorias condicionadas de persona2, el contraste en el sentido de H1f resulta significativo tras la corrección de Holm ($p < 0.0001$; r entre -0.98 y -1.00), por lo que se rechaza H0f y se acepta H1f, es decir, que G1 usurpa la agencia del jugador de

forma explícita en menos turnos que G2. Dado que la precisión del detector frente al evaluador externo de referencia fue de 33.3 % en conjunto, de 42.9 % en G1 y de 28.6 % en G2, se repitió el contraste tras multiplicar la tasa de cada campaña por la precisión estimada de su arquitectura: con las estimaciones puntuales, G1 se mantuvo por debajo de G2 en los 27 pares, y en el escenario más desfavorable para la hipótesis, que combina el límite superior del intervalo de G1 con el inferior del de G2, en 26 de los 27 pares (Wilcoxon unilateral, $p < 0.0001$ en ambos casos). En consecuencia, la aceptación de H1f es robusta en su dirección, aunque se refiere a la usurpación explícita que el detector capta y su magnitud real es menor que la reportada en la Tabla 8, y se mantiene condicionada a la calibración del instrumento, dado que no se alcanzó un acuerdo fiable entre los evaluadores humanos (apartados 5.3 y 5.6), mientras que la evidencia exploratoria de diversidad léxica, una vez controlada la longitud, resulta consistente con esta misma dirección.

4.3.7. Hipótesis general

Hg: Los sistemas multiagente producen campañas de Dungeons & Dragons con mayor coherencia narrativa que los sistemas monolíticos.

H0g: Los sistemas multiagente producen campañas de Dungeons & Dragons con una coherencia narrativa igual o inferior a la de los sistemas monolíticos.

Conforme al criterio establecido en el apartado 2.4, la hipótesis general se considera sostenida únicamente si se sostienen las tres hipótesis comparativas, H1d, H1e y H1f. En el corpus estudiado, H1d no se sostiene, dado que el único instrumento confirmatorio de la coherencia reactiva no favorece a G1 y su contraste bilateral muestra una diferencia pequeña a favor de G2; H1e queda sin decisión confirmatoria, puesto que ningún instrumento de la coherencia longitudinal alcanzó la clasificación confirmatoria; y H1f se acepta, condicionada a la calibración de persona2, puesto que G1 usurpa la agencia del jugador de forma explícita en menos turnos que G2, resultado robusto a la precisión estimada del detector.

En consecuencia, no se rechaza H0g y la hipótesis general no se sostiene en su forma general, por lo que la decisión se reporta desagregada por dimensión: con una memoria estructurada del estado del mundo común a ambas arquitecturas, la especialización de agentes no produjo una mayor coherencia reactiva ni una mayor coherencia longitudinal medibles, aunque sí redujo la frecuencia con la que el sistema decide, piensa, siente o habla en nombre del personaje jugador. De manera complementaria, el contraste de las hipótesis de degradación indica que el sistema monolítico no se degradó a lo largo de los 1,400 turnos en ninguna de las dimensiones con instrumentos confirmatorios, de modo que la comparación entre arquitecturas no se produjo frente a una línea base deteriorada, sino frente a un sistema monolítico estable.

V. **DISCUSIÓN DE LOS RESULTADOS**

5.1. Coherencia reactiva del sistema monolítico (OE-1)

Los valores descriptivos muestran que la fluidez de las respuestas del sistema monolítico no constituye un problema, dado que la gramaticalidad se mantiene en el techo de la escala y que los errores mecánicos, como narrar como éxito una tirada fallida, afectan a menos del 0.1 % de los turnos, resultado que contrasta con las dificultades para implementar mecánicas consistentes que RPGBench reporta en modelos que actúan como motores de juego (Yu et al., 2025) y que resulta coherente con el diseño de DM-IA, en el que la tirada se resuelve fuera del modelo antes de la narración. Del mismo modo, el arraigo de las respuestas a la acción del jugador, medido por el único instrumento confirmatorio de la dimensión, presenta una dispersión reducida entre campañas, con un coeficiente de variación cercano al 10 %, lo que indica que el comportamiento reactivo del sistema monolítico es estable con independencia del escenario, del tono y del personaje jugador, en línea con la mejora que la información explícita sobre el estado del juego produce en la generación de turnos de D&D (Callison-Burch et al., 2022; Zhu et al., 2023). En cambio, el indicador exploratorio de nombres no reconocidos, cuya cola alcanza el 24.23 % de los turnos, no permite todavía distinguir los nombres inventados de los personajes introducidos legítimamente por el sistema, por lo que no se interpreta como evidencia de alucinación sin la depuración que se describe a continuación.

Cierre de la brecha metodológica identificada

La brecha abordada en este apartado se identificó al constatar que el indicador exploratorio de nombre no reconocido se reportaba sin distinguir los nombres efectivamente inventados de los personajes legítimos introducidos por el propio sistema. En lugar de una muestra manual, se realizó una auditoría censal y determinista: las 9,629 marcas del indicador en las 54 campañas, reproducidas exactamente, se clasificaron contra la propia base de datos según la palabra

perteneciera a una entidad registrada después de su aparición, a un objeto registrado fuera de la ventana de vigencia, al vocabulario del escenario inicial, a una palabra común escrita con mayúscula, a una entidad recurrente nunca registrada o a una mención efímera. En G2, el 57.7 % de las marcas correspondió a palabras comunes, el 19.5 % a entidades que el sistema introdujo y registró después, y solo el 10.2 % a menciones efímeras candidatas a invención. A nivel de turno, el 15.1 % de los turnos marcados contenía una candidata a invención, proporción que osciló entre 9.4 % y 26.7 % en doce combinaciones de los umbrales de clasificación, de modo que la tasa bruta del indicador sobrestima la invención de nombres entre cuatro y once veces. Estas cifras deben leerse como un límite superior, ya que la categoría efímera conserva falsos positivos residuales, como expresiones idiomáticas. En términos comparativos, y con carácter exploratorio, la proporción de turnos con candidatas a invención fue menor en G1 en las doce combinaciones (con los umbrales de referencia, mediana de 0.29 % frente a 0.93 %; Wilcoxon bilateral, $p = 0.019$). La brecha se considera cerrada en su alcance: el indicador se mantiene como exploratorio, y su cifra bruta no debe usarse como evidencia de alucinación sin esta depuración.

5.2. Coherencia longitudinal del sistema monolítico (OE-2)

La dimensión longitudinal es la que presenta mayor heterogeneidad entre campañas, con coeficientes de variación elevados y desviaciones marcadas de la normalidad en la mayoría de sus instrumentos, rasgo coherente con la naturaleza acumulativa de los fallos que mide, cuya aparición depende en parte de decisiones narrativas propias de cada campaña, como la muerte o la desaparición de un personaje. Asimismo, los valores bajos de coherencia de entidad reproducen el patrón que Papalampidi et al. (2022) observaron en modelos sin memoria dinámica de entidades, los cuales tienden a abandonar a los protagonistas y a introducir entidades nuevas conforme el texto se extiende, si bien en DM-IA dicho abandono puede responder también a la propia dinámica del

juego, en la que el jugador se desplaza entre lugares y personajes, de modo que no todo abandono de una entidad constituye un error de continuidad.

Cierre de la brecha metodológica identificada

La brecha abordada en este apartado se identificó durante el análisis de OE-2, al constatar que el recuerdo de cambios de estado de Jericho-QA, el instrumento más cercano a medir de forma directa la preservación del estado del mundo, se estaba reportando sin haber sido sometido a la prueba de sensibilidad exigida a los demás instrumentos, carencia que reproducía en el propio estudio la brecha que la literatura señala en la evaluación de narrativas co-creadas con inteligencia artificial, esto es, la ausencia de marcos que verifiquen si un instrumento automático mide el constructo que declara medir antes de tratarlo como evidencia (Valdivia & Burelli, 2025).

Para cerrarla, se diseñó y ejecutó una prueba de sensibilidad sobre el recuerdo de Jericho-QA y sobre el indicador complementario de relojes de facción reconocidos, inyectando perturbaciones sintéticas de dirección conocida, a saber, la inserción y la supresión del término que denota el evento real, sobre 40 cambios de estado evaluables y 16 relojes del corpus, con las expectativas fijadas mediante un resumen criptográfico antes de la ejecución y conforme al mismo protocolo aplicado a los demás instrumentos. Dado que la prueba obtuvo un 100 % de confirmaciones en las cuatro perturbaciones (JQ1 40/40, JQ2 40/40, RJ1 7/7 y RJ2 16/16), resultado esperable casi por construcción, puesto que la perturbación inserta o suprime el mismo término que el instrumento busca, se complementó con un diagnóstico adicional que comparó la tasa de reconocimiento real con la que produce el mismo vocabulario sobre una ventana de turnos elegida al azar, con 20 réplicas por evento y semilla fija.

Este diagnóstico mostró que Jericho-QA discrimina por encima del azar únicamente en los cambios de condición de los personajes (30–32 % frente a 7–9 %), mientras que en los cambios de afinidad, que concentran el 55 % de los eventos evaluables, la diferencia es

marginal (21 % frente a 17–19 %), y que el indicador de relojes reconocidos resulta prácticamente indistinguible del azar (88.3 % frente a 89.8 %), en buena medida porque su vocabulario incluye palabras funcionales de alta frecuencia presentes en cualquier turno. En consecuencia, Jericho-QA se mantiene como exploratorio, con la salvedad de que su poder de discriminación se concentra en la condición de los personajes, y el indicador de relojes se reclasifica como descriptivo, de modo que la brecha queda cerrada en el sentido de que ningún instrumento de la dimensión permanece sin someterse a la prueba de sensibilidad, aunque el resultado de dicha prueba impide promover a Jericho-QA a confirmatorio y se documenta como un hallazgo metodológico.

5.3. Calidad narrativa emergente del sistema monolítico (OE-3)

A diferencia de las dimensiones reactiva y longitudinal, varios instrumentos de QN-1, como la legibilidad, carecen de un sentido de mejora definido, dado que una legibilidad más alta no implica una mejor narrativa, y las medidas de diversidad léxica solo aproximan la ausencia de repetición, tal como advierten Li et al. (2016) al emplearlas siempre junto con la evaluación humana, de manera que el interés y la creatividad del relato, que RPGBench identifica como la dimensión con menor concordancia entre la evaluación automática y la humana (Yu et al., 2025), permanecen sin una medición directa en este estudio. Por el contrario, la usurpación de la agencia admite una lectura de calidad inequívoca, dado que una tasa menor implica un mayor respeto por las decisiones del jugador, y su mediana de 3.47 % de los turnos resulta relevante si se considera que la toma del control del personaje fue el fallo que los evaluadores de FIREBALL señalaron con mayor frecuencia (Zhu et al., 2023), aunque, como se muestra en el cierre de brecha de este objetivo, esta cifra corresponde a las marcas del detector y sobrestima la frecuencia real de la usurpación explícita.

Cierre de la brecha metodológica identificada

La brecha abordada en este apartado se identificó al constatar que persona2, el único instrumento de QN-2 y el que sostiene las decisiones sobre H1c y H1f, había superado la prueba de sensibilidad pero no contaba con una medida de su concordancia con el juicio humano, requisito habitual en la validación de instrumentos de codificación automática, sin el cual no es posible establecer si el detector mide la usurpación de la agencia con la fidelidad necesaria para sostener una hipótesis confirmatoria (González-Romero et al., 2021).

Para cerrarla, se construyó una sonda estratificada de 515 turnos y un formulario de etiquetado ciego basado en el libro de códigos del propio instrumento, que registra el veredicto, la tipología de la violación y si esta ocurre tras una tirada, y se ejecutó una primera pasada de etiquetado sin conocer el veredicto del detector, la cual arrojó una precisión de 25.6 % (IC 95 % 20.2–31.8 %) y una exhaustividad de 67.9 % (IC 95 % 57.1–77.1 %), con la cognición como la categoría más fiable del detector (56.7 % de acierto) y el habla como la más problemática (4.3 %), debido principalmente a diálogos de personajes no jugadores confundidos con habla no declarada del personaje jugador. Dado que esta pasada se ejecutó con asistencia de un sistema de inteligencia artificial, se documenta como tal y se trata como una estimación preliminar, y no como la evaluación humana que exige el diseño.

Para completar el cierre, tres directores de juego externos al equipo investigador etiquetaron de forma ciega la submuestra estratificada del 20 % de la sonda (102 ítems), sin acceso al veredicto del detector. El acuerdo entre ellos fue nulo (kappa de Fleiss = −0.09), por lo que se aplicó el mismo criterio de calidad empleado en la validación del detector de personajes no jugadores inactivos. Bajo ese criterio, un evaluador respondió «no viola» en la totalidad de los ítems y otro presentó signos de respuesta apresurada (mediana de 9 segundos por ítem, con 33 ítems resueltos en cinco segundos o menos, y un

acuerdo con el tercer evaluador inferior al azar). Frente al único evaluador con un registro consistente (mediana de 47 segundos por ítem), la precisión del detector fue de 33.3 % (IC 95 % de Wilson 21.0–48.4 %), del mismo orden que la estimación de la pasada asistida (25.6 %). Además, en los turnos de la sonda tomados al azar, donde el detector no se activó en ningún caso, ese evaluador identificó usurpación mental o verbal en el 7.7 % de los turnos, lo que indica que persona2 capta solo la forma explícita de la usurpación, aquella en que la narración atribuye al personaje jugador verbos de pensamiento, emoción, decisión o habla en segunda persona, y que su exhaustividad sobre el corpus es baja, aunque esta estimación es imprecisa por el tamaño de la sonda. En consecuencia, persona2 se reinterpreta como un detector de usurpación explícita y, dado que no se alcanzó un acuerdo fiable entre evaluadores humanos, la brecha se considera avanzada pero no cerrada, y el instrumento se mantiene como confirmatorio condicionado.

5.4. Comparación de la coherencia reactiva (OE-4)

La coherencia reactiva es la única dimensión en la que la evidencia confirmatoria y la exploratoria apuntan en direcciones opuestas dentro de un mismo constructo, dado que la respuesta a la acción específica normalizada en z favorece a G2, mientras que el solapamiento sin normalizar, el anclaje al escenario y el anclaje sin nombres propios favorecen a G1 con efectos grandes. Esta discordancia sugiere un límite de validez de constructo antes que una superioridad clara de alguna arquitectura, puesto que la normalización controla factores como la longitud del turno, que en G1 es mayor (158 frente a 116 palabras de mediana), cuestión que se examina en el cierre de brecha de este objetivo. Desde la perspectiva de los antecedentes, el resultado matiza la expectativa derivada de Zhou et al. (2023), según la cual descomponer explícitamente las decisiones del director de juego mejora la adecuación de sus intervenciones, y resulta compatible con la advertencia de Cemri et al. (2025) sobre las ganancias limitadas de los sistemas multiagente

frente a un solo agente, en particular cuando, como en este estudio, ambas arquitecturas disponen de la misma información sobre el estado del juego (Callison-Burch et al., 2022).

Cierre de la brecha metodológica identificada

La brecha abordada en este apartado se identificó al constatar que la versión normalizada de la respuesta a la acción favorecía a G2, mientras que sus tres versiones crudas favorecían a G1. Para resolverla, cada versión se descompuso en un componente específico y uno genérico. En la respuesta a la acción, la puntuación cruda equivale a la media de un nulo, formado por la misma respuesta emparejada con acciones de otros turnos, más la puntuación z por la dispersión de ese nulo. Sobre 75,588 turnos computables, la ventaja cruda de G1 (+0.009 de mediana por par) se explicó casi por completo por la media del nulo (+0.009; G1 mayor en los 27 pares): sus respuestas, más extensas (16 lemas de contenido más por turno), comparten más vocabulario con cualquier acción del jugador, mientras que el exceso específico no difirió entre arquitecturas (Wilcoxon bilateral, $p = 0.59$). En el anclaje al escenario, el coseno de cada ventana con el escenario propio se contrastó con su coseno frente a los otros 26 escenarios; en este caso, la ventaja de G1 sí resultó específica de su escenario (exceso de 0.100 frente a 0.029; $p < 0.001$), pero se concentró en los nombres propios, ya que al excluirlos la diferencia se redujo a 0.005 ($p = 0.034$). En consecuencia, se adopta como criterio explícito de validez de constructo que el arraigo contextual de la Rúbrica D&D-IA se refiere a la respuesta a la acción específica del jugador, bajo el cual la versión normalizada es la válida para CR-2; la versión cruda de la respuesta a la acción queda como descriptiva, porque mezcla lo específico con lo genérico, y las de anclaje describen una faceta distinta, el anclaje al mundo del escenario, en la que G1 menciona con más frecuencia los nombres propios de su escenario. La discordancia queda así explicada: ninguna arquitectura responde mejor a la acción específica del jugador, y G1 nombra más su propio mundo, resultado compatible con un diseño en el que cada personaje no jugador es interpretado a partir de su propia ficha.

5.5. Comparación de la coherencia longitudinal (OE-5)

La coherencia longitudinal presenta el panorama más simétrico de las tres dimensiones comparativas, dado que la coherencia de entidad favorece a G1 ($p = 0.0170$; $r = +0.54$), la mención sin refinar de personajes no jugadores inactivos favorece a G2 ($p = 0.0315$) y ninguno de estos instrumentos alcanza el estatus confirmatorio necesario para decidir H1e. La ventaja de G1 en la coherencia de entidad resulta consistente con el hallazgo de Papalampidi et al. (2022), según el cual una memoria dedicada a las entidades mejora su continuidad a lo largo del relato, función que en G1 cumple el actor de personajes no jugadores al recibir únicamente lo que cada personaje conoce; en cambio, la desaparición de la significancia del indicador de personajes inactivos al exigir que el personaje sea sujeto gramatical de la oración sugiere que buena parte del efecto sin refinar corresponde a referencias retrospectivas legítimas, como el recuerdo de un personaje ausente, y no a errores de continuidad, interpretación que la validación humana descrita en el apartado 5.5 permite examinar. Por esta razón, se decidió no promover el indicador sin refinar a confirmatorio condicionado pese a su paralelismo con persona2, dado que dicha promoción habría constituido una decisión a conveniencia no respaldada por el propio refinamiento del instrumento.

Cierre de la brecha metodológica identificada

La brecha abordada en este apartado se identificó en la docimasia de H1e, al constatar que ningún instrumento de la dimensión longitudinal había alcanzado la clasificación confirmatoria, de modo que la hipótesis no podía decidirse con el rigor exigido a las demás, situación que motivó la recomendación de desarrollar o validar un instrumento confirmatorio para CL-1 y CL-2.

Para cerrarla, se siguieron tres líneas de evidencia independientes, la primera de las cuales es la prueba de sensibilidad de Jericho-QA y de los relojes reconocidos descrita en el apartado 5.2, cuyo resultado no permite promover ningún instrumento de CL-2 a confirmatorio, mientras que la segunda, no contemplada en la recomendación

original, es un análisis de supervivencia sobre el turno de la primera mención narrada de un personaje no jugador inactivo como si actuara, con censura en el turno 1,400 para las campañas en que el evento no ocurre, en el que se estimó la función de supervivencia de cada brazo mediante el método de Kaplan-Meier (Kaplan & Meier, 1958) y se contrastaron ambos brazos mediante la prueba de rangos logarítmicos (Mantel, 1966), tras verificar que la implementación reproducía de forma exacta el estadístico publicado para el conjunto de datos de referencia de Freireich et al. (1963).

El análisis mostró que G1 tarda más que G2 en mencionar por primera vez a un personaje no vivo como si actuara (mediana de 1,139 frente a 891 turnos, con 16 eventos y 11 censuras en cada brazo), pero la diferencia no alcanzó significancia ni en el conjunto de los 27 pares ($\chi^2 = 0.084$, $p = 0.772$) ni al desagregar por lote según la versión del motor (pares 1 a 17: $p = 0.726$; pares 18 a 27: $p = 0.409$). Cabe precisar que la prueba trata ambos brazos como muestras independientes, sin aprovechar el emparejamiento por escenario, por lo que una versión estratificada por par constituye un refinamiento posible.

Como tercera línea de evidencia, se construyó un instrumento semántico basado en representaciones vectoriales de oraciones (bge-m3, 457,613 oraciones indexadas en una capa de medición añadida sobre el corpus ya generado), cuya primera versión no superó el control de sensibilidad por responder a la sola mención del nombre de la entidad. La segunda versión, que restringe la comparación a oraciones que mencionan a la entidad, sí superó las cuatro perturbaciones de la prueba de sensibilidad, pero mostró que, una vez controlada la mención, la similitud semántica apenas detecta los cambios de estado (recuerdo de 0.08 frente a una tasa de azar de 0.05). Una variante que construye el nulo solo con ventanas anteriores al evento, para evitar que las narraciones posteriores del estado ya cambiado elevaran el umbral, apenas modificó el resultado (0.115 frente a 0.089 en los 529 eventos evaluables por ambas). En consecuencia, tampoco esta vía produjo un instrumento confirmatorio

para la coherencia longitudinal, y el resultado refuerza la conveniencia de un clasificador de inferencia en lenguaje natural en español como trabajo futuro. En conjunto, las tres líneas de evidencia cierran la brecha en el sentido de que no queda, con los datos disponibles, ningún candidato adicional por evaluar, aunque su resultado sustantivo es negativo y refuerza, en lugar de revertir, la ausencia de un instrumento confirmatorio para decidir H1e.

Cierre de la brecha de validación humana del detector de personajes inactivos

Esta brecha se identificó al analizar la discordancia entre las dos versiones del detector de personajes no jugadores inactivos, dado que la versión sin refinar favorecía a G2 con significancia ($p = 0.0315$), mientras que la versión refinada, que exige que el personaje sea sujeto gramatical de la oración, perdía toda significancia ($p = 0.4375$), sin que existiera una referencia externa para determinar cuál de las dos distinguía correctamente entre un personaje narrado como activo, que constituye un error de continuidad, y uno mencionado de forma retrospectiva, que es narrativamente legítimo. En otras palabras, tanto este detector como el recuerdo de Jericho-QA carecían de una verdad de referencia humana, y su validación no podía realizarla el propio equipo investigador sin incurrir en un sesgo, real o percibido, de juez y parte; asimismo, se evaluó como alternativa un clasificador automático basado en un modelo de lenguaje pequeño, cuyo piloto sobre ocho casos no permitió distinguir su desempeño del azar, por lo que se descartó.

Para cerrarla, se extrajo del corpus una muestra estratificada de 60 turnos según la salida de los instrumentos, esto es, turnos en los que el detector señalaba al personaje como activo, turnos en los que solo lo registraba como referido y turnos en los que Jericho-QA no reconocía ningún cambio, muestra que resultó en 59 casos únicos debido a un ítem que la herramienta de etiquetado presentó dos veces, lo que se detectó porque los tres evaluadores respondieron de forma idéntica en ambas apariciones. Tres evaluadores voluntarios

externos al equipo investigador etiquetaron de forma ciega cada caso en tres categorías, según si la narración trataba al personaje como activo, lo mencionaba de forma retrospectiva o el caso no aplicaba, y el acuerdo se estimó mediante el kappa de Fleiss para los tres evaluadores (Fleiss, 1971) y mediante el kappa de Cohen y el coeficiente AC1 de Gwet para cada par, sobre la distinción binaria entre activo y no activo (Cohen, 1960; Gwet, 2008).

Como se observa en la Tabla 12, el acuerdo global resultó bajo (κ de Fleiss = 0.138), aunque no de forma homogénea, dado que el par E1–E3 alcanzó un acuerdo moderado (79.7 %; κ = 0.595; AC1 = 0.593), mientras que los dos pares que incluyen a E2 se situaron en niveles cercanos o inferiores al azar (κ = 0.051 y −0.020). El registro de E2 mostró, además, signos de respuesta apresurada, con una mediana de 12 segundos por caso frente a 60 y 38 segundos de E1 y E3, 35 de sus 58 respuestas emitidas en menos de 15 segundos, una concentración de veredictos en la categoría retrospectiva (69 % frente a 44 % y 34 %) y un caso sin responder, por lo que se excluyó y el acuerdo se reporta con el par E1–E3, cuyo valor se aproxima, aunque sin alcanzarlo, al precedente de κ = 0.671 que Chen et al. (2023) reportaron para la evaluación de la consistencia de la persona.

Frente al veredicto humano mayoritario, en los 34 casos de los estratos de actuación y de referencia con una mayoría clara, el detector refinado obtuvo una precisión de 62.5 % (IC 95 % de Wilson 38.6–81.5 %) y una exhaustividad de 40.0 % (IC 95 % 23.4–59.3 %), con 10 verdaderos positivos, 6 falsos positivos, 3 verdaderos negativos y 15 falsos negativos, mientras que, en el estrato de silencio de Jericho-QA, los evaluadores confirmaron la ausencia de error en 18 de 20 casos y detectaron 2 falsos negativos. En consecuencia, la brecha queda cerrada, dado que el detector cuenta ahora con una estimación de su desempeño frente a un juicio humano externo y ciego, cuyo resultado indica que el detector refinado es relativamente

preciso cuando señala un error, pero omite la mayoría de los errores reales, por lo que se mantiene como exploratorio y H1e permanece sin decisión confirmatoria; cabe precisar, además, que Jericho-QA valida si la transición de estado se narró, mientras que el detector valida si una mención posterior trata al personaje como activo, de modo que ambos instrumentos miden constructos relacionados pero no idénticos.

Tabla 12. Acuerdo entre evaluadores en la validación humana del detector de personajes inactivos.

Comparación	n común	% de acuerdo	κ de Cohen	AC1 de Gwet
E1–E2	58	51.7 %	0.051	0.088
E1–E3	59	79.7 %	0.595	0.593
E2–E3	58	51.7 %	−0.020	0.119
E1–E2–E3 (κ de Fleiss)	59	—	0.138	—

Nota. Elaboración propia. El kappa de Cohen y el AC1 se calculan sobre la distinción binaria entre activo y no activo, mientras que el kappa de Fleiss considera las tres categorías; E2 se excluyó por los criterios descritos en el texto.

5.6. Comparación de la calidad narrativa emergente (OE-6)

La calidad narrativa emergente es la única dimensión comparativa con un bloque de instrumentos confirmatorios consistente, dado que persona2 mide directamente el principio central de QN-2, esto es, que las decisiones del jugador no sean usurpadas por el sistema, y favorece a G1 en las cinco categorías con un efecto de magnitud casi máxima. Este resultado concuerda con los antecedentes que vinculan la gestión explícita de los personajes con la agencia del jugador, como la gestión de la experiencia de Ware et al. (2023), que al no suprimir nunca las acciones del jugador obtuvo una mayor percepción de agencia, y con el hallazgo de FIREBALL, cuyos evaluadores identificaron la toma del control del personaje como el fallo más frecuente (Zhu et al., 2023), de modo que la separación entre el actor de los personajes no jugadores y el narrador en G1 parece reducir precisamente ese fallo. Por su parte, la diversidad léxica ilustra el valor de haber controlado la longitud del turno antes de interpretar los resultados, puesto que la ventaja inicial de G2 en TTR y en repetición de bigramas se invierte al calcularlos sobre las primeras 100 palabras,

y la diferencia remanente, aunque detectable, es pequeña (0.002 en TTR y 0.0014 en bigramas) y favorece a G1.

Dado que el sistema multiagente realiza más llamadas al modelo por turno, cabe la objeción de que su ventaja en la agencia del jugador provenga del mayor cómputo y no de su estructura. Aunque no se registraron los tokens consumidos, las bitácoras conservan la latencia de cada llamada, lo que permitió estimar el costo en los pares 7 a 27: del lado del director de juego, G1 realizó 2.86 llamadas por turno frente a una en G2, empleó 2.6 veces más tiempo de modelo y produjo narraciones 1.5 veces más extensas, patrón que se repite en los pares 1 a 6. Sin embargo, dentro de cada arquitectura, las campañas con más cómputo o más texto por turno presentaron una mayor tasa de usurpación (Spearman ρ entre +0.50 y +0.74), es decir, la relación opuesta a la que exigiría la objeción, y G1 usurpó la agencia en menos turnos pese a narrar textos más extensos, en los que el detector tiene más oportunidades de activarse. Esta evidencia no permite separar por completo la estructura del presupuesto, por lo que la ventaja se atribuye al sistema multiagente como conjunto, y su contraste con una línea base monolítica dotada del mismo presupuesto de llamadas queda como trabajo futuro.

Cierre de la brecha metodológica identificada

La brecha abordada en este apartado se distingue de la de OE-3: no basta con que la precisión de persona2 sea conocida, sino que debe verificarse que no difiera entre arquitecturas al punto de fabricar la ventaja de G1. Frente al evaluador externo con registro consistente, la precisión del detector fue de 42.9 % en G1 (IC 95 % de Wilson 21.4–67.4 %) y de 28.6 % en G2 (15.3–47.1 %), es decir, el detector produce proporcionalmente más falsos positivos en G2, lo que podría inflar la diferencia. Para estimar ese efecto, la tasa de cada campaña se multiplicó por la precisión estimada de su arquitectura y se repitió el contraste pareado. Con las estimaciones puntuales, G1 se mantuvo por debajo de G2 en los 27 pares (medianas de 0.07 % frente a 0.99 % de los turnos), y en el escenario más desfavorable para la hipótesis,

que combina el límite superior de G1 con el inferior de G2, G1 se mantuvo por debajo en 26 de 27 pares (0.11 % frente a 0.53 %; Wilcoxon unilateral, $p < 0.0001$ en ambos casos). Por tanto, la dirección de H1f es robusta al sesgo diferencial del detector, pero la magnitud reportada sobrestima la usurpación explícita real, que en G2 se sitúa entre 0.5 % y 1 % de los turnos. La sonda aleatoria, con unos veinte turnos por arquitectura, no permite contrastar la dirección con juicio humano directo (evaluador de referencia: 9.5 % en G1 frente a 5.6 % en G2, con intervalos superpuestos), por lo que H1f se mantiene aceptada en su dirección y referida a la usurpación explícita que el detector capta, condicionada a la calibración del instrumento.

CONCLUSIONES

El corpus de 27 pares, medido mediante la batería de instrumentos deterministas descrita en el Capítulo III, arroja un patrón claro en el nivel del sistema monolítico y no uniforme en la comparación entre arquitecturas. En cuanto a los objetivos de evaluación, el sistema monolítico sostiene una coherencia reactiva estable, una coherencia longitudinal heterogénea entre campañas y una calidad narrativa emergente con una usurpación explícita de la agencia marcada por el detector en el 3.47 % de los turnos en mediana, sin que ninguna de estas dimensiones se degrade a lo largo de los 1,400 turnos, dado que no se rechazan H0a ni H0c y que H1b, sin instrumento confirmatorio, tampoco muestra degradación en su evidencia exploratoria una vez corregida la confusión por exposición, en tanto que el análisis exploratorio del último tramo de 100 turnos tampoco reveló un punto de quiebre al final de la campaña. Este resultado matiza la premisa de que la coherencia de un director de juego basado en un solo modelo se degrada conforme la campaña se extiende (Liu et al., 2024; Gallotta et al., 2024), y sugiere que un registro estructurado del estado del mundo, compartido por ambas arquitecturas, contrarresta dicha degradación dentro de la extensión estudiada, en línea con los antecedentes que atribuyen a la información explícita del estado una mejora de la generación (Callison-Burch et al., 2022; Farrell & Ware, 2025).

En cuanto a los objetivos de comparación, en la coherencia reactiva el único instrumento confirmatorio favorece ligeramente a G2, mientras que las versiones exploratorias del mismo constructo favorecen a G1 por un componente genérico asociado a la mayor extensión de sus respuestas, de modo que no se rechaza H0d y ninguna arquitectura responde mejor a la acción específica del jugador; en la coherencia longitudinal ningún instrumento alcanzó la clasificación confirmatoria, de modo que H1e queda sin decisión confirmatoria, conclusión que refuerzan el análisis de supervivencia, el instrumento semántico basado en representaciones vectoriales y la validación humana externa del detector de personajes inactivos; y en la calidad narrativa

emergente persona2 favorece a G1 de forma unánime y con un efecto casi máximo, por lo que se acepta H1f, referida a la usurpación explícita de la agencia que el detector capta, resultado que se mantiene al corregir la tasa de cada arquitectura por la precisión estimada por un evaluador externo, aunque condicionado a la calibración del instrumento.

En consecuencia, conforme al criterio establecido en el apartado 2.4, la hipótesis general no se sostiene en su forma general, puesto que solo una de las tres hipótesis comparativas se sostiene, y la evidencia de este corpus indica, en lugar de una superioridad uniforme del sistema multiagente, una ventaja específica en el respeto a la agencia del jugador, dimensión en la que la separación de roles se traduce en un beneficio medible, junto con la ausencia de una ventaja demostrable en la coherencia reactiva y en la longitudinal cuando ambas arquitecturas comparten el mismo modelo y la misma información del estado, resultado que concuerda con la advertencia de Cemri et al. (2025) sobre los beneficios limitados de los sistemas multiagente y que orienta la especialización hacia los componentes en los que efectivamente aporta, considerando, además, que la arquitectura multiagente requirió entre dos y tres veces más cómputo por turno del lado del director de juego, sin que ese mayor cómputo explique por sí solo su ventaja en la agencia del jugador.

Coherencia reactiva del sistema monolítico (OE-1)

Sobre las 27 campañas del corpus, el sistema monolítico exhibe una coherencia reactiva estable, con una gramaticalidad cercana al techo de la escala, errores mecánicos marginales y un arraigo contextual de magnitud consistente entre campañas (Mdn = 2.81, RIQ = 0.40), el cual, además, no se degrada a lo largo de la campaña, puesto que no se rechaza H0a (Page, p = 0.310); por consiguiente, dentro de la extensión estudiada de 1,400 turnos, la coherencia reactiva del sistema monolítico no se ve afectada por la acumulación de la historia, resultado cuyo significado comparativo se examina en OE-4; asimismo, la auditoría censal del indicador de nombres no

reconocidos mostró que su tasa bruta sobrestima entre cuatro y once veces la invención de nombres, por lo que no constituye evidencia de alucinación sin depuración.

Coherencia longitudinal del sistema monolítico (OE-2)

Sobre las 27 campañas del corpus, la coherencia longitudinal del sistema monolítico es la dimensión de mayor variabilidad entre campañas, con al menos un caso de abandono total de las entidades iniciales y un recuerdo bajo de los cambios de estado narrados; no obstante, H1b queda sin decisión confirmatoria por la ausencia de instrumentos confirmatorios en la dimensión, y la evidencia exploratoria, una vez corregida la confusión por exposición, no muestra una degradación a lo largo de la campaña, mientras que la prueba de sensibilidad de Jericho-QA indicó que este instrumento solo discrimina por encima del azar en los cambios de condición de los personajes.

Calidad narrativa emergente del sistema monolítico (OE-3)

Sobre las 27 campañas del corpus, el sistema monolítico mantiene una diversidad léxica estable una vez controlada la longitud del turno (MTLD, Mdn = 108.9; MATTR, Mdn = 0.828), una legibilidad en la banda normal según dos fórmulas convergentes pero no independientes y una tasa de usurpación de la agencia de 3.47 % de los turnos en mediana, sin que ninguna de estas propiedades se degrade a lo largo de la campaña, puesto que no se rechaza H0c, si bien persona2 capta solo la forma explícita de la usurpación y, con una precisión de 33.3 % frente al evaluador externo de referencia, la cifra de 3.47 % sobrestima su frecuencia real.

Comparación de la coherencia reactiva (OE-4)

La coherencia reactiva es la única dimensión comparativa en la que la evidencia confirmatoria contradice a la exploratoria dentro del mismo constructo, dado que el instrumento confirmatorio favorece a G2 (p bilateral = 0.0319; r = −0.47), mientras que las tres versiones exploratorias del arraigo contextual favorecen a G1

con efectos grandes (r entre +0.62 y +0.84); no obstante, la descomposición de las versiones crudas mostró que la ventaja de G1 en ellas es genérica, asociada a respuestas más extensas, y que el componente específico de la respuesta a la acción no difiere entre arquitecturas; en consecuencia, no se rechaza H0d y H1d no se sostiene con la evidencia confirmatoria de este corpus.

Comparación de la coherencia longitudinal (OE-5)

La coherencia longitudinal es la única dimensión comparativa sin un instrumento confirmatorio para decidir su hipótesis, por lo que H1e queda sin decisión confirmatoria en este corpus, con una evidencia exploratoria mixta, dado que la coherencia de entidad favorece a G1 ($p = 0.0170$) y la mención sin refinar de personajes inactivos favorece a G2 ($p = 0.0315$), efecto que desaparece en su versión refinada ($p = 0.4375$); asimismo, el análisis de supervivencia, el instrumento semántico basado en representaciones vectoriales y la validación humana del detector de personajes inactivos, descritos en los cierres de brecha de este objetivo, refuerzan la ausencia de una diferencia detectable entre arquitecturas.

Comparación de la calidad narrativa emergente (OE-6)

De las tres hipótesis comparativas, H1f es la única sostenida por un bloque de instrumentos confirmatorios, dado que persona2 favorece a G1 en las cinco categorías medidas con el tamaño de efecto máximo observable en un diseño pareado, mientras que la diversidad léxica, corregida por la longitud del turno, es consistente con esa dirección aunque con una magnitud pequeña; en consecuencia, se acepta H1f, referida a la usurpación explícita de la agencia, resultado robusto a la precisión diferencial del detector entre arquitecturas, aunque con una magnitud real menor que la reportada, y que no se explica por el mayor cómputo de G1, dado que dentro de cada arquitectura un mayor cómputo se asoció con más usurpación y no con menos.

RECOMENDACIONES

En el plano metodológico inmediato, se recomienda refinar el libro de códigos de persona2 y realizar una sesión de calibración previa con un número mayor de evaluadores externos, con el fin de alcanzar un acuerdo fiable entre evaluadores humanos que permita promoverlo a confirmatorio pleno, dado que es el instrumento que sostiene la única hipótesis comparativa aceptada; asimismo, se recomienda documentar en la ficha de instrumentos el criterio de validez de constructo adoptado para el arraigo contextual, según el cual CR-2 se mide mediante la versión normalizada de la respuesta a la acción, y desarrollar un instrumento confirmatorio para la coherencia longitudinal, para lo cual resultan candidatos un clasificador de inferencia en lenguaje natural entrenado para el español y una prueba de rangos logarítmicos estratificada por par, dado que ni Jericho-QA ni el instrumento semántico basado en representaciones vectoriales alcanzaron esa clasificación.

En el plano de las investigaciones futuras, se recomienda extender las campañas más allá de 1,400 turnos, con el fin de verificar si la ausencia de degradación observada se mantiene en horizontes más largos, en particular respecto de la usurpación de la agencia, cuya tendencia se aproximó a la significancia, y de la respuesta a la acción del sistema monolítico, que alcanzó su valor mínimo en el último tramo de 100 turnos sin que la diferencia resultara significativa; contrastar la arquitectura multiagente con una línea base monolítica dotada del mismo presupuesto de llamadas al modelo y registrar los tokens consumidos, con el fin de separar el efecto de la estructura del efecto del cómputo; replicar el experimento con otros modelos de lenguaje y en otros idiomas, con el propósito de establecer si la ventaja de la arquitectura multiagente en la agencia del jugador depende del modelo empleado; e incorporar jugadores humanos que permitan evaluar el interés y la creatividad del relato, dimensión que los instrumentos deterministas solo aproximan, así como el aplanamiento estilístico sugerido por la observación de uno de los

evaluadores voluntarios sobre el carácter formulaico de las escenas de muerte.

Coherencia reactiva del sistema monolítico (OE-1)

Se recomienda aplicar la depuración de la auditoría censal antes de emplear el indicador de nombre no reconocido como evidencia de alucinación, y complementar la categoría de menciones efímeras con una revisión humana externa que elimine los falsos positivos residuales, como las expresiones idiomáticas.

Coherencia longitudinal del sistema monolítico (OE-2)

Se recomienda investigar la causa del caso de coherencia de entidad igual a cero mediante la lectura directa de la transcripción correspondiente y ampliar el vocabulario de Jericho-QA más allá de los cambios de condición de los personajes, dado que la prueba de sensibilidad mostró que solo en ellos discrimina por encima del azar.

Calidad narrativa emergente del sistema monolítico (OE-3)

Se recomienda extender persona2 a las formas implícitas de usurpación de la agencia, dado que la sonda aleatoria indicó que el detector solo capta la forma explícita y que su exhaustividad sobre el corpus es baja, y estimar su exhaustividad con una sonda aleatoria de mayor tamaño etiquetada por evaluadores externos calibrados.

Comparación de la coherencia reactiva (OE-4)

Se recomienda mantener la versión normalizada como medida de CR-2, conforme al criterio de validez de constructo adoptado, y reportar el anclaje al escenario como una faceta distinta, el anclaje al mundo del escenario, controlando en ambos casos la extensión de las respuestas de cada arquitectura.

Comparación de la coherencia longitudinal (OE-5)

Se recomienda priorizar, para una futura extensión de la investigación, el desarrollo o la validación de un instrumento confirmatorio dedicado a CL-1 y CL-2, cuyo candidato más cercano es un clasificador de inferencia en lenguaje natural en español con su

propia prueba de sensibilidad, dado que es la única de las tres dimensiones de la Rúbrica D&D-IA sin evidencia confirmatoria en el corpus actual.

Comparación de la calidad narrativa emergente (OE-6)

Se recomienda contrastar la ventaja de G1 en la agencia del jugador con una línea base monolítica de presupuesto equivalente y con jugadores humanos, así como recalibrar la magnitud del efecto con una estimación de la precisión de persona2 basada en un acuerdo fiable entre evaluadores.

REFERENCIAS BIBLIOGRÁFICAS

Amato, F., Moscato, F., & Xhafa, F. (2019). Generation of game contents by social media analysis and MAS planning. *Computers in Human Behavior, 100*, 286–294. https://doi.org/10.1016/j.chb.2019.02.030

Ammanabrolu, P., Cheung, W., Tu, D., Broniec, W., & Riedl, M. O. (2020). Bringing stories alive: Generating interactive fiction worlds. *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment, 16*(1), 3–9. https://doi.org/10.1609/aiide.v16i1.7400

Ammanabrolu, P., & Riedl, M. O. (2021). Situated language learning via interactive narratives. *Patterns, 2*(9), Artículo 100316. https://doi.org/10.1016/j.patter.2021.100316

Arias, F. G. (2012). *El proyecto de investigación: Introducción a la metodología científica* (6.ª ed.). Episteme.

Barambones, J., Cano-Benito, J., Sánchez-Rivero, I., Imbert, R., & Richoux, F. (2023). Multiagent systems on virtual games: A systematic mapping study. *IEEE Transactions on Games, 15*(2), 134–147. https://doi.org/10.1109/TG.2022.3214154

Barzilay, R., & Lapata, M. (2008). Modeling local coherence: An entity-based approach. *Computational Linguistics, 34*(1), 1–34. https://doi.org/10.1162/coli.2008.34.1.1

Byrt, T., Bishop, J., & Carlin, J. B. (1993). Bias, prevalence and kappa. *Journal of Clinical Epidemiology, 46*(5), 423–429. https://doi.org/10.1016/0895-4356(93)90018-V

Callison-Burch, C., Tomar, G. S., Martin, L. J., Ippolito, D., Bailis, S., & Reitter, D. (2022). Dungeons and Dragons as a dialog challenge for artificial intelligence. En *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing* (pp. 9379–9393). Association for Computational Linguistics. https://doi.org/10.18653/v1/2022.emnlp-main.637

Casas-Roma, J., Nelson, M. J., Arnedo-Moreno, J., Gaudl, S. E., & Saunders, R. (2019). Towards simulated morality systems: Role-playing games as

artificial societies. En *Proceedings of the 11th International Conference on Agents and Artificial Intelligence* (pp. 244–251). SciTePress. https://doi.org/10.5220/0007496702440251

Cemri, M., Pan, M. Z., Yang, S., Agrawal, L. A., Chopra, B., Tiwari, R., Keutzer, K., Parameswaran, A., Klein, D., Ramchandran, K., Zaharia, M., Gonzalez, J. E., & Stoica, I. (2025). *Why do multi-agent LLM systems fail?* (arXiv:2503.13657) [Preprint]. arXiv. https://doi.org/10.48550/arXiv.2503.13657

Chen, R., Wang, J., Yu, L.-C., & Zhang, X. (2023). Learning to memorize entailment and discourse relations for persona-consistent dialogues. *Proceedings of the AAAI Conference on Artificial Intelligence, 37*(11), 12653–12661. https://doi.org/10.1609/aaai.v37i11.26489

Chhun, C., Colombo, P., Suchanek, F. M., & Clavel, C. (2022). Of human criteria and automatic metrics: A benchmark of the evaluation of story generation. En *Proceedings of the 29th International Conference on Computational Linguistics* (pp. 5794–5836). International Committee on Computational Linguistics.

Cliff, N. (1993). Dominance statistics: Ordinal analyses to answer ordinal questions. *Psychological Bulletin, 114*(3), 494–509. https://doi.org/10.1037/0033-2909.114.3.494

Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement, 20*(1), 37–46. https://doi.org/10.1177/001316446002000104

Covington, M. A., & McFall, J. D. (2010). Cutting the Gordian knot: The moving-average type–token ratio (MATTR). *Journal of Quantitative Linguistics, 17*(2), 94–100. https://doi.org/10.1080/09296171003643098

De Lima, E. S., Feijó, B., & Furtado, A. L. (2023). Managing the plot structure of character-based interactive narratives in games. *Entertainment Computing, 47*, Artículo 100590. https://doi.org/10.1016/j.entcom.2023.100590

Edge, D., Trinh, H., Cheng, N., Bradley, J., Chao, A., Mody, A., Truitt, S., Metropolitansky, D., Ness, R. O., & Larson, J. (2025). *From local to global:*

A graph RAG approach to query-focused summarization (arXiv:2404.16130) [Preprint]. arXiv. https://doi.org/10.48550/arXiv.2404.16130

Farrell, R., & Ware, S. G. (2025). Large language models as narrative planning search guides. *IEEE Transactions on Games, 17*(2), 419–428. https://doi.org/10.1109/TG.2024.3487416

Faul, F., Erdfelder, E., Lang, A.-G., & Buchner, A. (2007). G*Power 3: A flexible statistical power analysis program for the social, behavioral, and biomedical sciences.* Behavior Research Methods, 39*(2), 175–191. https://doi.org/10.3758/BF03193146*

Fernández Huerta, J. (1959). Medidas sencillas de lecturabilidad. *Consigna, 214*, 29–32.

Fleiss, J. L. (1971). Measuring nominal scale agreement among many raters. *Psychological Bulletin, 76*(5), 378–382. https://doi.org/10.1037/h0031619

Freireich, E. J., Gehan, E., Frei, E., III, Schroeder, L. R., Wolman, I. J., Anbari, R., Burgert, E. O., Mills, S. D., Pinkel, D., Selawry, O. S., Moon, J. H., Gendel, B. R., Spurr, C. L., Stokes, R., Haurani, F., Hoogstraten, B., & Lee, S. (1963). The effect of 6-mercaptopurine on the duration of steroid-induced remissions in acute leukemia: A model for evaluation of other potentially useful therapy. *Blood, 21*(6), 699–716.

Gallotta, R., Todd, G., Zammit, M., Earle, S., Liapis, A., Togelius, J., & Yannakakis, G. N. (2024). Large language models and games: A survey and roadmap. *IEEE Transactions on Games*. https://doi.org/10.1109/TG.2024.3461510

George, R. A. (2015). Narrative generation in entertainment: Using artificial intelligence planning. *Fields: Journal of Huddersfield Student Research, 1*(1). https://doi.org/10.5920/fields.2015.118

González-Romero, N., Gutiérrez-Romero, M. F., Molina Ríos, J. A., Mesa-Hoyos, T., & Carbonell-Blanco, O. A. (2021). Diseño y validación del instrumento para la evaluación de la calidad narrativa de relatos orales ficticios creados

con el Attachment Script Assessment. *Íkala, Revista de Lenguaje y Cultura, 26*(2), 395–412. https://doi.org/10.17533/udea.ikala.v26n2a07

Grosz, B. J., Joshi, A. K., & Weinstein, S. (1995). Centering: A framework for modeling the local coherence of discourse. *Computational Linguistics, 21*(2), 203–225.

Guinaudeau, C., & Strube, M. (2013). Graph-based local coherence modeling. En *Proceedings of the 51st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (pp. 93–103). Association for Computational Linguistics.

Guo, Z., Xia, L., Yu, Y., Ao, T., & Huang, C. (2025). *LightRAG: Simple and fast retrieval-augmented generation* (arXiv:2410.05779) [Preprint]. arXiv. https://doi.org/10.48550/arXiv.2410.05779

Gwet, K. L. (2008). Computing inter-rater reliability and its variance in the presence of high agreement. *British Journal of Mathematical and Statistical Psychology, 61*(1), 29–48. https://doi.org/10.1348/000711006X126600

Halliday, M. A. K., & Hasan, R. (1976). *Cohesion in English*. Longman.

Hausknecht, M., Ammanabrolu, P., Côté, M.-A., & Yuan, X. (2020). Interactive fiction games: A colossal adventure. *Proceedings of the AAAI Conference on Artificial Intelligence, 34*(05), 7903–7910. https://doi.org/10.1609/aaai.v34i05.6297

Hodges, J. L., & Lehmann, E. L. (1963). Estimates of location based on rank tests. *The Annals of Mathematical Statistics, 34*(2), 598–611. https://doi.org/10.1214/aoms/1177704172

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics, 6*(2), 65–70.

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys, 55*(12), Artículo 248. https://doi.org/10.1145/3571730

Kaplan, E. L., & Meier, P. (1958). Nonparametric estimation from incomplete observations. *Journal of the American Statistical Association, 53*(282), 457–481. https://doi.org/10.1080/01621459.1958.10501452

Kerby, D. S. (2014). The simple difference formula: An approach to teaching nonparametric correlation. *Comprehensive Psychology, 3*. https://doi.org/10.2466/11.IT.3.1

Kybartas, B., & Bidarra, R. (2017). A survey on story generation techniques for authoring computational narratives. *IEEE Transactions on Computational Intelligence and AI in Games, 9*(3), 239–253. https://doi.org/10.1109/TCIAIG.2016.2546063

Laclaustra, I. M., Ledesma, J. L., Méndez, G., & Gervás, P. (2014). Kill the dragon and rescue the princess: Designing a plan-based multi-agent story generator. En *Proceedings of the Fifth International Conference on Computational Creativity*. Jožef Stefan Institute.

Laird, J. E., & van Lent, M. (2001). Human-level AI's killer application: Interactive computer games. *AI Magazine, 22*(2), 15–25. https://doi.org/10.1609/aimag.v22i2.1558

Lehmann, E. L. (2006). *Nonparametrics: Statistical methods based on ranks* (ed. rev.). Springer.

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2021). *Retrieval-augmented generation for knowledge-intensive NLP tasks* (arXiv:2005.11401) [Preprint]. arXiv. https://doi.org/10.48550/arXiv.2005.11401

Li, J., Galley, M., Brockett, C., Gao, J., & Dolan, B. (2016). A diversity-promoting objective function for neural conversation models. En *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies* (pp. 110–119). Association for Computational Linguistics. https://doi.org/10.18653/v1/N16-1014

Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Petroni, F., & Liang, P. (2024). Lost in the middle: How language models use long contexts. *Transactions of the Association for Computational Linguistics, 12*, 157–173. https://doi.org/10.1162/tacl_a_00638

Manheim, D., & Garrabrant, S. (2019). *Categorizing variants of Goodhart's law* (arXiv:1803.04585) [Preprint]. arXiv. https://doi.org/10.48550/arXiv.1803.04585

Mankins, J. C. (1995). *Technology readiness levels: A white paper*. Office of Space Access and Technology, NASA.

Mantel, N. (1966). Evaluation of survival data and two new rank order statistics arising in its consideration. *Cancer Chemotherapy Reports, 50*(3), 163–170.

Martin, L. J., Sood, S., & Riedl, M. O. (2018). Dungeons and DQNs: Toward reinforcement learning agents that play tabletop roleplaying games. En *Proceedings of the Joint Workshop on Intelligent Narrative Technologies and Workshop on Intelligent Cinematography and Editing* (CEUR Workshop Proceedings, Vol. 2321). CEUR-WS.

Martinelli, G., Barba, E., & Navigli, R. (2024). Maverick: Efficient and accurate coreference resolution defying recent trends. En *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (pp. 13380–13394). Association for Computational Linguistics. https://doi.org/10.18653/v1/2024.acl-long.722

McCarthy, P. M., & Jarvis, S. (2010). MTLD, vocd-D, and HD-D: A validation study of sophisticated approaches to lexical diversity assessment. *Behavior Research Methods, 42*(2), 381–392. https://doi.org/10.3758/BRM.42.2.381

Murray, J. H. (1997). *Hamlet on the holodeck: The future of narrative in cyberspace*. Free Press.

Page, E. B. (1963). Ordered hypotheses for multiple treatments: A significance test for linear ranks. *Journal of the American Statistical Association, 58*(301), 216–230. https://doi.org/10.1080/01621459.1963.10500843

Pan, A. Z., Andronis, A., Hayek, E., Wilkinson, O. A. P., Lasy, I., Parry, A., Gadney, G., Smith, T. J., & Grierson, M. (2025). Guiding generative storytelling with knowledge graphs. *International Journal of Human–Computer Interaction*. https://doi.org/10.1080/10447318.2025.2603634

Papalampidi, P., Cao, K., & Kocisky, T. (2022). Towards coherent and consistent use of entities in narrative generation. En *Proceedings of the 39th International Conference on Machine Learning* (Vol. 162, pp. 17278–17294). PMLR.

Park, J. S., O'Brien, J., Cai, C. J., Morris, M. R., Liang, P., & Bernstein, M. S. (2023). Generative agents: Interactive simulacra of human behavior. En *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology* (Artículo 2). ACM. https://doi.org/10.1145/3586183.3606763

Peterson, J. (2012). *Playing at the world: A history of simulating wars, people and fantastic adventures, from chess to role-playing games*. Unreason Press.

Qu, X., Damoah, A., Sherwood, J., Liu, P., Shun Jin, C., Chen, L., Shen, M., Aleisa, N., Hou, Z., Zhang, C., Gao, L., Li, Y., Yang, Q., Wang, Q., & De Souza, C. (2025). *A comprehensive review of AI agents: Transforming possibilities in technology and beyond* (arXiv:2508.11957) [Preprint]. arXiv. https://doi.org/10.48550/arXiv.2508.11957

Riedl, M. O., & Bulitko, V. (2013). Interactive narrative: An intelligent systems approach. *AI Magazine, 34*(1), 67–77. https://doi.org/10.1609/aimag.v34i1.2449

Roemmele, M., Gordon, A. S., & Swanson, R. (2017). *Evaluating story generation systems using automated linguistic analyses* [Ponencia]. SIGKDD 2017 Workshop on Machine Learning for Creativity, Halifax, Canadá.

Romano, J., Kromrey, J. D., Coraggio, J., & Skowronek, J. (2006). *Appropriate statistics for ordinal level data: Should we really be using t-test and Cohen's d for evaluating group differences on the NSSE and other surveys?* [Ponencia]. Annual Meeting of the Florida Association of Institutional Research, Cocoa Beach, FL, Estados Unidos.

Santiago, J. M., Parayno, R. L., Deja, J. A., & Samson, B. P. V. (2023). *Rolling the dice: Imagining generative AI as a Dungeons & Dragons storytelling companion* (arXiv:2304.01860) [Preprint]. arXiv. https://doi.org/10.48550/arXiv.2304.01860

Schatzmann, J., Weilhammer, K., Stuttle, M., & Young, S. (2006). A survey of statistical user simulation techniques for reinforcement-learning of dialogue management strategies. *The Knowledge Engineering Review, 21*(2), 97–126. https://doi.org/10.1017/S0269888906000944

Shapiro, S. S., & Wilk, M. B. (1965). An analysis of variance test for normality (complete samples). *Biometrika, 52*(3–4), 591–611. https://doi.org/10.1093/biomet/52.3-4.591

Szigriszt-Pazos, F. (1993). *Sistemas predictivos de legibilidad del mensaje escrito: Fórmula de perspicuidad* [Tesis doctoral, Universidad Complutense de Madrid].

Trabasso, T., & van den Broek, P. (1985). Causal thinking and the representation of narrative events. *Journal of Memory and Language, 24*(5), 612–630. https://doi.org/10.1016/0749-596X(85)90049-X

Valdivia, A., & Burelli, P. (2025). Evaluating quality of gaming narratives co-created with AI. En *2025 IEEE Conference on Games (CoG)* (pp. 1–4). IEEE. https://doi.org/10.1109/CoG64752.2025.11114354

van der Linden, R., Lopes, R., & Bidarra, R. (2014). Procedural generation of dungeons. *IEEE Transactions on Computational Intelligence and AI in Games, 6*(1), 78–89. https://doi.org/10.1109/TCIAIG.2013.2290371

Van Velsen, M., Williams, J., & Verhulsdonck, G. (2009). Concepts for interactive digital storytelling: From table-top to game-AI. *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment, 5*(1), 173–178. https://doi.org/10.1609/aiide.v5i1.12374

Värtinen, S., Hämäläinen, P., & Guckelsberger, C. (2024). Generating role-playing game quests with GPT language models. *IEEE Transactions on Games, 16*(1), 127–139. https://doi.org/10.1109/TG.2022.3228480

Viana, B. M. F., & Dos Santos, S. R. (2019). A survey of procedural dungeon generation. En *2019 18th Brazilian Symposium on Computer Games and Digital Entertainment (SBGames)* (pp. 29–38). IEEE. https://doi.org/10.1109/SBGames.2019.00015

Ware, S. G., Garcia, E. T., Fisher, M., Shirvani, A., & Farrell, R. (2023). Multiagent narrative experience management as story graph pruning. *IEEE Transactions on Games, 15*(3), 378–387. https://doi.org/10.1109/TG.2022.3177125

Welleck, S., Weston, J., Szlam, A., & Cho, K. (2019). Dialogue natural language inference. En *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics* (pp. 3731–3741). Association for Computational Linguistics. https://doi.org/10.18653/v1/P19-1363

Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin, 1*(6), 80–83. https://doi.org/10.2307/3001968

Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association, 22*(158), 209–212. https://doi.org/10.1080/01621459.1927.10502953

Xia, H., Peng, H., Qi, Y., Wang, X., Xu, B., Hou, L., & Li, J. (2025). *StoryWriter: A multi-agent framework for long story generation* (arXiv:2506.16445) [Preprint]. arXiv. https://doi.org/10.48550/arXiv.2506.16445

Yannakakis, G. N., & Togelius, J. (2018). *Artificial intelligence and games*. Springer. https://doi.org/10.1007/978-3-319-63519-4

Yasunaga, M., Chen, X., Li, Y., Pasupat, P., Leskovec, J., Liang, P., Chi, E. H., & Zhou, D. (2024). Large language models as analogical reasoners. En *The Twelfth International Conference on Learning Representations (ICLR 2024)*.

Yu, P., Shen, D., Meng, S., Lee, J., Yin, W., Cui, A. Y., Xu, Z., Zhu, Y., Shi, X., Li, M., & Smola, A. (2025). *RPGBench: Evaluating large language models as role-playing game engines* (arXiv:2502.00595) [Preprint]. arXiv. https://doi.org/10.48550/arXiv.2502.00595

Zhou, P., Zhu, A., Hu, J., Pujara, J., Ren, X., Callison-Burch, C., Choi, Y., & Ammanabrolu, P. (2023). I cast detect thoughts: Learning to converse and guide with intents and theory-of-mind in Dungeons and Dragons. En *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (pp. 11136–11155). Association for Computational Linguistics. https://doi.org/10.18653/v1/2023.acl-long.624

Zhu, A., Aggarwal, K., Feng, A., Martin, L. J., & Callison-Burch, C. (2023). FIREBALL: A dataset of Dungeons and Dragons actual-play with structured game state information. En *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (pp. 4171–4193). Association for Computational Linguistics. https://doi.org/10.18653/v1/2023.acl-long.229

ANEXOS

Anexo 1. Ficha de los instrumentos de medición

La siguiente ficha resume, para cada indicador de la Rúbrica D&D-IA, los instrumentos deterministas aplicados sobre las 54 campañas del corpus, lo que cada uno mide, su dirección de mejora y la clasificación que obtuvo en la prueba de sensibilidad por perturbaciones y en las auditorías humanas descritas en el apartado 3.4.3. Solo los instrumentos confirmatorios y confirmatorios condicionados sustentan la docimasia de las hipótesis.

Indicador	Instrumento	Qué mide	Dirección de mejora	Clasificación
CR-1	Gramaticalidad (LanguageTool, sin ortografía)	Proporción de oraciones sin errores gramaticales	Mayor	Descriptivo (saturado cerca de 1)
CR-1	Pifia narrada como éxito	% de turnos en que una tirada de 1 natural se narra como éxito	Menor	Exploratorio (no reconoce la negación)
CR-1	Caracteres de otro alfabeto o U+FFFD	% de turnos con fallos de codificación o de idioma	Menor	Descriptivo
CR-2	Respuesta a la acción específica (z)	Solapamiento de lemas entre la acción y la respuesta, normalizado frente a un nulo de acciones de otros turnos	Mayor	Confirmatorio
CR-2	Solapamiento con la acción (crudo)	Solapamiento de lemas sin normalizar	Mayor	Descriptivo (mezcla componente específico y genérico; apartado 5.4)
CR-2	Anclaje al escenario (coseno, ventana de 8 turnos)	Similitud léxica de la narración con el escenario inicial propio	Mayor	Exploratorio (anclaje al mundo del escenario)
CR-2	Anclaje al escenario sin nombres propios	Ídem, excluidos los nombres propios	Mayor	Exploratorio
CR-2	Turnos con nombre no reconocido	% de turnos con palabras en mayúscula no registradas en el estado	Menor	Exploratorio (requiere la depuración del apartado 5.1)
CL-1	Coherencia de entidad (Papalampidi C)	Persistencia de las entidades más mencionadas como referentes rastreables	Mayor	Exploratorio
CL-1	Consistencia de atributos (Papalampidi V)	Estabilidad de los atributos asociados a cada entidad	Mayor	Exploratorio
CL-1	Tasa de correferencia de entidades	Proporción de entidades que corefieren con el contexto	Mayor	Descriptivo (saturado cerca de 1)
CL-2	Recuerdo de cambios de estado (Jericho-QA)	Proporción de cambios de estado registrados que la narración reconoce	Mayor	Exploratorio (discrimina solo en cambios de condición)
CL-2	PNJ inactivo mencionado	% de turnos que nombran a un personaje no jugador inactivo	Menor	Exploratorio
CL-2	PNJ inactivo como sujeto (refinado)	Ídem, solo cuando el personaje es sujeto gramatical	Menor	Exploratorio (precisión 62.5 %, exhaustividad 40.0 %)
CL-2	Turno de la primera mención de un PNJ no vivo	Turno en que ocurre por primera vez el fallo (análisis de supervivencia)	Mayor	Exploratorio

Indicador	Instrumento	Qué mide	Dirección de mejora	Clasificación
CL-2	Ciclos de ubicación	Fracción de campañas con ciclos entre lugares	Menor	Descriptivo (saturado)
CL-2	Relojes de facción reconocidos	Proporción de avances de reloj mencionados en la narración	Mayor	Descriptivo (indistinguible del azar)
CL-2	Recuerdo semántico (bge-m3, versión 2)	Reconocimiento de cambios de estado por similitud entre oraciones que mencionan a la entidad	Mayor	Exploratorio (recuerdo apenas superior al azar)
QN-1	TTR y repetición de bigramas por turno	Diversidad léxica y repetición sin control de longitud	Mayor / Menor	Exploratorio (confundido por la longitud)
QN-1	TTR y bigramas a 100 palabras	Ídem, sobre las primeras 100 palabras de cada turno	Mayor / Menor	Exploratorio
QN-1	MTLD y MATTR (ventana de 50)	Diversidad léxica independiente de la longitud	Mayor	Exploratorio
QN-1	Legibilidad Fernández Huerta y Szigriszt-Pazos	Facilidad de lectura según sílabas y longitud de frase	Sin dirección	Descriptivo
QN-1	Frases idénticas repetidas tres o más veces	% de turnos con fórmulas repetidas	Menor	Descriptivo
QN-2	persona2	% de turnos en que la narración decide, piensa, siente o habla por el personaje jugador de forma explícita	Menor	Confirmatorio condicionado (precisión 33.3 % frente al evaluador externo de referencia)

Fuente: elaboración propia. Los programas que implementan cada instrumento se encuentran en el repositorio descrito en el Anexo 3.

Anexo 2. Rúbrica D&D-IA y evaluación piloto del panel de expertos

La Rúbrica de Calidad Narrativa D&D-IA, versión 2.0, define los constructos que la batería de instrumentos operacionaliza. Organiza la coherencia narrativa en tres dimensiones y seis indicadores, cada uno con una definición operacional y descriptores para una escala ordinal de siete niveles, de 1, completamente deficiente, a 7, excelente:

- CR-1, fluidez y sentido lógico de la respuesta inmediata: respuestas cohesivas, consistentes con las reglas del juego y plausibles dado el estado inmediato anterior.
- CR-2, arraigo contextual: respuestas ancladas en la acción específica del jugador y en el estado del mundo, sin introducir entidades no establecidas.
- CL-1, consistencia de personajes a largo plazo: personajes que mantienen rasgos, motivaciones, historia, capacidades y voz a lo largo de la campaña.
- CL-2, consistencia de eventos y del estado del mundo: hechos establecidos con consecuencias duraderas que el sistema no ignora, contradice ni reinicia.
- QN-1, interés y creatividad: lenguaje evocador, elementos creativos y ausencia de repetición y monotonía.
- QN-2, reactividad a la agencia del jugador: decisiones con consecuencias visibles, sin que el sistema haga hablar, moverse o actuar al personaje jugador sin su control.

Las definiciones se adaptaron de los criterios de evaluación humana de FIREBALL (Zhu et al., 2023), de los criterios de fluidez, arraigo y cumplimiento de metas de Zhou et al. (2023) y del marco multidimensional de Pan et al. (2025), y se complementaron con la confiabilidad entre evaluadores reportada por Callison-Burch et al. (2022) y Chen et al. (2023) para criterios análogos. El protocolo original contemplaba un panel de cinco directores de juego con al menos cinco años de experiencia en D&D 5e, una evaluación de doble ciego con transcripciones anonimizadas y una sesión de calibración previa con el coeficiente de correlación intraclase como criterio de aceptación.

Durante la fase inicial del proyecto, el panel aplicó la rúbrica sobre tres campañas de una versión preliminar del sistema monolítico, lo que dio lugar a quince evaluaciones. Sus hallazgos cualitativos, en particular la colisión de identidades

entre personajes no jugadores, orientaron el diseño de varios instrumentos deterministas. Dado que dichas campañas proceden de una versión del sistema anterior al congelamiento y que la escala Likert no es comparable con los instrumentos del corpus experimental, esta evaluación se conserva únicamente como estudio piloto, conforme a la desviación declarada en el apartado 3.5.4.

Anexo 3. Evidencias de la ejecución y trazabilidad de la investigación

Todos los elementos necesarios para reproducir el corpus, las mediciones y los análisis se conservan en el repositorio del proyecto (https://github.com/BMarin2003/ORQUESTADOR-DM-IA), organizado de la siguiente manera:

- Código de las dos arquitecturas: el ciclo del turno de la arquitectura monolítica y de la multiagente, el enrutador, el árbitro, el agente del mundo, el módulo de tiradas deterministas y el extractor con su contrato de tipos permitidos.
- Instrucciones del sistema: los prompts del director de juego monolítico, de los cuatro roles multiagente que recurren al modelo, del extractor y del agente jugador, junto con las fichas de los 27 personajes jugadores.
- Esquema de la base de datos del estado del mundo y la migración que añade la capa de medición semántica, separada de las tablas que intervienen en la generación.
- Transcripciones de las 54 campañas de 1,400 turnos, con sus resúmenes de integridad, y las bitácoras de ejecución de cada tanda, que registran la latencia de cada llamada al modelo.
- Manifiesto de huellas del modelo empleado para verificar su estabilidad antes de cada tanda de generación.
- Instrumentos de medición, especificaciones de la prueba de sensibilidad con sus expectativas protegidas mediante resumen SHA-256, reportes consolidados por campaña y por par y scripts de los análisis estadísticos.
- Materiales de la validación humana externa: formularios de etiquetado ciego, claves de correspondencia separadas de los formularios y registros de los evaluadores del detector de personajes no jugadores inactivos y de persona2.
- Reportes de los cierres de brecha de cada objetivo y del análisis de costo por arquitectura.

Anexo 4. Resolución de aprobación del proyecto de investigación

[Insertar copia de la Resolución Directoral de aprobación del proyecto de investigación]

Anexo 5. Constancia del asesor

[Insertar constancia firmada por el asesor]